

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

На правах рукописи

Дорин Даниил Дмитриевич

**Пространственно-временные характеристики в задаче
декодирования мультимодальных многомерных
временных рядов**

Специальность 1.2.1 —
«Искусственный интеллект и машинное обучение»

Диссертация на соискание ученой степени
кандидата физико-математических наук

Научный руководитель:
кандидат физико-математических наук
Грабовой Андрей Валериевич

Москва — 2026

Оглавление

	Стр.
Введение	5
Глава 1. Анализ предметной области и постановка задачи	11
1.1. Декодирование сигналов мозга и интерфейсы мозг–компьютер . .	12
1.2. Модальности регистрации мозговой активности: фМРТ и ЭЭГ . .	13
1.3. Парадигмы стимуляции и локализация активных областей мозга	15
1.4. Пространственно-временные характеристики в анализе нейросигналов	15
1.5. Одномодальные методы декодирования визуальной информации	16
1.6. Визуальные энкодеры для извлечения семантических признаков .	19
1.7. Генеративные модели для реконструкции изображений	19
1.8. Наборы данных для декодирования визуальных стимулов	20
1.9. Постановка задачи декодирования	21
Глава 2. Оценка гемодинамического лага по временной динамике фМРТ	23
2.1. Постановка задачи	23
2.2. Линейная модель для оценки гемодинамического лага	24
2.3. Вычислительный эксперимент	26
2.3.1. Данные и постановка эксперимента	26
2.3.2. Пример прогноза	28
2.3.3. Анализ гемодинамического лага	28
2.3.4. Выбор параметра регуляризации	30
2.3.5. Влияние сжатия на время обучения	31
2.3.6. Распределение весов модели	32
2.3.7. Гипотеза об инвариантности весов относительно пациентов	33
2.3.8. Корректность метода на неинформативных данных	34
2.4. Обсуждение результатов	35

Глава 3. Пространственно-временная классификация

временных рядов фМРТ в условиях ограниченной	
выборки	37
3.1. Постановка задачи	37
3.2. Метод классификации	38
3.2.1. Извлечение масок активности мозга	40
3.2.2. Классификация временных рядов	43
3.2.3. Проекция на касательное пространство риманова многообразия	44
3.2.4. Сегментация временных рядов для аугментации	47
3.3. Теоретические свойства проекции на касательное пространство	48
3.3.1. Риманова структура и координаты признаков	48
3.3.2. Инвариантность к преобразованию каналов	50
3.3.3. Искажение расстояний касательной проекцией	52
3.3.4. Шум оценки ковариаций	56
3.4. Вычислительный эксперимент	59
3.4.1. Аугментация данных	60
3.4.2. Оценка алгоритма выделения масок	61
3.4.3. Результаты классификации	62
3.4.4. Анализ исключением компонент	65
3.4.5. Сравнение с нейросетевыми подходами	66
3.4.6. Численная проверка оценки искажения расстояний	68
3.4.7. Эксперименты на синтетических данных	68
3.5. Обсуждение результатов	72

Глава 4. Мульти模альная реконструкция визуальных

стимулов по сигналам фМРТ–ЭЭГ	74
4.1. Постановка задачи	74
4.2. Метод реконструкции	74
4.2.1. Восстановление отсутствующих каналов ЭЭГ	75
4.2.2. Контрастивное обучение комбинированных представлений	79
4.2.3. Процесс реконструкции стимулов	84
4.3. Вычислительный эксперимент	86
4.3.1. Данные	87

	Стр.
4.3.2. Параметры энкодеров	89
4.3.3. Результаты экспериментов	91
4.3.4. Ограничения метода	95
Заключение	97
Публикации автора по теме диссертации	99
Список рисунков	102
Список таблиц	109

Введение

Декодирование по сигналам мозга — одна из центральных задач нейровизуализации и интерфейсов мозг–компьютер: по зарегистрированной активности требуется восстановить вызвавшее ее внешнее воздействие или его категорию [10–12]. Такие интерфейсы уже применяются в клинической практике [13]. С их помощью пациенты с тетраплегией управляют протезом руки [14–16] и экзоскелетом [17]. Интерфейсы восстанавливают ходьбу после травмы спинного мозга [18] и общение при параличе [19–21]. Зрительные протезы частично возвращают зрение незрячим пациентам [22; 23]. Декодирование активности мозга используется и в диагностике, в том числе нарушений сознания [24] и болезни Альцгеймера [25–27].

Системы протезирования инвазивны и требуют хирургического вмешательства [13]. Неинвазивная регистрация безопасна и применяется значительно шире, поэтому именно на ней разрабатываются и проверяются методы декодирования [28]. Регистрируемые сигналы представляют собой мультимодальные многомерные временные ряды. Функциональная магнитно-резонансная томография (фМРТ) дает высокое пространственное разрешение при низкой частоте сканирования и гемодинамическом лаге отклика [29; 30], а электроэнцефалография (ЭЭГ) — высокое временное разрешение при слабой пространственной локализации [31]. Эти модальности дополняют друг друга по пространству и времени, и их совместный анализ открывает возможности, недоступные каждой из них в отдельности [32; 33].

Основное препятствие на этом пути — ограниченный объем выборки. Запись активности одного пациента сводится к одному протяженному временному ряду, число размеченных объектов измеряется десятками, тогда как размерность сигнала составляет десятки тысяч вокселей [34]. В таких условиях нейросетевые модели, требующие больших обучающих выборок, теряют качество [35; 36], а методы, не учитывающие структуру данных, не отделяют сигнал от шума. Поэтому актуальна разработка методов декодирования, которые явно используют временную структуру сигнала, прежде всего гемодинамический лаг, его пространственную структуру, то есть локализацию активных областей и ковариационные связи между ними, и межмодальную взаимодополняемость

фМРТ и ЭЭГ, сохраняя при этом работоспособность при малом объеме выборки.

Отдельный вопрос составляет обоснованность применяемых конструкций. Проекция ковариационных матриц на касательное пространство риманова многообразия широко применяется в анализе нейросигналов [37—39], однако используется как эвристика: инвариантность признаков к преобразованию каналов, близость евклидовой геометрии касательного пространства к геометрии многообразия и устойчивость признаков к ошибке оценки ковариации по короткому ряду принимаются без явных констант. Получение таких гарантий необходимо для обоснованного выбора параметров метода и области его применимости.

Целью данной работы является разработка методов декодирования внешнего воздействия по мультимодальным многомерным временным рядам, использующих временную, пространственную и межмодальную структуру сигнала и сохраняющих работоспособность в условиях ограниченного объема выборки. Для достижения цели были поставлены и решены следующие **задачи**:

1. Построить модель прогнозирования фМРТ-отклика по предъявленному стимулу и на ее основе метод оценки гемодинамического лага.
2. Разработать метод классификации временных рядов фМРТ одного пациента на основе масок активности классов и проекции ковариационных матриц на касательное пространство риманова многообразия.
3. Исследовать теоретические свойства касательных признаков ковариационных матриц: инвариантность к преобразованию каналов, искажение расстояний при проекции и устойчивость к шуму оценки ковариации.
4. Построить мультимодальную архитектуру реконструкции стимула по одновременным записям фМРТ и ЭЭГ.
5. Провести вычислительные эксперименты на открытых наборах данных и сравнить предложенные методы с нейросетевыми и классическими подходами.

Объектом исследования настоящей работы являются мультимодальные многомерные временные ряды, в частности ряды нейровизуализации, регистрируемые методами фМРТ и ЭЭГ в ответ на внешнее воздействие.

Предметом исследования данной работы являются методы декодирования внешнего воздействия, учитывающие временную, пространственную и межмодальную структуру таких рядов, и их теоретические свойства.

Научная новизна:

1. Предложен метод оценки гемодинамического лага по минимуму ошибки авторегрессионного прогноза фМРТ-отклика по стимулу; показано, что в области наибольшего отклика ошибка имеет выраженный минимум, согласованный с физиологическими оценками лага, тогда как по всему объему скана минимум не выражен.
2. Предложен метод классификации временных рядов фМРТ, в котором объект описывается отдельно с точки зрения каждого класса: маска активности класса отбирает воксели по кросс-корреляции со стимулом, а ковариация их рядов проецируется на касательное пространство в точке риманова среднего; размерность признаков не зависит от объема выборки.
3. Доказаны инвариантность касательных признаков к невырожденному преобразованию каналов, двусторонняя оценка искажения расстояний с неухудшаемой константой, выраженной через спектральный разброс касательных векторов, и оценка концентрации ошибки оценки ковариации в геодезической метрике, распределение которой не зависит от истинной ковариации.
4. Предложена мультимодальная архитектура реконструкции стимула по одновременным записям фМРТ и ЭЭГ с контрастивным выравниванием совместных представлений с пространством CLIP (англ. Contrastive Language-Image Pre-training) и двухстадийной диффузионной генерацией; показано, что объединение модальностей повышает качество реконструкции по сравнению с каждой из них в отдельности.

Теоретическая значимость полученных результатов заключается в строгом обосновании широко применяемой конструкции касательных признаков ковариационных матриц: доказаны инвариантность признаков к преобразованию каналов, двусторонняя оценка искажения расстояний с явной константой и оценка шума оценки ковариации, связывающая число каналов и длину ряда. Результаты не зависят от природы сигнала и применимы к любым многоканальным временным рядам, описываемым ковариацией каналов.

Практическая значимость настоящей работы заключается в применимости методов оценки лага и классификации к выборке одного пациента объемом в десятки объектов, где нейросетевые модели не обучаются, и в межсубъектной нейросетевой архитектуре реконструкции стимула, обучаемой на одновременных записях фМРТ и ЭЭГ многих пациентов; методы проверены на открытых наборах данных по воспроизводимым протоколам, а их программные реализации опубликованы в открытых репозиториях. Результаты анализа лага учтены при построении масок активности и синхронизации модальностей, а метод восстановления отсутствующих каналов ЭЭГ позволяет применять обученные модели к записям с неполным монтажом.

Методология и методы исследования. Для достижения поставленных в диссертационной работе целей используются:

1. Методы линейной алгебры и римановой геометрии: аффинно-инвариантная метрика на многообразии симметричных положительно определенных матриц, матричные функции, дифференциал матричной экспоненты.
2. Методы теории вероятностей и математической статистики: неасимптотические оценки сингулярных чисел гауссовых матриц, проверка статистических гипотез с поправкой на множественные сравнения, доверительные интервалы.
3. Методы машинного обучения и вычислительного эксперимента: регуляризованная линейная регрессия, логистическая регрессия, контрастное обучение представлений, диффузионные генеративные модели, воспроизводимая постановка экспериментов на открытых данных.

Основные положения, выносимые на защиту:

1. Линейная авторегрессионная модель прогнозирования фМРТ-отклика по предъявленному стимулу и метод оценки гемодинамического лага BOLD-сигнала на ее основе.
2. Метод классификации временных рядов фМРТ на основе масок активности классов и проекции ковариационных матриц на касательное пространство риманова многообразия, устойчивый в условиях ограниченного объема выборки одного пациента.
3. Теоретические свойства проекции ковариационных матриц на касательное пространство в точке риманова среднего: инвариантность признаков к невырожденному преобразованию каналов, двусторонняя

оценка искажения расстояний с неулучшаемой константой и оценка ошибки оценки ковариации по длине ряда.

4. Мультимодальная архитектура реконструкции стимула по одновременным сигналам фМРТ и ЭЭГ с контрастивным выравниванием совместных представлений и двухстадийной диффузионной генерацией.

Соответствие паспорту специальности. Диссертационная работа соответствует паспорту научной специальности 1.2.1 — «Искусственный интеллект и машинное обучение», а именно в наибольшей степени следующим направлениям исследований: п. 12 «Исследования в области надежности, устойчивости и переобучения систем класса ИИ»; п. 15 «Математические исследования в области статистики, логики, алгебры, топологии, анализа функций и других областях, ориентированные на решение задач искусственного интеллекта и машинного обучения»; п. 16 «Исследования в области специальных методов оптимизации, проблем сложности и снижения размерности»; п. 17 «Исследования в области многослойных алгоритмических конструкций, в том числе многослойных нейросетей».

Достоверность полученных результатов обеспечивается корректностью применения апробированного математического аппарата римановой геометрии, теории вероятностей и математической статистики, математически строгими доказательствами теоретических утверждений, а также экспериментальной проверкой разработанных методов на открытых наборах данных с фиксированными протоколами разбиения, статистическими критериями с поправкой на множественные сравнения и доверительными интервалами. Для вычислительных экспериментов даются детальные описания и опубликован программный код, обеспечивающие их воспроизводимость. Результаты опубликованы в рецензируемых научных изданиях и доложены на российских и международных конференциях по машинному обучению и анализу данных.

Апробация работы. Основные результаты работы докладывались и обсуждались на следующих научных конференциях:

1. 16-я Международная конференция «Интеллектуализация обработки информации (ИОИ-2026)», Витебск, Беларусь, 28 сентября – 1 октября 2026 г.
2. 68-я Всероссийская научная конференция МФТИ, Долгопрудный, 30 марта – 4 апреля 2026 г.

3. X Международная конференция по искусственному интеллекту AI Journey 2025, Москва, 19–21 ноября 2025 г.
4. 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025 г.
5. 67-я Всероссийская научная конференция МФТИ, Долгопрудный, 31 марта – 5 апреля 2025 г.
6. XXVI Международная научно-техническая конференция «Нейроинформатика-2024», Долгопрудный, 21–25 октября 2024 г.
7. 66-я Всероссийская научная конференция МФТИ, Долгопрудный, 1–6 апреля 2024 г.

Личный вклад. Все приведенные результаты, кроме отдельно оговоренных случаев, получены диссертантом лично при научном руководстве к.ф.-м.н. А.В. Грабового.

Публикации. *Список публикаций приведен в конце диссертации.* Основные результаты по теме диссертации изложены в 0 научных работах, из которых 3 — в периодических научных журналах, индексируемых Web of Science и Scopus, а остальные 6 — в тезисах докладов российских и международных конференций.

Объем и структура работы. Диссертация состоит из введения, 4 глав и заключения. Полный объем диссертации составляет 110 страниц, включая 31 рисунок и 14 таблиц. Список литературы содержит 148 наименований.

Глава 1. Анализ предметной области и постановка задачи

В главе рассматриваются составляющие, на которые опирается декодирование визуальной информации по сигналам мозга: свойства регистрируемых модальностей фМРТ и ЭЭГ, парадигмы стимуляции и локализация активных областей, методы анализа пространственно-временных характеристик нейросигналов, одномодальные методы декодирования, визуальные энкодеры, генеративные модели реконструкции и наборы данных. Детальное изложение методов и экспериментов приводится в последующих главах, основанных на работах автора [40–48].

Общее устройство работы иллюстрирует рис. 1.1: три постановки задачи декодирования упорядочены по сложности описываемой структуры данных — от временной динамики фМРТ к ее пространственно-временной структуре и далее к мультимодальному объединению фМРТ–ЭЭГ.




Рисунок 1.1 — Три постановки задачи декодирования, упорядоченные по сложности описываемой структуры данных. Штриховые линии — учет гемодинамического лага Δt , необходимость которого показана в первой постановке, в двух последующих: при построении масок активности и при временной синхронизации модальностей

1.1. Декодирование сигналов мозга и интерфейсы мозг–компьютер

Современные достижения в области анализа нейробиологических данных и нейровизуализации существенно расширили возможности разработки интерфейсов мозг–компьютер (ИМК) [10; 49]. ИМК — это технология прямого взаимодействия нервной системы с внешними устройствами в обход периферических нервно-мышечных путей [50]. Регистрируя и декодируя нейробиологические сигналы, такие системы переводят ментальные намерения и когнитивные состояния в управляющие команды для протезов, роботов или компьютерных интерфейсов [41; 51; 52]. Для пациентов с тяжелыми двигательными или коммуникативными нарушениями это открывает возможность вернуть способность к автономному взаимодействию с окружающей средой [53].

Наибольших успехов достигли инвазивные интерфейсы, регистрирующие активность непосредственно с коры. Пациенты с тетраплегией управляют с их помощью роботизированной рукой [14; 15], а стимуляция соматосенсорной коры дополняет такой протез тактильной обратной связью [16]. Декодирование воображаемого почерка и речи восстанавливает общение у парализованных пациентов [19—21]. Интерфейсы, управляющие экзоскелетом и стимуляцией спинного мозга, возвращают возможность ходить [17; 18]. Зрительные протезы решают обратную задачу: стимуляция сетчатки или зрительной коры вызывает зрительные ощущения у незрячих пациентов [22; 23]. Их разработка требует понимания того, как зрительный стимул отображается в активность коры.

Инвазивные интерфейсы требуют хирургического вмешательства, поэтому в исследованиях и диагностике преобладает неинвазивная регистрация: электроэнцефалография (ЭЭГ), магнитоэнцефалография (МЭГ) и функциональная магнитно-резонансная томография (фМРТ). По данным фМРТ удастся установить контакт с пациентами в нарушенном состоянии сознания [24]. Изменения функциональной активности мозга по данным фМРТ и ЭЭГ служат признаками болезни Альцгеймера, в том числе на ранних стадиях [25—27]. Во всех этих приложениях объем данных одного пациента ограничен.

Настоящая работа посвящена задаче декодирования и реконструкции визуальных стимулов по одновременным неинвазивным записям мозговой активности — фМРТ и ЭЭГ. Регистрируемые сигналы отражают динамику

восприятия визуальных сцен, причем само восприятие зависит не только от свойств внешнего стимула, но и от внутренних когнитивных состояний, эмоциональных реакций и индивидуального опыта наблюдателя.

Совокупность методов визуализации структуры и функций мозга называется нейровизуализацией [54]; ее методы, включая компьютерную и магнитно-резонансную томографию, применяются как для изучения мозга, так и для выявления заболеваний и психических расстройств [55—57]. Анализ данных фМРТ имеет решающее значение для понимания функций мозга в современной нейронауке и когнитивной психологии [30; 58], а классификация временных рядов фМРТ — важная задача, имеющая значимые применения в медицине и технологиях [59—61]. Точная классификация данных фМРТ позволяет проводить строгую диагностику неврологических и психиатрических расстройств [62—65], а понимание нейронных реакций на стимулы способствует улучшению результатов лечения [66]. Последние исследования сосредоточены на методах анализа активности мозга и декодирования данных [67—69]; к этому направлению относятся и три постановки, рассматриваемые в работе.

1.2. Модальности регистрации мозговой активности: фМРТ и ЭЭГ

ЭЭГ и фМРТ — две ключевые нейробиологические модальности, чьи пространственно-временные характеристики разрешения взаимно дополняют друг друга. Функциональная магнитно-резонансная томография — разновидность магнитно-резонансной томографии, основанная на изменениях кровотока, индуцированных нейронной активностью мозга [29]; она позволяет определить, какие области мозга активируются внешними стимулами. фМРТ измеряет связанный с нейронной активностью гемодинамический ответ через сигнал, зависящий от уровня оксигенации крови (англ. Blood-Oxygen-Level-Dependent, BOLD), который проявляется с лагом 4–8 секунд [40; 70]; такой лаг отражает инерционность сосудистой системы, медленно реагирующей на возросшую потребность мозга в глюкозе [71—73]. При регистрации используются последовательности эхопланарных изображений (англ. Echo-Planar Imaging, EPI) [74—76]. Обработка областей с различной интенсивностью сигнала, зависящей от способа активации и типа артефактов, выполняется специализированными методами

и программными средствами [70; 77; 78]; обработанные результаты формализуются в виде карт активации, совмещаемых с локализацией анатомических структур коры головного мозга.

Между фМРТ-сканами и соответствующими им кадрами стимула предполагается наличие устойчивого временного лага [73], однако его величина варьируется между пациентами [79; 80], поэтому при построении персонализированных моделей эту вариативность необходимо учитывать. В работе [40] показано, что учет лага имеет решающее значение для методов предсказания сигналов фМРТ по видеоряду. Оценке лага по временной динамике фМРТ посвящена глава 2. Она показывает, что качество прогноза отклика зависит от лага и что эта зависимость проявляется лишь в области, отвечающей за обработку стимула. Лаг учитывается далее при построении масок активности в главе 3 и при синхронизации модальностей в главе 4, а выделение информативной области лежит в основе самих масок.

Сильная сторона фМРТ — высокое пространственное разрешение, тогда как временное жестко ограничено малой частотой сканирования [29; 30; 81]. К этому добавляется чувствительность записи к артефактам от движений головы, пульсации, дыхания и теплового шума сканера [30; 81]; для подавления такого шума предложены, в частности, графовые методы, показавшие эффективность в задачах выявления эпилепсии и депрессии [82]. ЭЭГ устроена противоположным образом: она дает высокое временное разрешение и позволяет следить за динамикой нейронных процессов в реальном времени [83], однако ее пространственная локализация ограничена объемной проводимостью тканей головы, а сам сигнал ослаблен низким отношением сигнал/шум [84] и выраженной межиндивидуальной вариабельностью [85; 86]. Совмещение ЭЭГ и фМРТ в одной сессии объединяет достоинства обеих модальностей, но заставляет считаться со спецификой магнитно-резонансной среды: сильное магнитное поле порождает мощные градиентные и кардиобаллистические артефакты [32; 87]. Для их компенсации необходимы магнитно-резонансно совместимые системы записи, точная синхронизация временных меток и специализированные методы постобработки [33].

1.3. Парадигмы стимуляции и локализация активных областей мозга

Во время сбора данных фМРТ пациентам предлагаются различные задачи и стимулы, активирующие локальные области мозга, ответственные за выполнение соответствующих функций. Эти стимулы могут быть визуальными, моторными или когнитивными задачами разных категорий. Типичные задачи включают движения пальцами и конечностями [88—90], просмотр изображений различных категорий и наблюдение за шахматной доской [91; 92], а также прослушивание неспецифических звуков, отдельных слов или непрерывной речи [93; 94]. Изменения активности мозга во время фМРТ-обследования вызывает и просмотр видео [95]. В настоящей работе рассматриваются визуальные стимулы двух типов: видеоряд в главах 2 и 4 и статичные изображения различных категорий в главе 3.

Активные области мозга, ответственные за выполнение конкретных задач, называются областями интереса (англ. Region of Interest, ROI); их выделение — важный этап предобработки данных ЭЭГ, фМРТ и других нейровизуализационных данных [96]. Точное выделение активных областей составляет ключевой этап декодирования фМРТ: значительная доля вокселей соответствует фону и вносит шум, тогда как за обработку конкретных стимулов — визуальных, когнитивных и моторных — отвечают локальные зоны [40; 96; 97]. Так, при просмотре видео активируется специфическая сеть областей, включающая затылочную долю и фронтальные области и расположенная преимущественно в правом полушарии [98]; эта локализация используется в главе 2 при оценке лага. В главе 3 маски активности для каждой категории стимулов извлекаются непосредственно из данных по кросс-корреляции сигнала вокселей с временным рядом стимулов.

1.4. Пространственно-временные характеристики в анализе нейросигналов

Наряду с пространственной локализацией важна временная динамика сигнала, и для ее описания хорошо зарекомендовала себя риманова геометрия. Она представляет нейросигнал ковариационными матрицами и работает с ними как с точками на многообразии симметричных положительно определенных матриц, а не как с векторами в евклидовом пространстве [37; 99; 100]. Такой подход успешно применялся к ЭЭГ в задачах классификации моторных образов [38; 39; 101–103], распознавания эмоций [104] и диагностики заболеваний [105; 106], что мотивирует его перенос на данные фМРТ. Классические методы снижения размерности здесь уступают: метод независимых компонент [107] разделяет многомерный сигнал на аддитивные статистически независимые компоненты, но требует наличия множества сигналов [108] и не учитывает геометрическую структуру симметричных положительно определенных матриц [109], а метод главных компонент [110] предполагает евклидово пространство и игнорирует неевклидову геометрию ковариационных матриц [111], что ведет к потере пространственных связей в данных.

Современные архитектуры глубокого обучения, включая рекуррентные нейронные сети, трансформеры и графовые сверточные сети, демонстрируют высокую эффективность при выявлении сложных зависимостей в многомерных временных рядах [60; 112; 113]. Тем не менее, для достижения высокой обобщающей способности этим моделям требуются обширные обучающие выборки [35; 36]; так, графовые сверточные сети продемонстрировали потенциал в диагностике депрессии и аутизма на больших наборах данных, однако требуют обширной предобработки [60; 114]. В контексте нейровизуализации объем доступных данных, напротив, существенно ограничен, поскольку запись активности одного пациента, как правило, сводится к единственному, протяженному, временному ряду. Поэтому необходимы методы, извлекающие пространственно-временные признаки в условиях малого объема выборки.

1.5. Одномодальные методы декодирования визуальной информации

Значительное число исследований посвящено анализу визуальных стимулов, предъявляемых во время фМРТ-сканирования [11; 12; 115—118]: по результатам томографии в них либо предсказывается категория предъявленного изображения, либо генерируется само изображение. В ряде работ в качестве стимулов используются видеозаписи [119—121]; из-за большого объема данных такой подход вычислительно сложен и требует больших трансформерных моделей, тогда как не всякий практический вопрос требует столь детального анализа исследуемой зависимости. Поэтому для анализа связи между видеорядом и фМРТ-откликом в главе 2 используется линейная модель.

В связи с развитием контрастивного обучения появилась возможность эффективно сопоставлять данные из разных модальностей. Так, в модели CLIP (англ. Contrastive Language-Image Pre-training) [122] с помощью контрастивной функции потерь, построенной на косинусном расстоянии, удалось обучить совместное латентное пространство для эмбеддингов изображений и текстовых описаний. Аналогичный подход был распространен и на другие пары модальностей — при условии подбора соответствующих энкодеров [123; 124]. В области ИМК это привело к появлению методов реконструкции изображений по нейробиологическим сигналам, в первую очередь по фМРТ или ЭЭГ в отдельности [125; 126]. Основная идея большинства современных моделей сводится к контрастивному приближению эмбеддингов мозговой активности к CLIP-эмбеддингам изображений. Поскольку CLIP обучался на сопоставлении изображений и текста, его пространство эмбеддингов обладает богатой семантической структурой и демонстрирует высокую эффективность в задачах zero-shot (англ. zero-shot, «без примеров»), то есть на новые данные без дополнительного обучения [122]. Это делает CLIP-эмбеддинги особенно подходящими для обуславливания генеративных моделей, используемых в реконструкции изображений, предъявленных пациенту во время записи нейросигналов [126].

Недавние достижения в декодировании визуальной информации по фМРТ продемонстрировали высокое качество реконструкции за счет интеграции контрастивного обучения и генеративных моделей [125]. Авторы [118] предлагают двухэтапную модель: на первом этапе данные фМРТ кодируются с помощью

регрессии, обучаемой индивидуально для каждого пациента, после чего реконструируется грубое изображение с помощью очень глубокого вариационного автокодировщика (англ. Very Deep Variational Autoencoder, VDVAE); на втором — изображение уточняется диффузионной моделью, обусловленной как CLIP-эмбедами исходного изображения, так и его текстовым описанием, что обеспечивает высокую семантическую согласованность реконструкции. В работе [119] предлагается метод реконструкции видео по временному ряду фМРТ. Используется контрастивное обучение и CLIP-эмбедами, аналогично предыдущему исследованию. Генерация видео осуществляется с помощью модифицированной диффузионной модели с временным вниманием и обуславливанием на эмбедами фМРТ. В работе [127] предлагается диффузионная априорная модель для уточнения фМРТ-эмбеддингов в CLIP-пространстве, устраняющая разрыв между модальностями и повышающая качество декодирования. На основе ЭЭГ также достигнуто сопоставимое качество реконструкции. Основная идея многих работ аналогична: двухэтапная реконструкция — сначала контрастивно обучаются эмбедами сигналов ЭЭГ к CLIP-эмбедами изображений, затем используются предобученная генеративная модель для реконструкции [126; 128; 129]. В качестве кодировщиков применяют различные архитектуры: индивидуальные для каждого пациента сети долгой краткосрочной памяти (англ. Long Short-Term Memory, LSTM) [129], сверточные сети [128], а также гибридные архитектуры, сочетающие свертки с механизмом внимания [126]. Однако существующие подходы опираются лишь на одну модальность. В то же время фМРТ и ЭЭГ, как отмечено в разделе 1.2, обладают взаимодополняющими характеристиками разрешения, и их комбинация позволяет компенсировать слабые стороны каждой из модальностей и потенциально повысить качество реконструкции. Представленные подходы легли в основу проектирования предлагаемого мультимодального энкодера.

В главе 4 данной работы решается задача реконструкции изображений по одновременно зарегистрированным сигналам фМРТ–ЭЭГ, как проиллюстрировано на рис. 1.2.




Рисунок 1.2 — Иллюстрация задачи реконструкции изображений по одновременным сигналам фМРТ-ЭЭГ

1.6. Визуальные энкодеры для извлечения семантических признаков

Визуальный энкодер является одной из ключевых компонент рассматриваемой модели, поскольку от его качества напрямую зависит, насколько полно удастся извлечь семантическую информацию из изображения, включая объекты, их позы и контекст сцены. Для многих задач традиционно используются предобученные с учителем энкодеры, среди которых наиболее распространены сверточные архитектуры VGG-19 (англ. Visual Geometry Group) [130] и остаточные сети ResNet (англ. Residual Network) [131], а также Vision Transformer (ViT) [132]. Такие энкодеры дают устойчивые визуальные эмбединги, и все же, как показывают недавние работы по контрастивному обучению и самообучению, модели вроде CLIP [122] и DINO (англ. self-Distillation with NO labels) [133] на базе ViT формируют заметно более выразительные и обобщаемые представления, чем их аналоги, обученные с учителем. Это преимущество устойчиво проявляется в широком круге задач переноса обучения — в том числе при декодировании и реконструкции изображений по нейросигналам. Поэтому в роли визуального энкодера в мультимодальной постановке выбран именно CLIP [122]: он эффективен, устойчив к доменным сдвигам и обладает богатой семантической структурой латентного пространства. Для видеостимулов известные методы обработки основаны на трехмерных сверточных сетях, обрабатывающих пространственную и временную информацию одновременно, что увеличивает число параметров и вычислительную сложность [134]; в главе 2, где выбор энкодера не принципиален для корреляционной структуры исследуемых рядов, кадры видеоряда кодируются покадрово сетью ResNet152 [131].

1.7. Генеративные модели для реконструкции изображений

Современные генеративные модели изображений сыграли ключевую роль в продвижении задач визуального декодирования. Наиболее успешными оказались латентно-диффузионные архитектуры, которые работают в компактном скрытом пространстве и допускают гибкое обуславливание на внешние эмбединги [135; 136]. Отдельную линию исследований составляют модели, непосредственно обусловленные на CLIP-эмбединги изображений и/или текста, что позволяет использовать общее семантическое пространство для управления генерацией [122; 137]. В таких подходах CLIP-пространство выступает универсальным интерфейсом между модулями, кодирующими различные модальности, и генератором. В настоящей работе следует этой парадигме: для реконструкции изображений используется предобученная латентно-диффузионная модель SDXL (англ. Stable Diffusion XL) [138], обусловленная на CLIP-эмбединги через адаптер IP-Adapter (англ. Image Prompt Adapter) [138; 139], что позволяет напрямую переносить информацию из комбинированных эмбедингов фМРТ–ЭЭГ в пространство генерации.

1.8. Наборы данных для декодирования визуальных стимулов

Три рассматриваемые постановки опираются на открытые наборы данных с визуальной стимуляцией, различающиеся составом регистрируемых модальностей. Набор [140] содержит фМРТ-записи пациентов, просматривавших один и тот же короткий аудиовизуальный фильм, вместе с аннотациями моментов появления и исчезновения отдельных слов, объектов и персонажей [141; 142]; на нем в главе 2 проверяется гипотеза о зависимости между видеорядом и фМРТ-откликом. Набор [11] включает записи активности мозга пациентов, наблюдавших визуальные стимулы восьми различных категорий, и выбран для главы 3 из-за наличия целевых масок активности мозга, полученных нейроучеными, а также разметки стимулирования, включающей перерывы для отдыха, необходимые для наблюдения изменений активности. Характеристики обоих

наборов приводятся в экспериментальных разделах соответствующих глав. Наибольшие требования к данным предъявляет мультимодальная постановка.

Постановка и решение задачи реконструкции изображений по мозговой активности невозможны без качественных наборов данных, в которых фМРТ и ЭЭГ регистрируются одновременно и под предъявление визуальных стимулов. За последние годы появилось несколько открытых датасетов, включающих совместную регистрацию этих модальностей. Однако большинство доступных наборов либо исключают визуальную стимуляцию, например, регистрируют активность в состоянии покоя или при аудиостимуляции [143; 144], либо содержат разнесенные во времени сессии фМРТ и ЭЭГ [140], либо ориентированы на верификацию технической совместимости методов регистрации, а не на исследование стимул-зависимой нейродинамики [145]. Из доступных на момент написания работы датасетов лишь два обеспечивают одновременную регистрацию при предъявлении визуальных стимулов: датасет Telesford и др. [146] и датасет Wakeman и др. [147]. Первый содержит записи от 22 пациентов при просмотре как синтетических стимулов — мерцающего шахматного поля и абстрактных сцен в парадигме Inscapes, — так и натуралистических — коротких видеороликов. Второй включает данные 16 пациентов при выполнении задачи распознавания статичных изображений лиц. В работе рассматривается датасет [146] в качестве основного, поскольку разнообразие стимулов — от контролируемых синтетических до динамических естественных видео — обеспечивает более широкое покрытие визуальных паттернов и способствует обучению обобщаемых моделей реконструкции. Именно на его основе формируются обучающие триплеты (фМРТ, ЭЭГ, изображение).

1.9. Постановка задачи декодирования

Декодирование внешнего воздействия по сигналам мозга рассматривается в работе как единая задача, к которой осуществляется постепенный переход: сначала анализируется временная динамика сигнала фМРТ, затем к ней добавляется пространственная структура, и наконец выполняется переход к мультимодальности — совместному использованию фМРТ–ЭЭГ. Ниже вводит-

ся общий формализм; каждая из трех отвечающих этим этапам постановок конкретизируется в начале соответствующей главы.

Пусть $\mathcal{X}_{(m)}$ — пространство наблюдений модальности m , где $m = 1, \dots, M$. Совместное пространство нейробиологических данных определяется как декартово произведение:

$$\mathcal{X} = \mathcal{X}_{(1)} \times \dots \times \mathcal{X}_{(M)}.$$

Стимул или его характеристика описываются пространством $\mathcal{Y}$. Задача мультимодального декодирования состоит в построении отображения:

$$\mathbf{g} : \mathcal{X} \rightarrow \mathcal{Y}.$$

В рамках общей постановки в работе решаются три задачи: оценка гемодинамического лага в главе 2, классификация временных рядов фМРТ в главе 3 и мультимодальное декодирование по одновременным записям фМРТ–ЭЭГ при $M = 2$ в главе 4.

Глава 2. Оценка гемодинамического лага по временной динамике фМРТ

В данной главе рассматривается первая постановка задачи декодирования, учитывающая только временную структуру сигнала: по предъявленному визуальному стимулу прогнозируется фМРТ-отклик, а гемодинамический лаг Δt оценивается по минимуму ошибки восстановления. Глава служит обоснованием для последующих методов. Она показывает, что лаг необходимо учитывать явно и что его влияние на качество проявляется лишь в области, отвечающей за обработку стимула. Результаты главы опубликованы в работе [40].

Полный код реализации, использованный для получения результатов главы, доступен в открытом репозитории:

<https://github.com/DorinDaniil/Forecasting-fMRI-Images>

2.1. Постановка задачи

BOLD-сигнал фМРТ возникает с гемодинамическим лагом Δt относительно момента предъявления визуального стимула [70; 73]; ЭЭГ-сигнал, напротив, отражает нейронный отклик практически без лага. Для анализа лага рассматривается обратная к декодированию задача: по предъявленному стимулу предсказать вызванный им фМРТ-отклик. Согласно гипотезе о гемодинамическом лаге, фМРТ-скан $\mathbf{F}(t) \in \mathcal{X}_f \subseteq \mathbb{R}^{X \times Y \times Z}$ в момент t порождается не текущим, а сдвинутым на Δt в прошлое стимулом $\mathbf{y}(t - \Delta t) \in \mathcal{Y}$. Формально требуется построить отображение:

$$\mathbf{q} : \mathcal{Y} \rightarrow \mathcal{X}_f, \quad \mathbf{F}(t) \approx \mathbf{q}[\mathbf{y}(t - \Delta t)], \quad (2.1)$$

сопоставляющее стимулу вызванный им фМРТ-отклик. Искомый лаг — значение гиперпараметра Δt , при котором (2.1) восстанавливает отклик с наименьшей ошибкой.

2.2. Линейная модель для оценки гемодинамического лага

Конкретизируем постановку из раздела 2.1 с учетом различия временных шкал модальностей. Пусть ν — частота кадров видеоряда, а μ — частота регистрации фМРТ, так что записи отвечают видеопоследовательность $[\mathbf{y}(1), \dots, \mathbf{y}(\nu t_{\text{rec}})]$ и последовательность сканов $[\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T})]$, $\mathcal{T} = \mu t_{\text{rec}}$, где t_{rec} — длительность записи. Поскольку $\nu > \mu$, каждому скану соответствует несколько кадров; индекс кадра, отвечающего ℓ -му скану, определяется как

$$k_\ell = \frac{\ell \cdot \nu}{\mu}.$$

С учетом гемодинамического лага скану $\mathbf{F}(\ell)$ сопоставляется кадр $\mathbf{y}(k_\ell - \nu \Delta t)$, предъявленный на Δt раньше. Отображение $\mathbf{q}$ из (2.1) реализуется повоксельной линейной регрессией: эмбединг сопоставленного кадра, полученный предобученным визуальным энкодером, обозначается $\mathbf{x}(t) \in \mathbb{R}^d$. В качестве энкодера используется ResNet152 [131] без последнего линейного слоя; выбор энкодера не принципиален, поскольку корреляционная структура исследуемых рядов сохраняется и для других энкодеров, например ViT [132]. Тем самым отображение $\mathbf{q}$ представляется суперпозицией

$$\mathbf{q} = \boldsymbol{\varphi} \circ \boldsymbol{\psi}, \quad \boldsymbol{\psi} : \mathcal{Y} \rightarrow \mathbb{R}^d, \quad \boldsymbol{\varphi} : \mathbb{R}^d \rightarrow \mathcal{X}_f,$$

где $\boldsymbol{\psi}$ — фиксированная векторизация кадра предобученным энкодером, а $\boldsymbol{\varphi}$ — обучаемое линейное отображение эмбединга в фМРТ-отклик. Схема предложенной модели приведена на рис. 2.1.

Сжатие фМРТ. Информативная доля вокселей мала, поэтому для ускорения сканы предварительно сжимаются по пространственным измерениям. Сжатие вдвое задается отображением

$$\chi : \mathbb{R}^{X \times Y \times Z} \rightarrow \mathbb{R}^{X/2 \times Y/2 \times Z/2},$$

а сжатие в 2^k раз — его k -кратным применением. Далее для краткости сохраняются обозначения размерностей $X \times Y \times Z$.

Марковское допущение. Последовательность сканов считается марковской: каждый скан зависит лишь от предыдущего и от текущего стимула.




Рисунок 2.1 — Схема модели прогнозирования снимков фМРТ по стимулу. На этапе предобработки из видеокadra предобученным энкодером извлекаются признаки, а фМРТ-сканы нормируются. На этапе прогнозирования многомерная линейная модель отображает эмбединг видеокadra в приращение между двумя последовательными сканами

Поэтому модель предсказывает не сам скан, а его приращение

$$\delta(t) = \mathbf{F}(t) - \mathbf{F}(t - 1) = [\delta_{xyz}(t)] \in \mathbb{R}^{X \times Y \times Z}, \quad t = 2, \dots, \mathcal{T},$$

с покомпонентными значениями $\delta_{xyz}(t)$. Полный скан восстанавливается последовательным суммированием приращений.

Повоксельная линейная регрессия. После сопоставления сканов и кадров с учетом лага Δt для каждого вокселя (x, y, z) образуется выборка пар

$$\mathcal{D}_{xyz} = \{(\mathbf{x}(t), \delta_{xyz}(t)) \mid t = 2, \dots, \mathcal{T}\}.$$

Кадр $\mathbf{y}(k_t - \nu \Delta t)$ определен лишь при $k_t \geq \nu \Delta t$, поэтому фактически в выборку входят сканы с $t \geq \lceil \mu \Delta t \rceil + 1$, и число обучающих пар, приближенно равное $\mu(t_{\text{rec}} - \Delta t)$, убывает с ростом лага; для краткости пределы суммирования далее записываются как $t = 2, \dots, \mathcal{T}$. Приращение моделируется линейно по эмбедингу стимула с вектором параметров $\mathbf{w}_{xyz} \in \mathbb{R}^d$:

$$\hat{\delta}_{xyz}(t) = \langle \mathbf{x}(t), \mathbf{w}_{xyz} \rangle.$$

Параметры находятся минимизацией квадратичной ошибки с L_2 -регуляризацией, коэффициент регуляризации обозначается λ :

$$\mathcal{L}_{xyz}(\mathbf{w}_{xyz}) = \sum_{t=2}^{\mathcal{T}} (\langle \mathbf{x}(t), \mathbf{w}_{xyz} \rangle - \delta_{xyz}(t))^2 + \lambda \|\mathbf{w}_{xyz}\|_2^2. \quad (2.2)$$

Задача (2.2) имеет замкнутое решение по методу наименьших квадратов. Введем матрицу объекты–признаки и вектор приращений одного вокселя:

$$\mathbf{X} = [\mathbf{x}(2), \dots, \mathbf{x}(\mathcal{T})]^\top \in \mathbb{R}^{(\mathcal{T}-1) \times d}, \quad \Delta_{xyz} = [\delta_{xyz}(2), \dots, \delta_{xyz}(\mathcal{T})]^\top \in \mathbb{R}^{\mathcal{T}-1}.$$

Тогда

$$\hat{\mathbf{w}}_{xyz} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbb{I})^{-1} \mathbf{X}^\top \Delta_{xyz}.$$

Авторегрессионное восстановление. Веса всех вокселей построчно объединяются в матрицу $\widehat{\mathbf{W}} = [\widehat{\mathbf{w}}_1, \dots, \widehat{\mathbf{w}}_{XYZ}]^\top \in \mathbb{R}^{XYZ \times d}$, и прогноз очередного скана получается авторегрессионно:

$$\text{vec}(\widehat{\mathbf{F}}(t)) = \text{vec}(\mathbf{F}(t-1)) + \widehat{\mathbf{W}} \mathbf{x}(t). \quad (2.3)$$

Последовательное применение (2.3), начиная с известного первого скана, восстанавливает всю последовательность фМРТ по стимулу и задает отображение $\mathbf{q}$. Лаг Δt входит в модель через сопоставление стимула скану; ее оптимальное значение выбирается по минимуму среднеквадратичной ошибки восстановления (англ. Mean Squared Error, MSE).

2.3. Вычислительный эксперимент

2.3.1. Данные и постановка эксперимента

Оценка лага Δt выполнена на наборе данных с одновременной регистрацией видеостимулов и фМРТ [140] с помощью модели $\mathbf{q}$ из раздела 2.2. Набор содержит записи 63 пациентов, из которых фМРТ-сканы доступны для 30: среди них 16 мужчин и 14 женщин в возрасте от 7 до 47 лет, средний возраст составляет 22 года. Все они просматривали один и тот же короткий

аудиовизуальный фильм. Пример данных из выборки приведен на рис. 2.2, характеристики выборки сведены в Таблицу 1.




Рисунок 2.2 — Визуализация данных используемого набора. Для примера выбраны три момента времени. Слева показаны видеокадры, справа — срезы фМРТ-сканов за соответствующий период для трех пациентов: 7, 13 и 47. Частота видеокадров выше, поэтому каждому фМРТ-скану соответствует несколько кадров

Таблица 1 — Характеристики используемого набора данных

Название	Обозначение	Значение
Длительность записи	t_{rec}	390 с
Частота видеокадров	ν	25 Гц
Частота фМРТ	μ	1,64 Гц
Размеры видеокадра	H, W, C	640, 480, 3
Размеры фМРТ-скана	X, Y, Z	40, 64, 64

Выборка делится на обучающую и тестовую в пропорции 70% к 30%. На этапе обучения по обучающей выборке вычисляется матрица оптимальных весов $\widehat{\mathbf{W}}$, которая затем используется для авторегрессионного прогноза сканов на тестовой выборке. Качество восстановления оценивается ошибкой MSE между истинными сканами тестовой выборки и их восстановлением по формуле (2.3), усредненной по всем вокселям; по форме эта ошибка совпадает с первым слагаемым функции потерь (2.2).

Для сокращения времени работы алгоритма сканы предварительно сжимаются слоем трехмерного максимального пулинга MaxPool3D; рассматриваются коэффициенты сжатия 1, 2, 4 и 8. Значения вокселей нормируются в отрезок $[0, 1]$ линейным масштабированием MinMaxScale: статистики вычисляются на обучающей выборке, после чего преобразование применяется к обучающей и тестовой выборкам. Характеристики вычислительной системы, на которой проводился эксперимент, приведены в Таблице 2.

Таблица 2 — Характеристики вычислительной системы

Элемент	Описание
Процессор (англ. Central Processing Unit, CPU)	Intel Core i7-7700 3,6 ГГц
Графический процессор (англ. Graphics Processing Unit, GPU)	NVIDIA GeForce GTX 1060 3 ГБ
Оперативная память (англ. Random Access Memory, RAM)	16 ГБ 2400 МГц
Твердотельный накопитель (англ. Solid-State Drive, SSD)	M.2
Операционная система	Windows 10

2.3.2. Пример прогноза

На рис. 2.3 показаны срезы истинного и восстановленного сканов из тестовой выборки, а также разность между ними. Для демонстрации работы алгоритма выбран 7-й пациент, $\Delta t = 5$ с, коэффициент сжатия 1, коэффициент регуляризации $\lambda = 1000$; рассматривается 20-й срез вдоль первой координаты 37-го скана последовательности. Поскольку значения вокселей нормированы в отрезок $[0, 1]$, ошибка порядка 10^{-3} свидетельствует о достаточно точном прогнозе.

2.3.3. Анализ гемодинамического лага

Модель обучается при различных значениях лага, и для каждого из них вычисляется MSE. Если ошибку считать по всему фМРТ-скану, выраженного минимума у зависимости нет, так как области, не связанные с обработкой




Рисунок 2.3 — Срезы фМРТ-сканов из тестовой выборки для 7-го пациента: истинный и восстановленный сканы и разность между ними. Ошибка порядка 10^{-3} свидетельствует о достаточно точном прогнозе

зрительной информации, вносят шум. Чтобы его устранить, ошибка пересчитывается на затылочной доле, которая отвечает за обработку визуальных стимулов [98]. Эта зрительная зона локализуется так: из нижней трети и правых двух третей объема скана отбираются 3% вокселей с наибольшим суммарным абсолютным изменением значений во времени. Выделенные таким образом воксели показаны красным на рис. 2.4. На этой области зависимость MSE от Δt имеет отчетливый минимум при $\Delta t \approx 5$ с, как показано на рис. 2.5. Это значение согласуется с известным медицинским диапазоном лага BOLD-сигнала [70], поэтому величина $\Delta t = 5$ с фиксируется на этапе прогнозирования. Зависимость ошибки от лага проявляется лишь после локализации зрительной зоны. Это наблюдение мотивирует построение масок активности в главе 3.




Рисунок 2.4 — Локализация наиболее активной зоны для 47-го пациента. Красным выделены 3% наиболее изменчивых во времени вокселей затылочной доли, которая отвечает за обработку визуальной информации, в том числе при просмотре видеоряда. Это подтверждает корректность локализации




Рисунок 2.5 — Зависимость MSE от величины гемодинамического лага Δt . Слева — расчет по всему фМРТ-скану, где выраженный минимум отсутствует из-за шума от областей, не связанных со зрением. Справа — расчет на локализованной затылочной доле, дающий отчетливый минимум при $\Delta t \approx 5$ с

2.3.4. Выбор параметра регуляризации

Исследуется оптимальное значение коэффициента L_2 -регуляризации в функции потерь (2.2). Для каждого коэффициента сжатия 1, 2, 4 и 8 вычисляется среднее значение MSE на тестовой выборке с усреднением по пациентам; соответствующие графики с границами стандартного отклонения приведены на рис. 2.6.

Графики показывают, что оптимальное значение коэффициента составляет $\lambda \approx 1000$, причем форма кривой сохраняется независимо от коэффициента сжатия. Вместе с тем увеличение сжатия приводит к росту MSE. Это объясняется главным образом различием в числе фоновых вокселей на сканах: на фоне метод дает высокое качество, поскольку значения фоновых вокселей постоянны во времени, а применение max pooling при сжатии увеличивает долю информативных вокселей.




Рисунок 2.6 — Зависимость MSE на тестовой выборке от параметра регуляризации λ (на графике обозначен α) при различных коэффициентах сжатия. Оптимальное значение составляет $\lambda \approx 1000$; увеличение коэффициента сжатия снижает качество из-за уменьшения числа фоновых вокселей

2.3.5. Влияние сжатия на время обучения

Сравнивается время обучения модели при использовании различных коэффициентов сжатия фМРТ-сканов. Для каждого значения коэффициента вычисляются среднее время обучения по всем пациентам и его стандартное отклонение. Результаты сведены в Таблицу 3: предварительное сжатие сканов существенно сокращает время работы метода, а эксперимент с подбором коэффициента регуляризации подтверждает, что сжатие не меняет характера исследуемых зависимостей.

Таблица 3 — Зависимость времени обучения модели от коэффициента сжатия

Коэффициент сжатия	Среднее время, с	Стандартное отклонение, с
1	36,3	6,1
2	6,7	0,5
4	1,6	0,1
8	1,4	0,3

2.3.6. Распределение весов модели

Чтобы оценить интерпретируемость вспомогательной модели, рассматривается распределение ее весов. Векторы $\hat{\mathbf{w}}_{xyz}$ усредняются по всем вокселям одного пациента, и для полученного вектора строится распределение его компонент. Результат для 4-го пациента приведен на рис. 2.7. Компоненты не сосредоточены вблизи какого-либо одного значения, то есть распределение не вырождено. Это согласуется с тем, что при просмотре видео человек обращает внимание на отдельные части кадра, такие как персонажи или иные значимые детали, поэтому обученная модель опирается на разнообразные признаки стимула.




Рисунок 2.7 — Распределение компонент усредненного по вокселям вектора весов вспомогательной модели для 4-го пациента. Веса не концентрируются вокруг одного значения, что указывает на невырожденное распределение и свидетельствует об обученности модели, опирающейся на разнообразные признаки

2.3.7. Гипотеза об инвариантности весов относительно пациентов

Проверялась гипотеза об инвариантности весов модели относительно пациента: матрица весов одного пациента использовалась для восстановления фМРТ-сканов другого. В качестве показателя использовалась MSE на тестовой выборке. Рассматривались 4-й и 7-й пациенты: матрица весов 4-го применялась для восстановления сканов 7-го. Результаты представлены в Таблице 4 — значения MSE практически совпадают.

Таблица 4 — Проверка гипотезы об инвариантности весов модели относительно пациентов

Матрица весов	Собственная	Смешанная	Разность
MSE	$6,3912 \cdot 10^{-5}$	$6,3911 \cdot 10^{-5}$	$1,37 \cdot 10^{-9}$

Аналогичный эксперимент проведен для каждой пары пациентов; результаты представлены на рис. 2.8. Тепловая карта построена по следующей процедуре: для данного пациента, которому отвечает строка матрицы, сначала вычисляется «собственная» MSE; затем берется другой пациент, которому отвечает столбец матрицы, и его матрица весов $\widehat{\mathbf{W}}$ используется для прогноза сканов первого, что дает «смешанную» MSE. В ячейке отображается процентное отклонение между «собственной» и «смешанной» ошибками, то есть средняя абсолютная процентная ошибка (англ. Mean Absolute Percentage Error, MAPE) между пациентами.

Положительные значения на тепловой карте означают, что «смешанная» ошибка больше «собственной», отрицательные — что меньше. В идеале модель должна давать только положительные отклонения, однако на рис. 2.8 присутствуют и отрицательные значения с отклонениями порядка 1%. Это объясняется простотой модели, которая обеспечивает ей высокую обобщающую способность. Несмотря на эти незначительные отрицательные отклонения, данные не противоречат гипотезе об инвариантности весов модели относительно пациентов.





Рисунок 2.8 — Процентное изменение MSE при прогнозе со смешанной матрицей весов. Каждая строка и каждый столбец соответствуют пациенту; «смешанная» ошибка получена прогнозом по весам другого пациента. Положительные значения означают, что «смешанная» MSE больше «собственной»

2.3.8. Корректность метода на неинформативных данных


Исследуется роль информативных признаков изображений в предложенном методе прогнозирования: исходные эмбединги, полученные энкодером ResNet152, заменяются неинформативными — матрица $\mathbf{X}$ заполняется единицами. Результаты прогнозирования для исходной и неинформативной матриц объекты–признаки сравниваются следующим образом: метод применяется авторегрессионно для восстановления последнего скана тестовой последовательности, для чего все предсказанные приращения последовательно суммируются с первым сканом тестовой выборки. Выбран 35-й пациент.

На рис. 2.9 показаны срезы последнего истинного и восстановленного сканов тестовой выборки и разность между ними; результаты на неинформативных данных приведены на рис. 2.10. Разность между истинным и восстановленным сканами при работе с неинформативными данными значительно выше, что подтверждает наличие корреляции между показаниями датчиков и изображениями видеоряда. Численные результаты сведены в Таблицу 5.



Истинный Восстановленный Разность

Рисунок 2.9 — Срезы последнего скана тестовой последовательности 35-го пациента: истинный скан, авторегрессионное восстановление по исходным видеокдрам и разность между ними



Истинный Восстановленный Разность

Рисунок 2.10 — Срезы последнего скана тестовой последовательности при неинформативных данных. Значение MSE для неинформативной выборки больше, что указывает на наличие корреляции в истинных данных

Таблица 5 — Качество работы метода на неинформативных данных

Данные	Исходные	Неинформативные	Разность
MSE	$3,67 \cdot 10^{-4}$	$1,39 \cdot 10^{-3}$	$1,02 \cdot 10^{-3}$

2.4. Обсуждение результатов

Полученные результаты дают представление о связи между видеорядом и фМРТ-сканами и демонстрируют потенциал линейных моделей в прогнозировании активности мозга по визуальным стимулам. Проведенный анализ показывает, что линейная авторегрессионная модель эффективно улавливает корреляцию между видеокдрами и фМРТ-сканами в предположении мар-

ковости последовательности сканов. Такой подход позволяет предсказывать следующий скан по предыдущему скану и соответствующему видеокадру и тем самым восстанавливать всю последовательность магнитно-резонансных изображений по просмотренному видео.

Для последующих глав существенны два вывода. Во-первых, качество прогноза отклика зависит от гемодинамического лага, поэтому лаг необходимо учитывать при сопоставлении сигнала со стимулом. Это сделано при построении масок активности в главе 3 и при синхронизации модальностей в главе 4. Во-вторых, зависимость от лага проявляется лишь в зрительной зоне, а не по всему объему скана. Поэтому информативные воксели необходимо выделять до построения признаков, что и делают маски активности главы 3.

Результаты тесно связаны с более широкой областью нейровизуализации и интерфейсов мозг–компьютер. В то время как предшествующие исследования часто опираются на сложные модели для задач предсказания по видео, предложенный метод предоставляет простую и эффективную альтернативу для анализа корреляции между визуальными стимулами и активностью мозга. Упрощенный подход особенно полезен в практических приложениях, где детальный анализ не требуется.

Вместе с тем исследование имеет ряд ограничений. Во-первых, использованный набор данных, хотя и репрезентативен, относительно мал по числу пациентов; проверка модели на более крупных и разнообразных наборах данных необходима для подтверждения обобщаемости. Во-вторых, линейная авторегрессионная модель, будучи вычислительно эффективной, может не улавливать всю сложность связи между видеостимулами и фМРТ-сканами: более сложные модели потенциально способны повысить точность прогноза ценой роста вычислительной сложности. В-третьих, пространственное и временное разрешение фМРТ ограничено, и на качество модели влияет присущий гемодинамическому отклику лаг; более точный учет этого лага составляет направление дальнейшей работы.

Несмотря на указанные ограничения, полученные результаты уточняют представление о реакции человеческого мозга на внешние стимулы и служат основой для последующих исследований в этой области.

Глава 3. Пространственно-временная классификация временных рядов фМРТ в условиях ограниченной выборки

В данной главе рассматривается вторая постановка задачи декодирования, дополняющая временное описание пространственным: временные ряды фМРТ одного пациента классифицируются по категориям стимулов на основе масок активности классов и проекции ковариационных матриц на касательное пространство риманова многообразия. Размерность признакового описания задается числом активных вокселей и не зависит от объема выборки. Результаты главы опубликованы в работе [41].

Полный код реализации, использованный для получения результатов главы, доступен в открытом репозитории:

<https://github.com/DorinDaniil/Spatial-and-Temporal-Characteristics>

3.1. Постановка задачи

Временной ряд фМРТ — это последовательность из $\mathcal{T}$ сканов:

$$\mathbf{S} = [\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T})] \in \mathcal{X}_s,$$

где $\mathbf{F}(t) \in \mathcal{X}_f$ — скан в момент t . Задана выборка из N рядов одного пациента, каждому из которых сопоставлена метка категории стимула:

$$\mathfrak{D} = \{(\mathbf{S}_i, y_i) \mid i = 1, \dots, N\}, \quad y_i \in \{1, \dots, L\}, \quad (3.1)$$

где L — число категорий стимулов. Требуется построить отображение:

$$\mathbf{h} : \mathcal{X}_s \rightarrow \{1, \dots, L\},$$

учитывающее пространственно-временные характеристики ряда.

3.2. Метод классификации

Предлагается методология декодирования с учетом пространственно-временных характеристик (англ. Decoding with Spatio-Temporal characteristics, DeSPoT) — комплексный подход для выделения активных областей мозга путем взвешивания вокселей с использованием кросс-корреляции, классификации временных рядов на основе полученных масок активности, а также сегментации временных рядов фМРТ для аугментации. Методология включает алгоритм декодирования активности мозга (англ. Brain Activity Decoder, BAD), модель классификации, использующую этот алгоритм, и метод аугментации. Методология специально разработана для решения задачи декодирования данных одного пациента, где объем выборки ограничен. Общая схема методологии приведена на рис. 3.1.




Рисунок 3.1 — Обзор предложенной методологии. Классифицируются временные ряды фМРТ с учетом индивидуальных структур мозга, не требуя больших объемов данных. Ключевые компоненты включают выделение областей интереса (англ. Region of Interest, ROI) и преобразование пространства признаков с использованием римановой геометрии, что составляет основу извлечения пространственно-временных характеристик. Результатом классификации является распределение вероятностей по категориям стимулов. Кроме того, используются методы аугментации данных для улучшения обучения на данных отдельных пациентов

Модель классификации работает в два этапа. На первом этапе для каждой категории стимулов $y = 1, \dots, L$ по обучающей выборке *извлекается маска активности* $\mathcal{M}^y$: алгоритм выделяет воксели, сигнал которых сильнее всего

коррелирует с бинарным рядом стимулов этой категории при гемодинамическом лаге Δt . На втором этапе выполняется *классификация ряда*: объект описывается L раз, по одному разу с точки зрения каждого класса, и каждое описание получается проекцией ковариационной матрицы отобранных вокселей на касательное пространство риманова многообразия (англ. Tangent Space Mapping, TSM) [37]. Схема второго этапа для одного объекта приведена на рис. 3.2.




Рисунок 3.2 — Схема модели классификации для одного объекта $\mathbf{S}$ из $\mathcal{T}$ сканов. Строка y отвечает классу y : маска активности $\mathcal{M}^y$, построенная по кросс-корреляции сигнала со стимулом при лаге Δt , отбирает ряды активных вокселей $\mathbf{Y}_y$; их ковариационная матрица $\mathbf{R}_y$ проецируется логарифмическим отображением на касательное пространство в точке риманова среднего $\bar{\mathbf{R}}_y$, что дает вектор $\mathbf{p}_y$ соответствия объекта классу y . Векторы всех классов конкатенируются в признак $\mathbf{p} \in \mathbb{R}^d$, по которому классификатор η предсказывает класс $\hat{y}$

Объект $\mathbf{S}$ есть последовательность из $\mathcal{T}$ сканов $\mathbf{F}(t)$. Строка схемы с номером y отвечает классу y и читается слева направо. Отображение $\mathbf{m}_y$ применяет маску $\mathcal{M}^y$ к каждому скану и оставляет временные ряды h_y активных вокселей, образуя матрицу $\mathbf{Y}_y \in \mathbb{R}^{h_y \times \mathcal{T}}$. По этой матрице вычисляется ковариационная матрица $\mathbf{R}_y$, то есть точка риманова многообразия симметричных положительно определенных матриц. Логарифмическое отображение $\text{Log } \bar{\mathbf{R}}_y$ проецирует ее на касательное пространство в точке риманова среднего $\bar{\mathbf{R}}_y$ ковариаций обучающих объектов, вычисленных с той же маской; координаты проекции в ортонормированном базисе касательного пространства образуют

вектор $\mathbf{p}_y$. Поскольку маска $\mathcal{M}^y$ выделяет область, реагирующую на стимулы класса y , ковариационная структура этой области различна у объектов класса y и у остальных объектов, и вектор $\mathbf{p}_y$ измеряет соответствие объекта классу y . Векторы всех классов конкатенируются в признак $\mathbf{p} \in \mathbb{R}^d$, по которому классификатор $\boldsymbol{\eta}$ предсказывает метку $\hat{y}$. Размерность признака определяется числами активных вокселей h_y и не зависит от объема выборки, что существенно при ограниченной выборке одного пациента.

3.2.1. Извлечение масок активности мозга

Активные области, или области интереса (англ. Region of Interest, ROI), выделяются по корреляции сигнала вокселя со стимулом. Для ускорения каждый скан ряда $\mathbf{S}$ предварительно сжимается 3D average pooling с ядром k_s , после чего сигнал вокселя $F_{xyz}(t)$ и бинарный ряд стимуляции $\mathbf{u} = [u(1), \dots, u(\mathcal{T})]$, $u(t) \in \{0,1\}$, приводятся к нулевому среднему и единичной дисперсии, то есть подвергаются Z-нормализации. Вычисляется их кросс-корреляция при гемодинамическом лаге Δt :

$$\rho_{xyz} = \frac{1}{\mathcal{T}-1} \sum_t \dot{u}(t) \dot{F}_{xyz}(t + \Delta t). \quad (3.2)$$

Бинарная маска активности $\mathcal{M} \in \{0,1\}^{X/k_s \times Y/k_s \times Z/k_s}$ задается единицами в h вокселях с наибольшим значением ρ_{xyz} .

Формализуем процедуру выделения маски. В основе алгоритма лежат два предположения.

Предположение 3.2.1. *Каждый пациент имеет индивидуальный постоянный гемодинамический лаг отклика Δt , который учитывает время, необходимое для изменения уровня кислорода в крови в ответ на нейронную активность.*

Предположение 3.2.2. *Если область мозга реагирует на стимул, функция кросс-корреляции между вокселями в этой области и временным рядом стимулов достигает пика при гемодинамическом лаге Δt . Этот пик указывает на сильную корреляцию между нейронной активностью и стимулом.*

Предположение 3.2.1 опирается на результат главы 2: гипотеза о наличии гемодинамического лага между предъявлением стимула и BOLD-откликом не была отвергнута — ошибка прогноза фМРТ-отклика существенно зависит от лага и на зрительной зоне имеет выраженный минимум, как показано в разделе 2.3.3 на рис. 2.5. Этот минимум наблюдается лишь в зрительной зоне, что и мотивирует отбор вокселей по корреляции со стимулом. В настоящую главу переносится сам факт этого влияния, а не конкретное значение лага: Δt выступает индивидуальным для пациента параметром Алгоритма 1, и кросс-корреляция (3.2) вычисляется со сдвигом именно на этот лаг.

Алгоритм 1 принимает временной ряд фМРТ и бинарный ряд стимулов и имеет три настраиваемых параметра: размер ядра k_s , гемодинамический лаг Δt и количество активных областей h . Частота сканирования μ используется для перевода лага в число отсчетов, что обеспечивает точный учет временной динамики гемодинамического отклика.

Кросс-корреляция (3.2) есть значение функции $\rho_{xyz}(p)$ из Алгоритма 1 в точке $p = p_{\Delta t}$. Для проверки статистической значимости областей, полученных Алгоритмом 1, проверяется значимость корреляции между временным рядом стимулов и временным рядом каждого вокселя. Обозначим $\mathbf{v}$ — временной ряд вокселя и $\tau_{\mathbf{v}\mathbf{u}}$ — коэффициент ранговой корреляции Кендалла. Применяется следующий критерий:

Выборки: $\mathbf{v} = [v(1), \dots, v(\mathcal{T})]$
 $\mathbf{u} = [u(1), \dots, u(\mathcal{T})]$
 выборки связаны

Нулевая гипотеза: $H_0: \tau_{\mathbf{v}\mathbf{u}} = 0$

Альтернативная гипотеза: $H_1: \tau_{\mathbf{v}\mathbf{u}} > 0$

Статистика критерия: $\hat{\tau}_{\mathbf{v}\mathbf{u}}$

Распределение при нулевой гипотезе: табличное

Критерий применяется к каждому вокселю, что образует задачу множественной проверки гипотез. Для контроля групповой вероятности ошибки первого рода (англ. Family-Wise Error Rate, FWER) на заданном уровне значимости используется поправка Холма. Таким образом отсеиваются ложные срабатывания и выделяются воксели со статистически значимой корреляцией.

Алгоритм 1. Декодирование активности мозга (англ. Brain Activity Decoder, BAD)

Вход : временной ряд фМРТ $\mathbf{S}$; бинарный ряд стимулов $\mathbf{u}$; параметры $k_s, \Delta t, h$

Выход: маска активности $\mathcal{M}$ и ее версия $\mathcal{M}^\uparrow$ в исходном разрешении

- 1 **Сжатие**: 3D average pooling с ядром k_s : $\mathbf{S} \rightarrow \mathbf{V}$, $\mathbf{V} \in \mathbb{R}^{\mathcal{T} \times X/k_s \times Y/k_s \times Z/k_s}$;
- 2 **Z-нормализация**: нормализация временных рядов вокселей и ряда стимулов: $\mathbf{V} \rightarrow \mathring{\mathbf{V}}, \mathbf{u} \rightarrow \mathring{\mathbf{u}}$;
- 3 **Кросс-корреляция**: для каждого вокселя (x, y, z) вычисляется

$$\rho_{xyz}(p) = \frac{1}{\mathcal{T} - 1} \sum_{t=1}^{\mathcal{T}-p} \mathring{u}(t) \mathring{V}_{xyz}(t+p), \quad p = 0, \dots, \mathcal{T} - 1$$

- 4 **Определение маски**: вычисляется $p_{\Delta t} = \lfloor \mu \Delta t \rfloor$; создается бинарная маска $\mathcal{M} \in \{0,1\}^{X/k_s \times Y/k_s \times Z/k_s}$ с единицами в позициях h наибольших значений $\rho_{xyz}(p_{\Delta t})$;
- 5 **Увеличение разрешения**: для получения $\mathcal{M}^\uparrow \in \{0,1\}^{X \times Y \times Z}$ каждому элементу присваивается значение ближайшего элемента $\mathcal{M}$:

$$\mathcal{M}^\uparrow(x, y, z) = \mathcal{M} \left(\left\lfloor \frac{x}{k_s} \right\rfloor, \left\lfloor \frac{y}{k_s} \right\rfloor, \left\lfloor \frac{z}{k_s} \right\rfloor \right)$$

return $\mathcal{M}, \mathcal{M}^\uparrow$

Маска строится отдельно для каждой категории $y = 1, \dots, L$. Применение Алгоритма 1 к отдельным объектам класса не гарантирует, что полученная маска соответствует области мозга, ответственной за стимуляцию класса y , из-за ограничений процедуры фМРТ, описанных в главе 1. Поэтому для повышения статистической значимости ряды и стимулы объектов класса y объединяются по времени:

$$\begin{aligned} \tilde{\mathbf{S}}^y &= \mathbf{S}_1 \oplus \mathbf{S}_2 \oplus \dots \oplus \mathbf{S}_{N_y}, & \tilde{\mathbf{S}}^y &\in \mathbb{R}^{\mathcal{T} N_y \times X \times Y \times Z}, \\ \tilde{\mathbf{u}}^y &= \mathbf{u}_1 \oplus \mathbf{u}_2 \oplus \dots \oplus \mathbf{u}_{N_y}, & \tilde{\mathbf{u}}^y &\in \{0, 1\}^{\mathcal{T} N_y}, \end{aligned}$$

где N_y — число объектов класса y , а $\oplus$ обозначает конкатенацию по временной оси. К конкатенированным данным применяется Алгоритм 1 с параметрами $h_y, k_s, \Delta t$; шаг увеличения разрешения опускается, поскольку применение average pooling уменьшает влияние аномальных и зашумленных вокселей. Результат —

маска $\mathcal{M}^y \in \{0,1\}^{X/k_s \times Y/k_s \times Z/k_s}$. Усреднение по объектам класса повышает статистическую значимость маски и ее устойчивость к шуму отдельных записей.

Формально определим результат применения маски к временному ряду.

Определение 3.2.3. Результат применения маски активности $\mathcal{M}$ к ряду $\mathbf{S} = [\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T})]$ определяется как матрица

$$\mathbf{Y} = \mathcal{M} \odot \mathbf{S} \in \mathbb{R}^{h \times \mathcal{T}},$$

где $\odot$ обозначает произведение Адамара, а столбец t матрицы $\mathbf{Y}$ состоит из значений скана $\mathbf{F}(t)$, соответствующих ненулевым элементам маски, h — число таких элементов.

3.2.2. Классификация временных рядов

Задан набор данных $\mathfrak{D}$, см. (3.1), и маски активности $\mathcal{M}^y$, $y = 1, \dots, L$. Искомое отображение $\mathbf{h} : \mathcal{X}_s \rightarrow \{1, \dots, L\}$ представляется суперпозицией

$$\mathbf{h} = \boldsymbol{\eta} \circ \boldsymbol{\psi} \circ \mathcal{A}, \quad (3.3)$$

где $\mathcal{A}$ — 3D average pooling с ядром k_s , $\boldsymbol{\psi}$ — кодировщик пространственно-временных характеристик, $\boldsymbol{\eta} : \mathbb{R}^d \rightarrow \{1, \dots, L\}$ — классификатор.

Кодировщик является конкатенацией отображений для каждой категории стимула:

$$\boldsymbol{\psi} = \boldsymbol{\psi}_1 \oplus \dots \oplus \boldsymbol{\psi}_L, \quad \boldsymbol{\psi}_y = \boldsymbol{\pi}_y \circ \mathbf{m}_y, \quad d = \sum_{y=1}^L d_y, \quad (3.4)$$

где $\mathbf{m}_y$ применяет маску $\mathcal{M}^y$ в смысле Определения 3.2.3 и отбирает h_y активных вокселей, формируя матрицу из $\mathbb{R}^{h_y \times \mathcal{T}}$, а $\boldsymbol{\pi}_y$ проецирует ее на касательное пространство риманова многообразия с последующей векторизацией. Размерность определяется в разделе 3.2.3:

$$d_y = \frac{h_y(h_y + 1)}{2}.$$

Основным компонентом модели является кодировщик $\boldsymbol{\psi}$, который транслирует временные ряды в евклидово пространство, проецируя их на касательное пространство риманова многообразия, которое само по себе является евклидовым.

Это преобразование упрощает последующую задачу классификации, эффективно извлекая пространственно-временные характеристики, демонстрирующие степень соответствия между объектом и маской активности конкретного класса. В результате выбор классификатора становится простым, и в данной работе в качестве $\boldsymbol{\eta}$ рассматриваются логистическая регрессия и двухслойный перцептрон.

3.2.3. Проекция на касательное пространство риманова многообразия

Для упрощения изложения и без потери общности индекс класса y опускается во всех обозначениях. Отображение $\boldsymbol{\pi} : \mathbb{R}^{h \times \mathcal{T}} \rightarrow \mathbb{R}^d$ называется отображением на касательное пространство (англ. Tangent Space Mapping, TSM) [37]. Оно преобразует пространство объектов в терминах римановой геометрии [37; 99]: выборка ковариационных матриц объектов проецируется с риманова многообразия, которое не является линейным пространством, на касательную плоскость, которая является евклидовым пространством. Первым шагом метода является формирование пространства центрированных признаков. Для i -го объекта матрица активных вокселей $\mathbf{Y}_i = \mathcal{M} \odot \mathbf{S}_i$ из Определения 3.2.3 центрируется по времени:

$$\mathbf{Y}_i = \begin{bmatrix} y_{11}^i & y_{12}^i & \cdots & y_{1\mathcal{T}}^i \\ y_{21}^i & y_{22}^i & \cdots & y_{2\mathcal{T}}^i \\ \vdots & \vdots & \ddots & \vdots \\ y_{h1}^i & y_{h2}^i & \cdots & y_{h\mathcal{T}}^i \end{bmatrix} = \begin{bmatrix} \mathbf{y}_1^i \\ \mathbf{y}_2^i \\ \vdots \\ \mathbf{y}_h^i \end{bmatrix} \in \mathbb{R}^{h \times \mathcal{T}}, \quad i = 1, \dots, N,$$

где $\mathbf{y}_k^i$, $k = 1, \dots, h$, — центрированные временные ряды активных вокселей. Затем вычисляется ковариационная матрица многомерного временного ряда $\mathbf{Y}_i$:

$$\mathbf{R}_i = \frac{1}{\mathcal{T} - 1} \mathbf{Y}_i \mathbf{Y}_i^\top \in \mathbb{S}_+^h, \quad i = 1, \dots, N, \quad (3.5)$$

где $\mathbb{S}_+^h$ — пространство симметричных положительно определенных (англ. Symmetric Positive Definite, SPD) матриц размера $h \times h$. Известно, что это пространство образует риманово многообразие $\mathcal{R}$ [99].

В каждой точке риманова многообразия существует касательная плоскость с определенным на ней скалярным произведением. Общая касательная

плоскость для проецирования всех ковариационных матриц выборки формируется в точке геометрического среднего по римановой метрике известных ковариационных матриц. Геометрическое среднее SPD-матриц задается как

$$\bar{\mathbf{R}} = \mathfrak{G}(\mathbf{R}_1, \dots, \mathbf{R}_N) = \arg \min_{\mathbf{R} \in \mathbb{S}_+^h} \sum_{i=1}^N \delta_{\mathcal{R}}^2(\mathbf{R}, \mathbf{R}_i), \quad (3.6)$$

где риманова метрика, или геодезическое расстояние, от $\mathbf{R}_1$ до $\mathbf{R}_2$ равна

$$\delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2) = \|\log(\mathbf{R}_1^{-1}\mathbf{R}_2)\|_F = \left(\sum_{l=1}^h \log^2 \lambda_l \right)^{1/2}, \quad (3.7)$$

а λ_l — собственные значения матрицы $\mathbf{R}_1^{-1}\mathbf{R}_2$. Существование и единственность среднего (3.6) обсуждаются в разделе 3.3.

Для каждой ковариационной матрицы $\mathbf{R}_i$ существует ее проекция $\mathbf{P}_i$ на касательное пространство $T_{\bar{\mathbf{R}}}$ в точке $\bar{\mathbf{R}}$. Проекция задается логарифмическим отображением

$$\mathbf{P}_i = \text{Log}_{\bar{\mathbf{R}}}(\mathbf{R}_i) = \bar{\mathbf{R}}^{1/2} \log(\bar{\mathbf{R}}^{-1/2}\mathbf{R}_i\bar{\mathbf{R}}^{-1/2})\bar{\mathbf{R}}^{1/2}, \quad \mathbf{P}_i \in \mathbb{R}^{h \times h},$$

а обратное отображение с касательного пространства на многообразие — экспоненциальным:

$$\text{Exp}_{\bar{\mathbf{R}}}(\mathbf{P}_i) = \mathbf{R}_i = \bar{\mathbf{R}}^{1/2} \exp(\bar{\mathbf{R}}^{-1/2}\mathbf{P}_i\bar{\mathbf{R}}^{-1/2})\bar{\mathbf{R}}^{1/2}.$$

Эти операции вычисляются через спектральное разложение матриц. Для матрицы $\mathbf{Q} = \mathbf{U}\mathbf{D}\mathbf{U}^{-1}$, где $\mathbf{D}$ — диагональная матрица собственных значений, а $\mathbf{U}$ — матрица собственных векторов,

$$\mathbf{Q}^{\pm 1/2} = \mathbf{U}\mathbf{D}^{\pm 1/2}\mathbf{U}^{-1}, \quad \log(\mathbf{Q}) = \mathbf{U} \log(\mathbf{D})\mathbf{U}^{-1}, \quad \exp(\mathbf{Q}) = \mathbf{U} \exp(\mathbf{D})\mathbf{U}^{-1}. \quad (3.8)$$

После проекции каждой ковариационной матрицы $\mathbf{R}_i$ с использованием $\text{Log}_{\bar{\mathbf{R}}}(\cdot)$ получаются симметричные матрицы $\mathbf{P}_i \in \mathbb{R}^{h \times h}$. Последним шагом метода является векторизация. Длина касательного вектора в точке $\bar{\mathbf{R}}$ измеряется не нормой Фробениуса самой матрицы $\mathbf{P}_i$, а нормой ее отбеленной формы

$$\mathbf{S}_i = \bar{\mathbf{R}}^{-1/2}\mathbf{P}_i\bar{\mathbf{R}}^{-1/2} = \log(\bar{\mathbf{R}}^{-1/2}\mathbf{R}_i\bar{\mathbf{R}}^{-1/2}), \quad (3.9)$$

см. раздел 3.3. Поэтому векторизуется матрица $\mathbf{S}_i$: элементы ее верхнего треугольника последовательно записываются в вектор, причем диагональные

элементы берутся с коэффициентом 1, а внедиагональные — с коэффициентом $\sqrt{2}$. В результате получаются эмбединги

$$\mathbf{p}_i = \text{vec}_{\sqrt{2}}(\mathbf{S}_i) = \begin{bmatrix} S_{11} & \sqrt{2} S_{12} & \dots & \sqrt{2} S_{1h} & S_{22} & \sqrt{2} S_{23} & \dots & S_{hh} \end{bmatrix}^T \in \mathbb{R}^d, \quad (3.10)$$

размерности $d = h(h+1)/2$. Коэффициент $\sqrt{2}$ согласует евклидову норму вектора с нормой Фробениуса матрицы: каждый внедиагональный элемент симметричной матрицы входит в $\|\mathbf{S}_i\|_F^2 = \sum_k S_{kk}^2 + 2 \sum_{k<l} S_{kl}^2$ дважды, а в верхний треугольник — один раз, и множитель $\sqrt{2}$ восполняет недостающую двойку, так что $\|\mathbf{p}_i\|_2 = \|\mathbf{S}_i\|_F$. Без этого коэффициента евклидовы расстояния между эмбедингами занижали бы вклад внедиагональных элементов, а L_2 -регуляризация классификатора штрафovala бы диагональные и внедиагональные направления по-разному. Тем самым $\mathbf{p}_i$ — координаты касательного вектора $\mathbf{P}_i$ в ортонормированном базисе касательного пространства; их метрические свойства доказываются в разделе 3.3. Процесс проекции ковариационных матриц на касательное пространство, а затем обратно на многообразие проиллюстрирован на рис. 3.3.




Рисунок 3.3 — Проекция на касательное пространство. Ковариационная матрица $\mathbf{R}_j$ проецируется на касательное пространство $T_{\bar{\mathbf{R}}}$ в точке риманова среднего $\bar{\mathbf{R}}$ логарифмическим отображением $\text{Log}_{\bar{\mathbf{R}}}(\mathbf{R}_j)$; проекция $\mathbf{P}_j$ возвращается на многообразие $\mathcal{R}$ экспоненциальным отображением $\text{Exp}_{\bar{\mathbf{R}}}(\mathbf{P}_j)$. Длина $\|\mathbf{P}_j\|_{\bar{\mathbf{R}}}$ касательного вектора в аффинно-инвариантной метрике равна геодезическому расстоянию $\delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_j)$

3.2.4. Сегментация временных рядов для аугментации

Записи фМРТ обычно содержат одно протяженное измерение для каждого пациента, тогда как для обучения модели (3.3) требуется выборка размеченных рядов фиксированной длины. Для формирования такой выборки предлагается метод сегментации временного ряда, выделяющий сегменты с преобладающей категорией стимулов.

Определение 3.2.4. Фрагмент временного ряда $\mathbf{S}_{\text{rec}} = [\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T}_{\text{rec}})]$ — любая его подпоследовательность

$$[\mathbf{F}(t_1), \dots, \mathbf{F}(t_k)], \quad 1 \leq t_1 < \dots < t_k \leq \mathcal{T}_{\text{rec}}.$$

Определение 3.2.5. Сегмент временного ряда $\mathbf{S}_{\text{rec}}$ — его непрерывный фрагмент

$$[\mathbf{F}(t)]_{t=t_0}^{t_1}, \quad 1 \leq t_0 < t_1 \leq \mathcal{T}_{\text{rec}}.$$

Определение 3.2.6. Сегментация временного ряда — отображение $\mathcal{G}$, которое ставит в соответствие ряду $\mathbf{S}_{\text{rec}}$ множество его сегментов.

Пусть задана полная запись $\mathbf{S}_{\text{rec}} = [\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T}_{\text{rec}})]$ длиной $\mathcal{T}_{\text{rec}}$ и категориальный ряд стимулов

$$\mathbf{u}_{\text{rec}} = [u_{\text{rec}}(1), \dots, u_{\text{rec}}(\mathcal{T}_{\text{rec}})], \quad u_{\text{rec}}(t) \in \{0, 1, \dots, L\},$$

где класс 0 обозначает периоды отдыха пациента. Цель — сегментировать запись на интервалы фиксированной длины $\mathcal{T}$ так, чтобы каждый сегмент преимущественно содержал одну категорию стимулов.

Предположение 3.2.7. Пациент имел достаточно времени для отдыха между предъявлением стимулов из разных категорий: существует $\mathcal{T} > 0$ такое, что для любого сегмента длины $\mathcal{T}$ суммарная длина моментов стимуляции в нем меньше $\mathcal{T}$.

Фиксируем $\mathcal{T}$ в соответствии с Предположением 3.2.7. Для каждой категории $y \in \{1, \dots, L\}$ на первом шаге находятся начальные и конечные индексы интервалов стимуляции класса y , упорядоченные по возрастанию:

$$\begin{aligned} \{b_1, \dots, b_{N_y}\} &= \{t \mid u_{\text{rec}}(t) = y, u_{\text{rec}}(t-1) = 0\}, \\ \{e_1, \dots, e_{N_y}\} &= \{t \mid u_{\text{rec}}(t) = y, u_{\text{rec}}(t+1) = 0\}, \end{aligned}$$

где N_y — число интервалов категории y . На втором шаге каждый интервал $[b_j, e_j]$ длины $\mathcal{T}_j = e_j - b_j + 1$ дополняется периодами отдыха слева и справа до сегмента длины $\mathcal{T}$:

$$\mathbf{S}_j = [\mathbf{F}(b_j - r_1), \dots, \mathbf{F}(e_j + r_2)], \quad r_1 = \lfloor (\mathcal{T} - \mathcal{T}_j)/2 \rfloor, \quad r_2 = \lceil (\mathcal{T} - \mathcal{T}_j)/2 \rceil,$$

где $j = 1, \dots, N_y$, а $\lfloor \cdot \rfloor$ и $\lceil \cdot \rceil$ обозначают округление вниз и вверх. Аналогично сегментируется ряд стимулов; бинарный ряд стимуляции $\mathbf{u}$ объекта класса y задается индикатором $u(t) = \mathbf{1}\{u_{\text{rec}}(t) = y\}$. Объединяя все категории, получаем выборку из $N = \sum_{y=1}^L N_y$ сегментов длины $\mathcal{T}$ с метками классов.

3.3. Теоретические свойства проекции на касательное пространство

Кодировщик Ψ из (3.4) заменяет ковариационную матрицу объекта ее проекцией на касательное пространство в точке риманова среднего, после чего работает линейный классификатор. В настоящем разделе доказываются три свойства этой конструкции. Во-первых, признаки не зависят от единиц измерения сигнала и от невырожденного смешивания отобранных вокселей. Во-вторых, евклидовы расстояния между признаками отличаются от геодезических расстояний между ковариациями не более чем в контролируемое число раз, зависящее от наибольшего спектрального разброса касательных векторов, а потому и от геодезического радиуса облака объектов; константа этой оценки неулучшаема. В-третьих, ошибка оценки ковариации по $\mathcal{T}$ сканам не зависит от истинной ковариации и убывает как $h/\sqrt{\mathcal{T}}$, что задает ограничение на число отбираемых вокселей h .

3.3.1. Риманова структура и координаты признаков

Множество $\mathbb{S}_+^h$ снабжается аффинно-инвариантной римановой метрикой [148]: касательное пространство $T_{\mathbf{R}}$ в точке $\mathbf{R} \in \mathbb{S}_+^h$ есть пространство симметричных матриц $\text{Sym}(h)$, а скалярное произведение касательных векто-

ров $\mathbf{X}, \mathbf{Z} \in \text{Sym}(h)$ задается формулой

$$\langle \mathbf{X}, \mathbf{Z} \rangle_{\mathbf{R}} = \text{tr} (\mathbf{R}^{-1} \mathbf{X} \mathbf{R}^{-1} \mathbf{Z}), \quad \|\mathbf{X}\|_{\mathbf{R}} = \|\mathbf{R}^{-1/2} \mathbf{X} \mathbf{R}^{-1/2}\|_F. \quad (3.11)$$

Геометрическое расстояние (3.7) допускает эквивалентную симметричную запись

$$\delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2) = \|\log (\mathbf{R}_1^{-1/2} \mathbf{R}_2 \mathbf{R}_1^{-1/2})\|_F, \quad (3.12)$$

поскольку матрицы $\mathbf{R}_1^{-1} \mathbf{R}_2$ и $\mathbf{R}_1^{-1/2} \mathbf{R}_2 \mathbf{R}_1^{-1/2}$ подобны и имеют одни и те же собственные значения $\lambda_l > 0$, а норма Фробениуса симметричной матрицы равна корню из суммы квадратов ее собственных значений; в отличие от $\log(\mathbf{R}_1^{-1} \mathbf{R}_2)$, матрица под нормой в (3.12) симметрична.

Лемма 3.3.1. *Для любой обратимой матрицы $\mathbf{A} \in \mathbb{R}^{h \times h}$ и любых $\mathbf{R}_1, \mathbf{R}_2 \in \mathbb{S}_+^h$*

$$\delta_{\mathcal{R}}(\mathbf{A} \mathbf{R}_1 \mathbf{A}^\top, \mathbf{A} \mathbf{R}_2 \mathbf{A}^\top) = \delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2).$$

Доказательство. Расстояние зависит только от собственных значений матрицы $\mathbf{R}_1^{-1} \mathbf{R}_2$. Матрица $(\mathbf{A} \mathbf{R}_1 \mathbf{A}^\top)^{-1} \mathbf{A} \mathbf{R}_2 \mathbf{A}^\top = \mathbf{A}^{-\top} \mathbf{R}_1^{-1} \mathbf{R}_2 \mathbf{A}^\top$ подобна $\mathbf{R}_1^{-1} \mathbf{R}_2$, а подобные матрицы имеют одинаковые собственные значения. $\square$

Риманово среднее $\bar{\mathbf{R}}$ из раздела 3.2.3 существует и единственно, поскольку функция $\mathbf{R} \mapsto \delta_{\mathcal{R}}^2(\mathbf{R}, \mathbf{R}_i)$ строго геодезически выпукла на многообразии неположительной кривизны [148; 149]. Оно характеризуется уравнением

$$\sum_{i=1}^N \log (\bar{\mathbf{R}}^{-1/2} \mathbf{R}_i \bar{\mathbf{R}}^{-1/2}) = \mathbf{0}. \quad (3.13)$$

Координаты в касательном пространстве. Проекция $\mathbf{P}_i = \text{Log}_{\bar{\mathbf{R}}}(\mathbf{R}_i)$ является касательным вектором в точке $\bar{\mathbf{R}}$, и ее длина измеряется нормой (3.11). Напомним обозначения раздела 3.2.3, см. (3.9) и (3.10): отбеленная форма касательного вектора и признак объекта равны

$$\mathbf{S}_i = \bar{\mathbf{R}}^{-1/2} \mathbf{P}_i \bar{\mathbf{R}}^{-1/2} = \log (\bar{\mathbf{R}}^{-1/2} \mathbf{R}_i \bar{\mathbf{R}}^{-1/2}), \quad \mathbf{p}_i = \text{vec}_{\sqrt{2}}(\mathbf{S}_i) \in \mathbb{R}^d, \quad (3.14)$$

где $\text{vec}_{\sqrt{2}}$ — векторизация (3.10) и $d = h(h+1)/2$.

Лемма 3.3.2. *Отображение $\text{vec}_{\sqrt{2}}$ является линейной изометрией пространств $(\text{Sym}(h), \|\cdot\|_F)$ и $(\mathbb{R}^d, \|\cdot\|_2)$. Как следствие,*

$$\|\mathbf{p}_i\|_2 = \|\mathbf{P}_i\|_{\bar{\mathbf{R}}}, \quad \|\mathbf{p}_i - \mathbf{p}_j\|_2 = \|\mathbf{P}_i - \mathbf{P}_j\|_{\bar{\mathbf{R}}}.$$

Доказательство. Для симметричной $\mathbf{S}$ каждый внедиагональный элемент входит в норму Фробениуса дважды: $\|\mathbf{S}\|_F^2 = \sum_k S_{kk}^2 + 2 \sum_{k < l} S_{kl}^2 = \|\text{vec}_{\sqrt{2}}(\mathbf{S})\|_2^2$. Линейность очевидна. Второе утверждение следует из (3.11) и (3.14). $\square$

Замечание. Из уравнения (3.13) и линейности $\text{vec}_{\sqrt{2}}$ следует $\sum_i \mathbf{p}_i = \mathbf{0}$: признаки обучающей выборки центрированы автоматически.

Далее используются два элементарных факта о матричных функциях. Для симметричной $\mathbf{M} = \mathbf{U} \text{diag}(\lambda_1, \dots, \lambda_h) \mathbf{U}^\top$ с ортогональной $\mathbf{U}$ и функции f положено $f(\mathbf{M}) = \mathbf{U} \text{diag}(f(\lambda_1), \dots, f(\lambda_h)) \mathbf{U}^\top$, что согласуется с (3.8). Отображение $\exp: \text{Sym}(h) \rightarrow \mathbb{S}_+^h$ есть диффеоморфизм с обратным $\log$.

Лемма 3.3.3. Для ортогональной $\mathbf{Q}$ и симметричной $\mathbf{M}$ выполнено $f(\mathbf{Q}\mathbf{M}\mathbf{Q}^\top) = \mathbf{Q}f(\mathbf{M})\mathbf{Q}^\top$.

Доказательство. Если $\mathbf{M} = \mathbf{U} \text{diag}(\lambda) \mathbf{U}^\top$, то $\mathbf{Q}\mathbf{M}\mathbf{Q}^\top = (\mathbf{Q}\mathbf{U}) \text{diag}(\lambda) (\mathbf{Q}\mathbf{U})^\top$ — спектральное разложение с теми же собственными значениями и ортогональной матрицей $\mathbf{Q}\mathbf{U}$. $\square$

Лемма 3.3.4. Для симметричных $\mathbf{S}$ и $\mathbf{X}$ дифференциал матричной экспоненты равен

$$d \exp_{\mathbf{S}}[\mathbf{X}] = \left. \frac{d}{dt} e^{\mathbf{S}+t\mathbf{X}} \right|_{t=0} = \int_0^1 e^{(1-u)\mathbf{S}} \mathbf{X} e^{u\mathbf{S}} du. \quad (3.15)$$

Доказательство. Положим $\mathbf{G}(u) = e^{(1-u)\mathbf{S}} e^{u(\mathbf{S}+t\mathbf{X})}$. Тогда $\mathbf{G}(1) - \mathbf{G}(0) = e^{\mathbf{S}+t\mathbf{X}} - e^{\mathbf{S}}$, а производная $\mathbf{G}'(u) = e^{(1-u)\mathbf{S}} (-\mathbf{S} + \mathbf{S} + t\mathbf{X}) e^{u(\mathbf{S}+t\mathbf{X})} = t e^{(1-u)\mathbf{S}} \mathbf{X} e^{u(\mathbf{S}+t\mathbf{X})}$. Интегрируя по $u \in [0,1]$, деля на t и переходя к пределу $t \rightarrow 0$, получаем (3.15). $\square$

3.3.2. Инвариантность к преобразованию каналов

Первый вопрос к методу, работающему с многоканальной записью: зависит ли ответ от единиц измерения каналов и от их смешивания. Следующее предложение показывает, что для описанной конструкции ответ отрицательный.

Предложение 3.3.5. Пусть $\mathbf{A} \in \mathbb{R}^{h \times h}$ обратима и все ковариационные матрицы преобразованы как $\mathbf{R}'_i = \mathbf{A}\mathbf{R}_i\mathbf{A}^\top$, $i = 1, \dots, N$, что отвечает замене рядов $\mathbf{Y}_i$ на $\mathbf{A}\mathbf{Y}_i$. Тогда

- (а) риманово среднее преобразуется согласованно: $\bar{\mathbf{R}}' = \mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top$;
- (б) существует ортогональная матрица $\mathbf{O} \in \mathbb{R}^{d \times d}$, одна и та же для всех объектов, такая что $\mathbf{p}'_i = \mathbf{O}\mathbf{p}_i$;
- (в) матрица весов решения L_2 -регуляризованной логистической регрессии на признаках $\{\mathbf{p}'_i\}$ равна $\hat{\mathbf{W}}' = \hat{\mathbf{W}}\mathbf{O}^\top$, где $\hat{\mathbf{W}}$ — матрица весов решения на $\{\mathbf{p}_i\}$, и предсказания на любом объекте совпадают.

Доказательство. (а) По лемме 3.3.1 для любой $\mathbf{R} \in \mathbb{S}_+^h$ выполнено $\sum_i \delta_{\mathcal{R}}^2(\mathbf{A}\mathbf{R}\mathbf{A}^\top, \mathbf{R}'_i) = \sum_i \delta_{\mathcal{R}}^2(\mathbf{R}, \mathbf{R}_i)$. Отображение $\mathbf{R} \mapsto \mathbf{A}\mathbf{R}\mathbf{A}^\top$ — биекция $\mathbb{S}_+^h$ на себя, переводящая целевую функцию задачи о среднем для исходных матриц в целевую функцию задачи для преобразованных. Поэтому оно переводит минимизатор в минимизатор, и по единственности $\bar{\mathbf{R}}' = \mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top$.

(б) Положим $\mathbf{Q} = (\mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top)^{-1/2}\mathbf{A}\bar{\mathbf{R}}^{1/2}$. Прямая проверка дает

$$\mathbf{Q}\mathbf{Q}^\top = (\mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top)^{-1/2}\mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top(\mathbf{A}\bar{\mathbf{R}}\mathbf{A}^\top)^{-1/2} = \mathbb{I},$$

то есть $\mathbf{Q}$ ортогональна. Подставляя $\bar{\mathbf{R}}'$ из пункта (а) и вставляя $\bar{\mathbf{R}}^{1/2}\bar{\mathbf{R}}^{-1/2} = \mathbb{I}$ по обе стороны от $\mathbf{R}_i$, получаем

$$\bar{\mathbf{R}}'^{-1/2}\mathbf{R}'_i\bar{\mathbf{R}}'^{-1/2} = \mathbf{Q}(\bar{\mathbf{R}}^{-1/2}\mathbf{R}_i\bar{\mathbf{R}}^{-1/2})\mathbf{Q}^\top,$$

и по лемме 3.3.3 $\mathbf{S}'_i = \mathbf{Q}\mathbf{S}_i\mathbf{Q}^\top$. Отображение $\mathbf{S} \mapsto \mathbf{Q}\mathbf{S}\mathbf{Q}^\top$ линейно на $\text{Sym}(h)$ и сохраняет норму Фробениуса; в изометричных координатах леммы 3.3.2 оно задается матрицей $\mathbf{O}$, сохраняющей евклидову норму, то есть ортогональной. Матрица $\mathbf{O}$ зависит от $\mathbf{A}$ и $\bar{\mathbf{R}}$, но не от i .

(в) Функционал логистической регрессии с матрицей весов $\mathbf{W} \in \mathbb{R}^{L \times d}$ и вектором смещений $\mathbf{b}$

$$J(\mathbf{W}, \mathbf{b}) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, \mathbf{W}\mathbf{p}_i + \mathbf{b}) + \lambda \|\mathbf{W}\|_F^2$$

выпукл по паре $(\mathbf{W}, \mathbf{b})$, а слагаемое $\lambda \|\mathbf{W}\|_F^2$ строго выпукло по $\mathbf{W}$: если бы два минимизатора имели различные матрицы весов, их полусумма давала бы строго меньшее значение функционала. Поэтому матрица весов $\hat{\mathbf{W}}$ у всех минимизаторов одна и та же. Так как $(\mathbf{W}\mathbf{O}^\top)(\mathbf{O}\mathbf{p}_i) = \mathbf{W}\mathbf{p}_i$ и $\|\mathbf{W}\mathbf{O}^\top\|_F = \|\mathbf{W}\|_F$,

функционал задачи на преобразованных признаках в точке $(\mathbf{W}\mathbf{O}^\top, \mathbf{b})$ равен исходному в точке $(\mathbf{W}, \mathbf{b})$. Биекция $\mathbf{W} \mapsto \mathbf{W}\mathbf{O}^\top$ переводит минимизаторы в минимизаторы, откуда $\hat{\mathbf{W}}' = \hat{\mathbf{W}}\mathbf{O}^\top$, и $\hat{\mathbf{W}}'\mathbf{p}' = \hat{\mathbf{W}}\mathbf{p}$ для любого объекта, поскольку пункт (б) верен для произвольной $\mathbf{R} \in \mathbb{S}_+^h$, а не только для объектов обучающей выборки. $\square$

Следствие 3.3.6. *Результат классификации не зависит от единиц измерения сигнала, от покомпонентного масштабирования вокселей, которому отвечают диагональные $\mathbf{A}$, от нормировочного множителя в (3.5), которому отвечает $\mathbf{A} = c\mathbb{I}$, и от невырожденного смешивания отобранных вокселей.*

Замечание. Предложение предполагает, что признаки подаются в классификатор без покомпонентной стандартизации: она не коммутирует с поворотом $\mathbf{O}$. При $h < \mathcal{T} - 1$ выборочная ковариация (3.5) невырождена почти наверное, и регуляризация ковариаций сжатием не требуется.

3.3.3. Искажение расстояний касательной проекцией

Классификатор работает не с геодезическими расстояниями на многообразии, а с евклидовыми расстояниями между векторами $\mathbf{p}_i$. Следующая лемма дает основное вычисление: как дифференциал экспоненты меняет длину касательного вектора в метрике (3.11).

Лемма 3.3.7. *Пусть $\mathbf{S}, \mathbf{X} \in \text{Sym}(h)$, $\lambda_1, \dots, \lambda_h$ — собственные значения $\mathbf{S}$, а X_{kl} — элементы $\mathbf{X}$ в ортонормированном собственном базисе $\mathbf{S}$. Тогда*

$$\|d \exp_{\mathbf{S}}[\mathbf{X}]\|_{e^{\mathbf{S}}}^2 = \sum_{k,l=1}^h g(\lambda_k - \lambda_l)^2 X_{kl}^2, \quad g(x) = \frac{\sinh(x/2)}{x/2}, \quad g(0) = 1. \quad (3.16)$$

Функция g четна, $g(x) \geq 1$ и строго возрастает по $|x|$.

Доказательство. Касательный вектор (3.15) приложен в точке $\mathbf{P} = e^{\mathbf{S}}$, поэтому по (3.11) его длина равна норме Фробениуса матрицы

$$e^{-\mathbf{S}/2} \left(\int_0^1 e^{(1-u)\mathbf{S}} \mathbf{X} e^{u\mathbf{S}} du \right) e^{-\mathbf{S}/2} = \int_0^1 e^{(1/2-u)\mathbf{S}} \mathbf{X} e^{(u-1/2)\mathbf{S}} du.$$

Перейдем в ортонормированный собственный базис $\mathbf{S}$; норма Фробениуса при этом не меняется, а матрицы $e^{a\mathbf{S}}$ диагональны, поэтому элемент (k, l) подынтегральной матрицы равен $X_{kl}e^{(1/2-u)(\lambda_k-\lambda_l)}$. Интегрируя,

$$\int_0^1 e^{(1/2-u)(\lambda_k-\lambda_l)} du = \int_{-1/2}^{1/2} e^{v(\lambda_k-\lambda_l)} dv = \frac{e^{(\lambda_k-\lambda_l)/2} - e^{-(\lambda_k-\lambda_l)/2}}{\lambda_k - \lambda_l} = g(\lambda_k - \lambda_l),$$

что дает (3.16). Четность g очевидна, $g \geq 1$ следует из $\sinh x \geq x$ при $x \geq 0$, а строгое возрастание по $|x|$ — из строгого возрастания $\sinh x/x$ на $[0, \infty)$. $\square$

Для $\mathbf{S} \in \text{Sym}(h)$ обозначим через $\omega(\mathbf{S}) = \lambda_{\max}(\mathbf{S}) - \lambda_{\min}(\mathbf{S})$ ее спектральный разброс. Для касательного вектора (3.14) он равен логарифму числа обусловленности отбеленной ковариации: $\omega(\mathbf{S}_i) = \log \kappa(\bar{\mathbf{R}}^{-1/2} \mathbf{R}_i \bar{\mathbf{R}}^{-1/2})$, где $\kappa(\mathbf{C}) = \lambda_{\max}(\mathbf{C})/\lambda_{\min}(\mathbf{C})$.

Теорема 3.3.8. *Для признаков (3.14) справедливы следующие утверждения.*

(а) *Норма признака равна геодезическому расстоянию до опорной точки:*

$$\|\mathbf{p}_i\|_2 = \delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i).$$

(б) *Проекция не увеличивает расстояний: $\|\mathbf{p}_i - \mathbf{p}_j\|_2 \leq \delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j)$ для любых i, j .*

(в) *Если $\omega(\mathbf{S}_i) \leq \omega$ для всех i , то*

$$\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) \leq g(\omega) \|\mathbf{p}_i - \mathbf{p}_j\|_2, \quad g(\omega) = \frac{\sinh(\omega/2)}{\omega/2}. \quad (3.17)$$

(г) *Если $\delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i) \leq \rho$ для всех i , то*

$$\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) \leq c(\rho) \|\mathbf{p}_i - \mathbf{p}_j\|_2, \quad c(\rho) = g(\sqrt{2}\rho) = \frac{\sinh(\rho/\sqrt{2})}{\rho/\sqrt{2}}. \quad (3.18)$$

Доказательство. По предложению 3.3.5 с $\mathbf{A} = \bar{\mathbf{R}}^{-1/2}$ и лемме 3.3.1 обе части всех соотношений, а также $\omega(\mathbf{S}_i)$, не меняются при переходе к матрицам $\bar{\mathbf{R}}^{-1/2} \mathbf{R}_i \bar{\mathbf{R}}^{-1/2}$, поэтому достаточно рассмотреть случай $\bar{\mathbf{R}} = \mathbb{I}$. Тогда $\mathbf{S}_i = \log \mathbf{R}_i$ и $\mathbf{R}_i = \exp \mathbf{S}_i$.

(а) По (3.12) и лемме 3.3.2 $\delta_{\mathcal{R}}(\mathbb{I}, \mathbf{R}_i) = \|\log \mathbf{R}_i\|_F = \|\mathbf{S}_i\|_F = \|\mathbf{p}_i\|_2$.

(б) Из леммы 3.3.7 и $g \geq 1$ следует $\|d \exp_{\mathbf{S}}[\mathbf{X}]\|_{e^{\mathbf{S}}} \geq \|\mathbf{X}\|_F$ для всех $\mathbf{S}, \mathbf{X}$: экспонента не укорачивает касательных векторов. Пусть σ — произвольная гладкая кривая в $\mathbb{S}_+^h$ из $\mathbf{R}_i$ в $\mathbf{R}_j$. Поскольку $\exp$ — диффеоморфизм, кривая $\gamma = \log \circ \sigma$ лежит в $\text{Sym}(h)$, соединяет $\mathbf{S}_i$ с $\mathbf{S}_j$, и $\dot{\sigma}(t) = d \exp_{\gamma(t)}[\dot{\gamma}(t)]$. Для длин кривых

$$L(\sigma) = \int \left\| d \exp_{\gamma(t)}[\dot{\gamma}(t)] \right\|_{\sigma(t)} dt \geq \int \|\dot{\gamma}(t)\|_F dt \geq \|\mathbf{S}_i - \mathbf{S}_j\|_F,$$

где последнее неравенство — евклидов отрезок короче любой соединяющей кривой. Геодезическое расстояние есть нижняя грань $L(\sigma)$ по всем кривым, поэтому $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) \geq \|\mathbf{S}_i - \mathbf{S}_j\|_F = \|\mathbf{p}_i - \mathbf{p}_j\|_2$.

(в) Рассмотрим отрезок $\gamma(t) = (1-t)\mathbf{S}_i + t\mathbf{S}_j$, $t \in [0,1]$, и его образ $\exp \circ \gamma$, соединяющий $\mathbf{R}_i$ с $\mathbf{R}_j$. Функция $\lambda_{\max}$ выпукла, а $\lambda_{\min}$ вогнута на $\text{Sym}(h)$, поэтому

$$\omega(\gamma(t)) \leq (1-t)\omega(\mathbf{S}_i) + t\omega(\mathbf{S}_j) \leq \omega.$$

Разность любых двух собственных значений $\gamma(t)$ по модулю не превосходит $\omega(\gamma(t))$, и так как g возрастает по модулю аргумента, из (3.16) для всех t и $\mathbf{X} \in \text{Sym}(h)$

$$\|d \exp_{\gamma(t)}[\mathbf{X}]\|_{e^{\gamma(t)}} \leq g(\omega(\gamma(t)))\|\mathbf{X}\|_F \leq g(\omega)\|\mathbf{X}\|_F.$$

Следовательно, длина кривой $\exp \circ \gamma$ не превосходит $g(\omega) \int_0^1 \|\dot{\gamma}(t)\|_F dt = g(\omega)\|\mathbf{S}_j - \mathbf{S}_i\|_F$, а геодезическое расстояние не превосходит длины любой соединяющей кривой.

(г) Для симметричной $\mathbf{S}$ с собственными значениями λ_k из $(a-b)^2 \leq 2(a^2 + b^2)$ и $\sum_k \lambda_k^2 = \|\mathbf{S}\|_F^2$ следует $\omega(\mathbf{S}) \leq \sqrt{2}\|\mathbf{S}\|_F$. По пункту (а) и условию $\|\mathbf{S}_i\|_F \leq \rho$, поэтому $\omega(\mathbf{S}_i) \leq \sqrt{2}\rho$, и остается применить пункт (в) с $\omega = \sqrt{2}\rho$. $\square$

Следующее предложение показывает, что константы теоремы нельзя уменьшить, но достигаются они лишь в пределе.

Предложение 3.3.9. Пусть $\omega > 0$.

- (а) Для любой пары различных объектов, удовлетворяющих условию пункта (в) теоремы 3.3.8, неравенство (3.17) строгое; то же верно для пункта (г) и неравенства (3.18).
- (б) Пусть $\mathbf{D} = \text{diag}(\omega/2, -\omega/2, 0, \dots, 0)$, $\mathbf{Q}_\theta$ — поворот на угол θ в плоскости первых двух базисных векторов и $\mathbf{S}(\theta) = \mathbf{Q}_\theta \mathbf{D} \mathbf{Q}_\theta^\top$. Тогда $\omega(\mathbf{S}(\theta)) = \omega$, $\|\mathbf{S}(\theta)\|_F = \omega/\sqrt{2}$ для всех θ и

$$\lim_{\theta \rightarrow 0} \frac{\delta_{\mathcal{R}}(\exp \mathbf{S}(-\theta/2), \exp \mathbf{S}(\theta/2))}{\|\mathbf{S}(\theta/2) - \mathbf{S}(-\theta/2)\|_F} = g(\omega). \quad (3.19)$$

Выборка из четырех матриц $\exp \mathbf{S}(\pm\theta/2)$, $\exp(-\mathbf{S}(\pm\theta/2))$ имеет риманово среднее $\bar{\mathbf{R}} = \mathbb{I}$, все ее элементы удовлетворяют условию пункта (в) теоремы 3.3.8 с данным ω и условию пункта (г) с $\rho =$

$\omega/\sqrt{2}$, а отношение геодезического расстояния между $\exp \mathbf{S}(-\theta/2)$ и $\exp \mathbf{S}(\theta/2)$ к евклидову расстоянию между их признаками стремится к $g(\omega) = c(\rho)$.

Доказательство. (а) Как и в теореме, считаем $\bar{\mathbf{R}} = \mathbb{I}$. Пусть $\mathbf{X} = \mathbf{S}_j - \mathbf{S}_i \neq \mathbf{0}$, $\gamma(t) = \mathbf{S}_i + t\mathbf{X}$ и $\varphi(t) = \|d \exp_{\gamma(t)}[\mathbf{X}]\|_{e^{\gamma(t)}}$ — непрерывная функция на $[0,1]$. По лемме 3.3.7 $\varphi(t)^2 = \sum_{k,l} (g(\lambda_k(t) - \lambda_l(t))^2 X_{kl}(t)^2)$, где $\lambda_k(t)$ — собственные значения $\gamma(t)$, а $X_{kl}(t)$ — элементы $\mathbf{X}$ в собственном базисе $\gamma(t)$. Все множители не превосходят $g(\omega)$, а при $k = l$ равны $g(0) = 1 < g(\omega)$, поэтому равенство $\varphi(t) = g(\omega)\|\mathbf{X}\|_F$ возможно лишь при $X_{kk}(t) = 0$ для всех k . Но

$$\sum_k \lambda_k(t) X_{kk}(t) = \text{tr}(\gamma(t)\mathbf{X}) = \frac{1}{2} \frac{d}{dt} \|\gamma(t)\|_F^2,$$

и если бы $\varphi(t) = g(\omega)\|\mathbf{X}\|_F$ на всем отрезке $[0,1]$, функция $\|\gamma(t)\|_F^2 = \|\mathbf{S}_i\|_F^2 + 2t\langle \mathbf{S}_i, \mathbf{X} \rangle + t^2\|\mathbf{X}\|_F^2$ была бы постоянной, что противоречит $\|\mathbf{X}\|_F > 0$. Значит, $\varphi(t) < g(\omega)\|\mathbf{X}\|_F$ на непустом открытом множестве, и $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) \leq \int_0^1 \varphi(t) dt < g(\omega)\|\mathbf{X}\|_F$. Для пункта (г) достаточно заметить, что условие $\delta_{\mathcal{R}}(\mathbb{I}, \mathbf{R}_i) \leq \rho$ влечет условие пункта (в) с $\omega = \sqrt{2}\rho$.

(б) Ортогональное сопряжение не меняет спектра, откуда $\omega(\mathbf{S}(\theta)) = \omega$ и $\|\mathbf{S}(\theta)\|_F = \|\mathbf{D}\|_F = \omega/\sqrt{2}$. Кривая $\sigma(\theta) = \exp \mathbf{S}(\theta)$ гладкая, и для геодезического расстояния на римановом многообразии $\delta_{\mathcal{R}}(\sigma(-\theta/2), \sigma(\theta/2)) = \theta \|\dot{\sigma}(0)\|_{\sigma(0)} + o(\theta)$, тогда как $\|\mathbf{S}(\theta/2) - \mathbf{S}(-\theta/2)\|_F = \theta \|\dot{\mathbf{S}}(0)\|_F + o(\theta)$. Производная $\dot{\mathbf{Q}}_0 = \mathbf{e}_2 \mathbf{e}_1^\top - \mathbf{e}_1 \mathbf{e}_2^\top$, поэтому $\dot{\mathbf{S}}(0) = \dot{\mathbf{Q}}_0 \mathbf{D} - \mathbf{D} \dot{\mathbf{Q}}_0 = \omega(\mathbf{e}_1 \mathbf{e}_2^\top + \mathbf{e}_2 \mathbf{e}_1^\top)$: в собственном базисе $\mathbf{D}$ вектор $\dot{\mathbf{S}}(0)$ имеет лишь элементы (1,2) и (2,1), отвечающие паре собственных значений с разностью ω . По лемме 3.3.7 $\|\dot{\sigma}(0)\|_{\sigma(0)} = \|d \exp_{\mathbf{D}}[\dot{\mathbf{S}}(0)]\|_{e^{\mathbf{D}}} = g(\omega)\|\dot{\mathbf{S}}(0)\|_F$, что дает (3.19). Для выборки из четырех матриц $\exp(\pm \mathbf{S}(\pm \theta/2))$ сумма логарифмов равна нулю, то есть $\mathbb{I}$ удовлетворяет уравнению (3.13), характеризующему риманово среднее, откуда $\bar{\mathbf{R}} = \mathbb{I}$. Спектральный разброс и норма Фробениуса всех четырех касательных векторов $\pm \mathbf{S}(\pm \theta/2)$ равны ω и $\omega/\sqrt{2}$, поэтому по пункту (а) теоремы 3.3.8 выполнены условия пунктов (в) и (г). Признаки равны $\text{vec}_{\sqrt{2}}(\pm \mathbf{S}(\pm \theta/2))$, так что евклидово расстояние между признаками пары $\exp \mathbf{S}(\mp \theta/2)$ равно $\|\mathbf{S}(\theta/2) - \mathbf{S}(-\theta/2)\|_F$, и утверждение следует из (3.19) и равенства $g(\sqrt{2}\rho) = c(\rho)$. $\square$

Предельный переход (3.19) проверяется численно в разделе 3.4.6.

Замечание. Теорема 3.3.8 и предложение 3.3.9 означают, что отношение $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j)/\|\mathbf{p}_i - \mathbf{p}_j\|_2$ по всем парам объектов лежит в полуинтервале $[1, g(\omega))$, точная верхняя грань которого достигается в пределе сближающихся пар. Концы этого промежутка отвечают двум предельным направлениям смещения в касательном пространстве, показанным на рис. 3.4. Нижняя граница достигается на коммутирующих касательных векторах: в общем собственном базисе $\mathbf{R}_i^{-1/2}\mathbf{R}_j\mathbf{R}_i^{-1/2} = \exp(\mathbf{S}_j - \mathbf{S}_i)$, поэтому $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) = \|\mathbf{p}_i - \mathbf{p}_j\|_2$; в частности, радиальные расстояния вдоль геодезической через опорную точку сохраняются точно: при $\mathbf{p}_k = -\mathbf{p}_i$ выполнено $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_k) = 2\|\mathbf{p}_i\|_2$. Верхняя граница приближается на тангенциальных смещениях, поворачивающих собственный базис при неизменном спектре. Таким образом, искажение порождается не удаленностью объектов от опорной точки, а некоммутативностью их касательных векторов, и управляется спектральным разбросом ω , а не нормой: касательный вектор $a\mathbb{I}$, отвечающий общему масштабированию всех вокселей, имеет норму $|a|\sqrt{h}$, но нулевой разброс и не вносит вклада в искажение. В терминах числа обусловленности $\kappa = e^{\omega}$ отбеленных ковариаций константа записывается как $g(\log \kappa) = (\kappa - 1)/(\sqrt{\kappa} \log \kappa)$. Пункт (б) теоремы есть частный случай общего свойства многообразий неположительной кривизны: экспоненциальное отображение не уменьшает расстояний [148].

3.3.4. Шум оценки ковариаций

Ковариационная матрица объекта оценивается по $\mathcal{T}$ сканам, поэтому часть разброса признаков есть не различие объектов, а ошибка оценки. Следующая теорема показывает, что распределение этой ошибки в геодезической метрике не зависит от истинной ковариации, и дает ее оценку. Используется классический результат о сингулярных числах гауссовой матрицы.

Предложение 3.3.10 ([150, следствие 5.35]). Пусть $\mathbf{G} \in \mathbb{R}^{n \times k}$, $n \geq k$, имеет независимые элементы с распределением $\mathcal{N}(0,1)$. Тогда для любого $u \geq 0$ с вероятностью не меньше $1 - 2e^{-u^2/2}$

$$\sqrt{n} - \sqrt{k} - u \leq s_{\min}(\mathbf{G}) \leq s_{\max}(\mathbf{G}) \leq \sqrt{n} + \sqrt{k} + u,$$

где $s_{\min}$ и $s_{\max}$ — наименьшее и наибольшее сингулярные числа.




Рисунок 3.4 — Искажение расстояний при проекции на касательное пространство. Точки $\mathbf{R}_i, \mathbf{R}_j, \mathbf{R}_k$ лежат на окружности геодезического радиуса ρ вокруг $\bar{\mathbf{R}}$, их образы $\mathbf{p}_i, \mathbf{p}_j, \mathbf{p}_k$ — на окружности того же радиуса в $T_{\bar{\mathbf{R}}}$. Радиальное расстояние через $\bar{\mathbf{R}}$ сохраняется: $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_k) = \|\mathbf{p}_i - \mathbf{p}_k\|_2 = 2\rho$. Тангенциальное расстояние между соседними точками окружности при возвращении на многообразии растягивается: отношение $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j)/\|\mathbf{p}_i - \mathbf{p}_j\|_2$ меньше $c(\rho)$ и по предложению 3.3.9 стремится к $c(\rho)$ при сближении $\mathbf{R}_j$ с $\mathbf{R}_i$

Теорема 3.3.11. Пусть столбцы матрицы $\mathbf{Y} \in \mathbb{R}^{h \times \mathcal{T}}$ — независимые случайные векторы с распределением $\mathcal{N}(\mathbf{0}, \mathbf{R})$, $\mathbf{R} \in \mathbb{S}_+^h$, и $\hat{\mathbf{R}} = \mathcal{T}^{-1} \mathbf{Y} \mathbf{Y}^\top$. Тогда

- (а) распределение случайной величины $\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R})$ не зависит от $\mathbf{R}$, а только от h и $\mathcal{T}$;
- (б) для любого $t > 0$ такого, что $\varepsilon = \sqrt{h/\mathcal{T}} + t < 1$, с вероятностью не меньше $1 - 2 \exp(-\mathcal{T}t^2/2)$

$$\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R}) \leq \frac{2\sqrt{h} \varepsilon}{1 - \varepsilon}. \quad (3.20)$$

Доказательство. (а) Положим $\Xi = \mathbf{R}^{-1/2} \mathbf{Y}$. Столбцы Ξ независимы и распределены как $\mathcal{N}(\mathbf{0}, \mathbb{I})$, то есть все элементы Ξ независимы и стандартны нормальны, и их распределение от $\mathbf{R}$ не зависит. По лемме 3.3.1 с $\mathbf{A} = \mathbf{R}^{-1/2}$

$$\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R}) = \delta_{\mathcal{R}}(\mathbf{R}^{-1/2} \hat{\mathbf{R}} \mathbf{R}^{-1/2}, \mathbb{I}) = \|\log \hat{\mathbf{C}}\|_F, \quad \hat{\mathbf{C}} = \mathcal{T}^{-1} \Xi \Xi^\top,$$

и правая часть есть функция только от Ξ .

(б) Применим предложение 3.3.10 к матрице $\Xi^\top \in \mathbb{R}^{\mathcal{T} \times h}$ с $u = t\sqrt{\mathcal{T}}$: с вероятностью не меньше $1 - 2\exp(-\mathcal{T}t^2/2)$ все ее сингулярные числа лежат в отрезке $\sqrt{\mathcal{T}}[1 - \varepsilon, 1 + \varepsilon]$. Собственные значения $\hat{\mathbf{C}}$ суть квадраты сингулярных чисел $\Xi^\top$, деленные на $\mathcal{T}$, поэтому на этом событии они лежат в $[(1 - \varepsilon)^2, (1 + \varepsilon)^2]$, и для каждого из них

$$|\log \lambda_k(\hat{\mathbf{C}})| \leq \max \{2\log(1 + \varepsilon), -2\log(1 - \varepsilon)\} = -2\log(1 - \varepsilon) \leq \frac{2\varepsilon}{1 - \varepsilon},$$

где равенство следует из $-\log(1 - \varepsilon) \geq \log(1 + \varepsilon)$ при $\varepsilon \in (0, 1)$, а последнее неравенство — из $\log x \leq x - 1$ при $x = 1/(1 - \varepsilon)$. Остается заметить, что $\|\log \hat{\mathbf{C}}\|_F^2 = \sum_{k=1}^h \log^2 \lambda_k(\hat{\mathbf{C}}) \leq h \max_k \log^2 \lambda_k(\hat{\mathbf{C}})$, что дает (3.20). $\square$

Следствие 3.3.12. Пусть признаки $\mathbf{p}_i$ и $\hat{\mathbf{p}}_i$ вычислены по (3.14) при одной и той же опорной точке по истинной ковариации $\mathbf{R}_i$ и по ее оценке $\hat{\mathbf{R}}_i$. Тогда $\|\hat{\mathbf{p}}_i - \mathbf{p}_i\|_2 \leq \delta_{\mathcal{R}}(\hat{\mathbf{R}}_i, \mathbf{R}_i)$, и эта величина ограничена теоремой 3.3.11.

Доказательство. Первое неравенство — пункт (б) теоремы 3.3.8, примененный к паре $\hat{\mathbf{R}}_i, \mathbf{R}_i$. $\square$

Замечание. Пункт (а) теоремы 3.3.11 означает, что типичную величину ошибки оценки ковариации в геодезической метрике можно получить моделированием с единичной ковариацией, и результат будет верен для любых реальных ковариаций с теми же h и $\mathcal{T}$. Сравнение этой величины с наблюдаемым разбросом $\delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i)$ показывает, какая доля разброса признаков обусловлена шумом оценки, а не различием объектов. Оценка (3.20) задает скорость $\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R}) = O(h/\sqrt{\mathcal{T}})$: шум оценки растет линейно по числу отобранных вокселей и убывает как корень из длины ряда. Отсюда следует ограничение $h \ll \mathcal{T}$ на параметр h Алгоритма 1: ковариация вычисляется по небольшому числу наиболее коррелированных со стимулом вокселей, а не по всей маске, поскольку рост h при фиксированной длине сегмента увеличивает шум оценки. Для центрированных рядов и нормировки (3.5) теорема применяется с $\mathcal{T} - 1$ вместо $\mathcal{T}$; выбор нормировочного множителя на признаки не влияет по следствию 3.3.6.

Оценка (3.20) проверяется численно в разделе 3.4.7.

3.4. Вычислительный эксперимент

Вычислительный эксперимент использует данные фМРТ из исследования [11], собранные при изучении представлений лиц и объектов в зрительной коре. Набор данных содержит записи фМРТ от 6 пациентов. Каждый пациент проходил 12 сессий. В каждой сессии пациент пассивно просматривал черно-белые изображения восьми категорий, сгруппированные в блоки по 24 секунды, разделенные периодами отдыха. Каждое изображение демонстрировалось в течение 500 мс, после чего следовал интервал между стимулами длительностью 1500 мс. Данные фМРТ мозга записывались с частотой 2,5 Гц. Примеры стимулов приведены на рис. 3.5, характеристики записей — в Таблице 6.

Categories of stimuli used in the experiment




Рисунок 3.5 — Визуализация стимулов из используемого набора данных. В наборе данных представлено 8 различных типов визуальных стимулов. Для каждого типа выбрано по 4 примера изображений. Стимулы для каждой категории значительно различаются.

Кроме того, набор данных содержит временные ряды стимулов и маски активных областей мозга, полученные нейрочеными. Эти области были определены для каждого пациента эксперимента индивидуально. В наборе данных Нахбу et al. [11] учитывается гемодинамический лаг в процессе аннотирования,

Таблица 6 — Основные параметры временных рядов фМРТ из выборки

Название	Обозначение	Значение
Количество сканов за сессию	$\mathcal{T}_{\text{rec}}$	121
Частота сканирования	μ	2,5 Гц
Размеры скана	X, Y, Z	40, 64, 64

что обеспечивает корректную временную синхронизацию данных. Это позволяет установить гиперпараметр Δt равным 0 в ходе экспериментов.

3.4.1. Аугментация данных

Для формирования обучающей выборки к записи каждого пациента применялся метод сегментации из раздела 3.2.4. В Таблице 7 представлены параметры выборок, полученных в результате аугментации: из записи каждого пациента получено $N = 96$ временных рядов длины $\mathcal{T} = 19$ по $L = 8$ категориям, по $N_y = 12$ объектов на категорию. Выборка каждого пациента разбита на обучающую и тестовую в пропорции 80% к 20%. Качество оценивается метриками Accuracy, Macro F1-score и Micro F1-score.

Таблица 7 — Параметры выборки каждого пациента, полученной в результате аугментации временных рядов фМРТ

Название	Обозначение	Значение
Количество объектов	N	96
Длина каждого сегмента	$\mathcal{T}$	19
Количество классов стимулов	L	8
Количество объектов на класс	N_y	12

3.4.2. Оценка алгоритма выделения масок

Для оценки Алгоритма 1 его маски активности сравнивались с целевыми масками нейроученых и масками, полученными в ходе статистического анализа, с использованием метрик точности (англ. precision), полноты (англ. recall) и доли пересечения (англ. Intersection over Union, IoU), усредненных по шести пациентам. Precision измеряет долю правильных положительных предсказаний алгоритма, recall количественно оценивает способность алгоритма идентифицировать все релевантные области, а IoU оценивает перекрытие между предсказанными и истинными масками.

Гиперпараметры k_s и h выбирались для максимизации recall, чтобы маски активности покрывали как можно больше аннотаций нейроученых, даже если это означало включение некоторых дополнительных областей. Такой подход максимизирует выявление всех релевантных активных областей, потенциально за счет включения некоторых нерелевантных. Кроме того, важно было поддерживать высокую точность относительно статистически значимой маски. По результатам предварительных экспериментов значения параметров были установлены $k_s = 4$ и $h = 10$.

Таблица 8 — Усредненные значения метрик для сравнения масок активности. В таблице представлены средние значения и стандартные отклонения для каждой метрики

Метрика	Precision	Recall	IoU
Алгоритм 1 vs. Целевая	0.11 ± 0.04	0.43 ± 0.07	0.10 ± 0.04
Алгоритм 1 vs. Статистически значимая	1.00 ± 0.00	0.22 ± 0.09	0.22 ± 0.09

Результаты, представленные в Таблице 8, показывают, что алгоритм выявляет области мозга со статистически значимой корреляцией со стимулами, хорошо согласуясь с аннотациями нейроученых.

Для визуальной демонстрации рассматривается выборка первого пациента с размером ядра $k_s = 4$ и $h = 10$. Выбраны срезы на различных координатах: 20-й, 28-й и 24-й срезы вдоль каждой из трех осей. На рис. 3.6 приведены срезы скана из выборки с соответствующими масками активности: в верхней строке — области, определенные Алгоритмом 1, в средней — области, полученные

в результате статистического анализа, в нижней — аннотации нейроученых, служащие эталоном. Экспериментально подтверждено, что корреляция между взвешенными областями и стимулами статистически значима, а выявленные области хорошо согласуются с аннотациями нейроученых.

Также рассматривалось качество работы алгоритма на неинформативных данных. Использовались временные ряды фМРТ первого пациента и случайно сгенерированный бинарный временной ряд стимулов. На рис. 3.7 показаны срезы скана фМРТ, где цветом выделены области мозга, предсказанные Алгоритмом 1: алгоритм предсказывает случайные области, не связанные с активностью мозга. Как и в предыдущем эксперименте, были проведены статистические тесты. Ни одна из полученных областей не оказалась статистически значимой, что подтверждает корректность алгоритма.


Высокая пикселизация на рис. 3.6 и 3.7 является результатом намеренного сжатия сканов фМРТ в Алгоритме 1 для устранения лишнего шума. Визуализированные маски активности показаны после увеличения разрешения ($\mathcal{M}^\uparrow$), однако модель классификации работает со сжатыми сканами и маской $\mathcal{M}$, минуя шаг увеличения разрешения.

3.4.3. Результаты классификации


Рассматривались данные фМРТ первых трех пациентов. В ходе экспериментов были зафиксированы следующие параметры модели: количество областей для каждого класса $h_y = 10$, $y = 1, \dots, L$, и размер ядра $k_s = 4$. В качестве классификатора η использовалась логистическая регрессия со стратегией «один против всех» и единичным коэффициентом L_2 -регуляризации. Кроме того, рассматривался двухслойный перцептрон, каждый слой которого содержал 128 нейронов с сигмоидной функцией активации.

В Таблице 9 представлены усредненные значения метрик по пациентам на тестовой выборке, а также их стандартные отклонения и 95% доверительные интервалы (англ. Confidence Interval, CI), которые рассчитаны для определения диапазона, в котором, вероятно, находятся истинные значения метрик.


Полученные метрики указывают на возможность улучшения, что ожидается при ограниченном объеме данных. Тем не менее, модель демонстрирует



а) Алгоритм 1



б) Алгоритм 1



в) Алгоритм 1






г) Статистически
значимыед) Статистически
значимыее) Статистически
значимыеж) Аннотации
нейроученыхи) Аннотации
нейроученыхк) Аннотации
нейроученых

Рисунок 3.6 — Визуализация масок активности фМРТ. Выбранные области обозначены красным цветом. На верхней строке показаны предсказанные маски активности с использованием Алгоритма 1, на средней строке — статистически значимые области, полученные в результате анализа, а на нижней строке — аннотации нейроученых в качестве эталона. Предсказанные области достаточно покрывают истинные аннотации, а статистически значимая корреляция взвешенных вокселей со стимулами подтверждает надежность алгоритма





Рисунок 3.7 — Анализ работы Алгоритма 1 на неинформативных данных. Представлены срезы по трем измерениям. Использовался случайно сгенерированный бинарный временной ряд стимулов. Алгоритм предсказывает случайные области, не связанные с активностью мозга

Таблица 9 — Средние значения метрик по пациентам для тестовой выборки, включая стандартные отклонения и 95% доверительные интервалы (англ. Confidence Interval, CI)


Классификатор η	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Логистическая регрессия	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]
Перцептрон	0.64 ± 0.05	0.60 ± 0.05	0.62 ± 0.04	[0.57, 0.71]	[0.54, 0.67]	[0.57, 0.67]

перспективы в обучении зависимостям даже при малом объеме данных и значительном количестве классов. Для дальнейшего анализа исследовалось влияние доли обучающей выборки на качество; метрики последовательно рассчитывались на одной и той же тестовой выборке для обеспечения сопоставимости.

На рис. 3.8 представлены графики Accuracy и Macro F1-score для логистической регрессии и перцептрона в зависимости от доли обучающей выборки, изменяющейся от 0 до 1, с погрешностями в виде стандартного отклонения по пациентам. Устойчивый восходящий тренд указывает на то, что извлеченные пространственно-временные характеристики значимы и что качество модели улучшается с увеличением объема обучающих данных: улучшения не являются случайными или следствием переобучения, а отражают реальное повышение способности модели обучаться на данных.



а) Accuracy



б) Macro F1-Score

Рисунок 3.8 — Анализ улучшения качества декодирования в зависимости от доли обучающей выборки. Графики представляют метрики Accuracy и Macro F1-score, усредненные по пациентам, в зависимости от доли обучающей выборки, изменяющейся от 0 до 1. Метрики вычислялись на одной и той же тестовой выборке для обеспечения согласованности. Результаты демонстрируют последовательное улучшение качества декодирования по мере увеличения размера обучающей выборки

3.4.4. Анализ исключением компонент

Для оценки вклада каждого компонента в предложенную модель было проведено исследование методом исключения компонент. Рассматривались следующие варианты моделей:

- *Без TSM*: временные ряды преобразуются в вектор после применения масок каждого класса, конкатенируются и подаются на вход классификатору без использования TSM.
- *Без масок классов*: маска активности рассчитывается как среднее по всем временным рядам, без учета специфичных для классов масок, и TSM применяется для кодирования.
- *Оригинальные маски*: вместо масок, сгенерированных алгоритмом из раздела 3.2.1, используются оригинальные маски, предоставленные нейрочечными, и TSM применяется для кодирования временных рядов.

В Таблице 10 представлены усредненные значения метрик по пациентам, а также их стандартные отклонения и 95% доверительные интервалы. Статистическая значимость оценивалась с использованием t-тестов для связанных

выборок, с результатами, обозначенными звездочками, где $*p\text{-value} < .05$ и $**p\text{-value} < .005$. Это подчеркивает важность каждого компонента относительно полной модели. Была применена поправка Холма для множественного тестирования, чтобы обеспечить достоверность статистических сравнений по трем метрикам. В качестве классификатора η использовалась логистическая регрессия.

Таблица 10 — Анализ методом исключения компонент влияния отдельных компонентов модели на качество классификации. Метрики на тестовых выборках усреднены по пациентам. Статистическая значимость обозначена звездочками: $*p\text{-value} < .05$, $**p\text{-value} < .005$, отражающими значимость улучшений относительно полной модели. Доверительные интервалы (англ. Confidence Interval, CI) представляют диапазон, в котором, вероятно, находятся истинные значения метрик с 95% доверительной вероятностью.

Метод	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Без TSM	$0.24 \pm 0.11^*$	$0.22 \pm 0.11^*$	$0.24 \pm 0.11^*$	[0.11, 0.37]	[0.09, 0.36]	[0.10, 0.37]
Без масок классов	$0.25 \pm 0.13^*$	$0.23 \pm 0.13^*$	$0.25 \pm 0.13^*$	[0.09, 0.41]	[0.07, 0.39]	[0.09, 0.41]
Оригинальные маски	$0.10 \pm 0.05^{**}$	$0.09 \pm 0.04^{**}$	$0.10 \pm 0.05^{**}$	[0.04, 0.16]	[0.03, 0.14]	[0.04, 0.16]
Предложенная модель	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Исследование методом исключения компонент показывает, что метрики значительно снижаются при исключении проецирования на касательное пространство риманова многообразия, что указывает на важную роль этого шага в предложенной модели. Кроме того, отсутствие масок активности для каждого класса стимулов также приводит к снижению качества классификации, что показывает важность учета индивидуальных характеристик каждого стимула. Статистическая значимость, обозначенная звездочками, подтверждает, что наблюдаемые снижения производительности статистически значимы.

3.4.5. Сравнение с нейросетевыми подходами

Для демонстрации превосходства предложенной модели над подходами на основе нейронных сетей, особенно при работе с ограниченными данными, мы сравниваем ее с двумя альтернативными моделями, использующими различные методы кодирования временных рядов фМРТ:

- *Оригинальные маски и LSTM*: эта модель сначала применяет оригинальные маски, предоставленные нейрочеными, для выбора активных областей мозга. Затем временные ряды из этих областей кодируются с использованием сети долгой краткосрочной памяти (англ. Long Short-Term Memory, LSTM), которая улавливает временные зависимости. Извлеченные признаки передаются через линейный слой с активацией softmax для классификации.
- *Оригинальные маски и Attention*: эта модель сначала применяет оригинальные маски, предоставленные нейрочеными, для выбора активных областей мозга. Затем временные ряды из этих областей кодируются с использованием слоя внимания для кодирования временных рядов. Механизм внимания взвешивает временные признаки, фокусируясь на наиболее релевантных временных точках, и результирующий контекстный вектор передается через линейный слой с активацией softmax для классификации.

В Таблице 11 представлены средние значения метрик по пациентам на тестовой выборке для каждой модели в сравнении с предложенной моделью, использующей логистическую регрессию в качестве классификатора η . Таблица включает статистическую значимость, оцененную с использованием t-тестов для связанных выборок, обозначенную звездочками, где $**p\text{-value} < .005$, рассчитанную для проверки гипотезы об том, что улучшения метрик для полной модели статистически значимы. Применяется поправка Холма для множественного тестирования, чтобы обеспечить достоверность статистических сравнений по трем метрикам. Кроме того, представлены 95% доверительные интервалы (англ. Confidence Interval, CI), чтобы указать диапазон, в котором, вероятно, находятся истинные значения метрик.

Таблица 11 — Сравнение модели с подходами на основе нейронных сетей. Метрики усреднены по пациентам для тестовой выборки, с указанием статистической значимости и доверительных интервалов. Статистическая значимость обозначена звездочками: $**p\text{-value} < .005$.

Модель	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Оригинальные маски и LSTM	0.12 $\pm$ 0.02**	0.03 $\pm$ 0.01**	0.12 $\pm$ 0.02**	[0.09, 0.14]	[0.02, 0.04]	[0.09, 0.14]
Оригинальные маски и Attention	0.14 $\pm$ 0.04**	0.04 $\pm$ 0.03**	0.14 $\pm$ 0.04**	[0.11, 0.18]	[0.02, 0.07]	[0.11, 0.18]
Предложенная модель	0.61 $\pm$ 0.04	0.56 $\pm$ 0.03	0.61 $\pm$ 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Экспериментальные результаты, представленные в Таблице 11, показывают преимущество предложенной модели перед подходами на основе нейронных сетей, особенно в сценариях с ограниченной выборкой. Использование специфичных для классов масок из раздела 3.2.1, и TSM для кодирования позволяет модели эффективно улавливать как пространственные, так и временные характеристики данных фМРТ. Статистическая значимость, обозначенная $p\text{-value} < .005$, подтверждает гипотезу о том, что наблюдаемые улучшения метрик статистически значимы и маловероятно произошли случайно. Доверительные интервалы дают меру надежности этих оценок и подтверждают устойчивость улучшения качества модели.

3.4.6. Численная проверка оценки искажения расстояний

Предложение 3.3.9 утверждает, что константа $c(\rho)$ теоремы 3.3.8 неулучшаема, но достигается лишь в пределе. Предельный переход (3.19) проверен численно: для пар $\exp \mathbf{S}(\pm\theta/2)$ с $\omega = \sqrt{2}\rho$, $\rho \in \{1, 2, 4\}$ и опорной точкой $\bar{\mathbf{R}} = \mathbb{I}$ вычислено отношение $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j)/\|\mathbf{p}_i - \mathbf{p}_j\|_2$ в зависимости от угла поворота θ собственного базиса; результат показан на рис. 3.9. Отношение строго меньше $c(\rho)$ при всех $\theta > 0$ и стремится к $c(\rho)$ при $\theta \rightarrow 0$: при $\theta = 10^{-3}$ оно отличается от $c(\rho)$ менее чем на 10^{-4} , а при $\theta = \pi/2$, когда $\mathbf{S}_j = -\mathbf{S}_i$ и касательные векторы коммутируют, равно единице. Результат не зависит от h , поскольку при $h > 2$ пары отличаются от случая $h = 2$ нулевыми блоками.

3.4.7. Эксперименты на синтетических данных

На записях фМРТ истинные ковариации объектов неизвестны, а радиус облака объектов и длина сегмента заданы данными. Поэтому два вопроса, поставленных теорией раздела 3.3, проверены на синтетических данных, где эти величины задаются явно: дает ли учет геометрии многообразия выигрыш в точности по сравнению с методами, не согласованными с облаком объектов, и как




Рисунок 3.9 — Отношение геодезического расстояния к евклидову для пар предложения 3.3.9: касательные векторы с собственными значениями $\pm\rho/\sqrt{2}$, собственные базисы которых повернуты друг относительно друга на угол θ .

Пунктиром показана граница $c(\rho)$ теоремы 3.3.8

шум оценки ковариации по $\mathcal{T}$ отсчетам сказывается на точности в сравнении с границей теоремы 3.3.11.

Генеративная модель. Через $\mathbf{Z}$ обозначается случайная симметричная матрица размера $h \times h$, координаты $\text{vec}_{\sqrt{2}}(\mathbf{Z})$ которой независимы и имеют стандартное нормальное распределение. Для каждой задачи один раз разыгрываются опорная точка $\mathbf{R}_0 = \exp(\mathbf{Z}_0)$ и единичное направление разделения классов $\mathbf{U} = \mathbf{Z}_1 / \|\mathbf{Z}_1\|_F$. Центры двух классов

$$\mathbf{R}_{\pm} = \mathbf{R}_0^{1/2} \exp\left(\pm \frac{s}{2} \mathbf{U}\right) \mathbf{R}_0^{1/2}$$

лежат на геодезической, проходящей через $\mathbf{R}_0$, на расстоянии s друг от друга, а объект класса $\pm$ порождается как гауссово возмущение центра в отбеленных касательных координатах (3.9):

$$\mathbf{R}_i = \mathbf{R}_{\pm}^{1/2} \exp(\sigma \mathbf{Z}_i) \mathbf{R}_{\pm}^{1/2}, \quad \sigma = s/2. \quad (3.21)$$

Все масштабы модели пропорциональны s : в касательных координатах центра класса задача при разных s одна и та же, меняется только геодезический радиус облака, то есть вклад кривизны многообразия. В обучающую выборку входит по 100 объектов каждого класса, в тестовую — по 500; для каждого набора параметров разыграны десять задач с различными $\mathbf{R}_0$ и $\mathbf{U}$, по которым приводятся средние и стандартные отклонения.

Сравниваемые методы. Наряду с TSM, то есть признаками (3.14) в точке риманова среднего обучающей выборки и логистической регрессией, рассматриваются три метода. Лог-евклидова проекция (англ. log-Euclidean) [151] использует те же признаки с опорной точкой $\mathbb{I}$, то есть $\mathbf{p}_i = \text{vec}_{\sqrt{2}}(\log \mathbf{R}_i)$: геометрия многообразия учитывается, но опорная точка не согласована с облаком объектов. Евклидова векторизация (англ. Euclidean) подает в классификатор $\mathbf{p}_i = \text{vec}_{\sqrt{2}}(\mathbf{R}_i)$ и геометрию не учитывает. Классификатор по минимальному расстоянию до среднего (англ. Minimum Distance to Mean, MDM) [37] относит объект к классу, риманово среднее которого ближе по $\delta_{\mathcal{R}}$, и служит ориентиром, работающим на многообразии без касательной проекции. В методах с логистической регрессией коэффициент регуляризации единичный, как в разделе 3.4.3, а признаки умножаются на общий скалярный множитель, чтобы регуляризация действовала одинаково при любом масштабе облака; покоординатная стандартизация, нарушающая инвариантность по предложению 3.3.5, не применяется.

Учет геометрии. Параметр s меняется от 0,1 до 2,5 при $h = 8$, чему отвечают радиусы облака $\rho = \max_i \delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i)$ от 0,4 до 10. На рис. 3.10(а) показана точность методов на тестовой выборке, на рис. 3.10(б) — отношение $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) / \|\mathbf{p}_i - \mathbf{p}_j\|_2$ по всем парам обучающих объектов в сравнении с границами $c(\rho)$ и $g(\omega)$ теоремы 3.3.8. Точность TSM и MDM практически совпадает на всем диапазоне радиусов: касательная проекция в точке риманова среднего не теряет разделимости классов и тогда, когда гарантия теоремы 3.3.8 становится тривиальной. Рост точности с радиусом объясняется отрицательной кривизной многообразия: внутриклассовый разброс по построению (3.21) от кривизны не зависит, тогда как геодезическое расстояние между объектами разных классов растёт быстрее, чем линейно по s . Лог-евклидова проекция уступает TSM, и разрыв увеличивается с радиусом: облако удалено от $\mathbb{I}$, и касательные координаты в $\mathbb{I}$ связаны с координатами в $\bar{\mathbf{R}}$ анизотропным преобразованием. Евклидова векторизация существенно уступает методам, учитывающим геометрию многообразия, и ее точность с радиусом не растёт. Отношение расстояний для всех пар не меньше единицы, как и гарантирует пункт (б) теоремы 3.3.8, и остается много меньше границ: при наибольшем радиусе его максимум по парам близок к 1,5, тогда как граница $g(\omega)$ превышает 30. Для гауссовых облаков смещение между типичной парой объектов почти целиком приходится на компоненты, коммутирующие с касательными векторами, которые экспо-

ненциальное отображение не растягивает. После преобразования $\mathbf{A}\mathbf{R}_i\mathbf{A}^\top$ со случайной невырожденной матрицей $\mathbf{A}$ точность TSM и попарные расстояния между признаками совпали с исходными с точностью вычислений, в согласии с предложением 3.3.5.




Рисунок 3.10 — Зависимость от радиуса облака ρ при $h = 8$; средние и стандартные отклонения по десяти задачам. (а) Точность TSM, MDM, лог-евклидовой проекции и евклидовой векторизации на тестовой выборке. (б) Отношение геодезического расстояния между объектами к евклидову расстоянию между их признаками по всем парам обучающих объектов в сравнении с границами $c(\rho)$ и $g(\omega)$ теоремы 3.3.8

Шум оценки ковариаций. При $s = 0,5$ и $h \in \{8, 16\}$ истинные ковариации объектов обучающей и тестовой выборок заменены выборочными $\hat{\mathbf{R}}_i = \mathcal{T}^{-1}\mathbf{Y}_i\mathbf{Y}_i^\top$, где столбцы $\mathbf{Y}_i \in \mathbb{R}^{h \times \mathcal{T}}$ — независимые отсчеты с распределением $\mathcal{N}(\mathbf{0}, \mathbf{R}_i)$, в точности в условиях теоремы 3.3.11; число отсчетов $\mathcal{T}$ меняется от 20 до 1280. Признаки TSM и классификатор строятся по выборочным ковариациям, как и на реальных данных, а истинные ковариации используются только для вычисления ошибки $\delta_{\mathcal{R}}(\hat{\mathbf{R}}_i, \mathbf{R}_i)$, усредняемой по тестовым объектам, и эталонной точности TSM на тех же задачах. Граница (3.20) вычислена при уровне доверия 0,95 для тех $\mathcal{T}$, при которых она определена. Результаты показаны на рис. 3.11. Точность TSM растет с $\mathcal{T}$ и приближается к эталонной: при $\mathcal{T} = 20$ потеря точности заметна для обоих значений h , а при $\mathcal{T} \geq 320$ становится пренебрежимо малой. Средняя ошибка убывает как $\mathcal{T}^{-1/2}$ и пропорциональна h , в согласии с порядком $h/\sqrt{\mathcal{T}}$ оценки (3.20), а ее разброс между

задачами с различными ковариациями пренебрежимо мал, что отвечает пункту (а) теоремы 3.3.11. Граница превышает эмпирическую ошибку в несколько раз, но убывает с той же скоростью, то есть верно передает зависимость от h и $\mathcal{T}$ ценой постоянного множителя. Тем самым эксперимент подтверждает ограничение $h \ll \mathcal{T}$ при выборе числа вокселей в Алгоритме 1.




Рисунок 3.11 — Шум оценки ковариаций при $s = 0,5$. (а) Точность TSM на тестовой выборке при обучении на выборочных ковариациях в зависимости от числа отсчетов $\mathcal{T}$; пунктиром показана точность на истинных ковариациях. (б) Средняя ошибка $\delta_{\mathcal{R}}(\hat{\mathbf{R}}_i, \mathbf{R}_i)$ и граница теоремы 3.3.11 при уровне доверия 0,95

3.5. Обсуждение результатов

Экспериментальные результаты показали, что исключение отдельных компонентов предложенной модели значительно снижает качество классификации. Это показывает важность пространственно-временных характеристик, извлекаемых с помощью данной методологии, для достижения высокой точности классификации. Основное внимание в этой главе уделяется оценке качества классификации в условиях ограниченной выборки, где традиционные подходы демонстрируют низкую эффективность. Таким образом, предложенная методология представляет ценность для анализа и интерпретации нейронных данных, особенно в ситуациях с ограниченным объемом данных.

В сравнении с подходами на основе нейронных сетей предложенная методология показывает более высокие результаты. Нейронные сети часто требуют больших объемов данных для эффективного обучения зависимостей и паттернов. В то же время предложенный подход, использующий логистическую регрессию и перцептрон, демонстрирует лучшее качество декодирования на небольших объемах выборки. Это достигается за счет эффективного использования масок активности и отображения на касательное пространство, которые учитывают как пространственные, так и временные характеристики данных фМРТ.

Тем не менее, используемый набор данных является уникальным и содержит специфический набор временных точек стимуляции. Кроме того, небольшое количество пациентов может не полностью отражать разнообразие активности мозга. Валидация методологии на более крупных и разнообразных наборах данных, а также изучение альтернативных схем взвешивания для повышения производительности составляют направление дальнейшей работы. Несмотря на эти ограничения, полученные результаты уточняют представление о реакции человеческого мозга на внешние стимулы и служат основой для последующих исследований.

Глава 4. Мультимодальная реконструкция визуальных стимулов по сигналам фМРТ–ЭЭГ

В данной главе рассматривается третья постановка задачи декодирования, расширяющая построенное пространственно-временное описание на вторую модальность: по одновременным сигналам фМРТ и ЭЭГ реконструируются визуальные стимулы. Совместные представления модальностей контрастно выравниваются с CLIP-пространством, после чего реконструкция выполняется двухстадийной диффузионной генерацией. Результаты главы опубликованы в работах [42; 43].

Полный код реализации, использованный для получения результатов главы, доступен в открытом репозитории:

https://github.com/intsystems/CreationOfIntelligentSystems_Simultaneous_fmRI-EEG

4.1. Постановка задачи

Задан датасет триплетов (фМРТ, ЭЭГ, изображение):

$$\mathfrak{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y},$$

где $\mathbf{F}_i \in \mathcal{X}_f$ — фМРТ-скан; $\mathbf{E}_i \in \mathcal{X}_e \subseteq \mathbb{R}^{K \times T}$ — ЭЭГ-запись, где K — число каналов, T — длина временного окна; $\mathbf{I}_i \in \mathcal{Y} \subseteq \mathbb{R}^{H \times W \times C}$ — изображение с высотой H , шириной W и числом каналов C . Требуется построить отображение $\mathbf{f}$ из совместного пространства данных фМРТ–ЭЭГ в пространство изображений:

$$\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}.$$

4.2. Метод реконструкции

До появления недавних мультимодальных наборов данных с визуальными стимулами, таких как [146], обработка ЭЭГ и фМРТ, как правило, проводилась отдельно. Новые датасеты открывают возможность интегрировать оба

типа сигналов в единую архитектуру. По аналогии с предшествующими работами, в настоящей работе используется двухэтапный метод декодирования мозговой активности: 1) контрастивное выравнивание сигналов фМРТ и ЭЭГ с эмбедингами изображений; 2) обуславливание предобученной модели генерации изображений на уточненный априорной моделью эмбединг сигналов мозга.

На рис. 4.1 представлена схема декодирования изображений. Процесс строится из двух основных этапов: контрастивное обучение комбинированных представлений фМРТ–ЭЭГ сигналов и реконструкция стимулов. Предварительно записи ЭЭГ приводятся к фиксированному набору каналов восстановлением отсутствующих электродов, описанным в разделе 4.2.1.

4.2.1. Восстановление отсутствующих каналов ЭЭГ

На этапе предобработки решается задача восстановления пропусков в записях ЭЭГ: сигналы незарегистрированных электродов восстанавливаются методами пространственной интерполяции на основе данных ближайших доступных каналов и известной геометрии расположения датчиков.

Полный набор электродов системы регистрации включает K каналов. Каждому каналу $\{c_k\}_{k=1}^K$ соответствуют фиксированные пространственные координаты $\mathbf{p}_k \in \mathbb{R}^3$ на поверхности скальпа. Множество фактически зарегистрированных каналов в i -й записи обозначим как $\mathcal{C}_i \subseteq \{c_1, \dots, c_K\}$, $i = 1, \dots, N$. От записи к записи набор отсутствующих каналов меняется, поэтому ограничиваться лишь общим для всех записей подмножеством каналов нельзя — это привело бы к существенной потере информации. При этом энкодер ЭЭГ $\mathcal{E}_e$ принимает на вход тензор фиксированной размерности, без чего невозможна обработка обучающей выборки батчами. Отсюда и вытекает необходимость восстановить сигналы недостающих каналов до полного набора.

Для упрощения нотации далее рассматривается единичная запись ЭЭГ $\mathbf{E}$, при этом индекс i объекта выборки опускается. Обозначим через $\mathcal{C} \subseteq \{c_1, \dots, c_K\}$ — подмножество каналов, для которых доступны временные ряды $\mathbf{e}_k \in \mathbb{R}^T$. Таким образом, наблюдаемая часть записи задается как $\mathbf{E} = \{\mathbf{e}_k\}_{k \in \mathcal{C}}$. Для унификации формата данных каждому отсутствующему каналу $c_k \notin \mathcal{C}$ назначается восстановленный сигнал $\hat{\mathbf{e}}_k \in \mathbb{R}^T$, рассчитываемый как взвешенное

среднее значений n пространственно ближайших зарегистрированных электродов:

$$\hat{\mathbf{e}}_k = \sum_{j \in \mathcal{S}_k} w_{kj} \mathbf{e}_j, \quad \sum_{j \in \mathcal{S}_k} w_{kj} = 1, \quad (4.1)$$

где $\mathbf{e}_j \in \mathbb{R}^T$ — временной ряд канала c_j ; $\mathcal{S}_k$ — множество индексов n ближайших к c_k доступных электродов, определяемое в соответствии с выбранной пространственной метрикой; $w_{kj} \geq 0$ — неотрицательные нормированные веса. В исследовании рассматриваются четыре стратегии определения весов $\{w_{kj}\}$ и формирования множества соседей $\mathcal{S}_k$:

- **Zero**, нулевое заполнение: базовый метод, при котором отсутствующий сигнал заменяется нулевым вектором:

$$\hat{\mathbf{e}}_k = \mathbf{0} \in \mathbb{R}^T.$$

- **NN**, метод одного ближайшего соседа (англ. Nearest Neighbor, NN): сигнал отсутствующего канала заменяется сигналом ближайшего зарегистрированного электрода:

$$\hat{\mathbf{e}}_k = \mathbf{e}_{j^*}, \quad j^* = \arg \min_{j: c_j \in \mathcal{C}} \rho_{\text{eucl}}(c_k, c_j), \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

что соответствует $n = 1$ и $w_{kj^*} = 1$ в (4.1).

- **KNN-Euclidean**, метод ближайших соседей (англ. k -Nearest Neighbors, KNN): взвешенное усреднение по n ближайшим соседям в евклидовой метрике; веса определяются как величины, обратно пропорциональные расстоянию между электродами:

$$w_{kj} = \frac{1/\rho_{\text{eucl}}(c_k, c_j)}{\sum_{l \in \mathcal{S}_k} 1/\rho_{\text{eucl}}(c_k, c_l)}, \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

- **KNN-Spherical**: то же взвешенное усреднение по n ближайшим соседям, но в сферической метрике — евклидово расстояние здесь заменено геодезическим вдоль поверхности скальпа, которая аппроксимируется сферой радиуса R :

$$\rho_{\text{sph}}(c_k, c_j) = R \cdot \arccos\left(\frac{\langle \mathbf{p}_k, \mathbf{p}_j \rangle}{\|\mathbf{p}_k\|_2 \|\mathbf{p}_j\|_2}\right),$$

веса при этом полагаются $w_{kj} \propto 1/\rho_{\text{sph}}(c_k, c_j)$ и затем нормируются: $\sum_{j \in \mathcal{S}_k} w_{kj} = 1$.

Выполнение процедуры (4.1) для всех отсутствующих каналов приводит запись ЭЭГ к единому матричному виду $\mathbf{E} \in \mathbb{R}^{K \times T}$ с фиксированным числом каналов K . Тем самым размерность входного тензора согласуется с архитектурой энкодера $\mathcal{E}_e$, что и делает возможной последующую батчевую обработку.

Вероятностное обобщение: маскированное согласование потоков.

Интерполяция (4.1) дает точечную оценку пропущенного сигнала и использует только пространственную близость электродов. Ниже она достраивается до вероятностной модели, которая восстанавливает условное распределение пропусков при наблюдаемой части записи. Модель строится на согласовании потоков (англ. flow matching) [152]: непрерывный нормализующий поток [153] переносит гауссовский шум в данные, а обучается регрессией на условное векторное поле, без решения дифференциальных уравнений на этапе обучения.

Введем бинарную маску наблюдаемости $\mathbf{M} \in \{0,1\}^{K \times T}$, где $M_{k,t} = 1$ для зарегистрированных значений, и ее дополнение $\bar{\mathbf{M}} = \mathbf{1} - \mathbf{M}$; при выпадении канала c_k нулевой является вся строка k . Наблюдаемая и пропущенная части записи равны $\mathbf{E}_{\text{obs}} = \mathbf{M} \odot \mathbf{E}$ и $\mathbf{E}_{\text{miss}} = \bar{\mathbf{M}} \odot \mathbf{E}$, где $\odot$ — произведение Адамара. Геометрия монтажа задана матрицей расстояний $\mathbf{D} \in \mathbb{R}^{K \times K}$, $D_{kj} = \rho(c_k, c_j)$. Требуется по $(\mathbf{E}_{\text{obs}}, \mathbf{M}, \mathbf{D})$ восстановить условное распределение $p(\mathbf{E}_{\text{miss}} | \mathbf{E}_{\text{obs}}, \mathbf{M})$. Обучающая выборка состоит из окон записей; маски при обучении семплируются независимо от сигнала из распределения, воспроизводящего типичные сценарии: выпадение целых каналов и короткие артефактные блоки [154].

Маскированный путь и функция потерь. Пусть $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbb{I})$ — гауссовский шум той же размерности, что и запись, не зависящий от $(\mathbf{E}, \mathbf{M})$. Состояние в генеративное время $t \in [0,1]$ определяется по координатно: наблюдаемые значения неподвижны, а пропущенные движутся по отрезку от шума к данным,

$$\mathbf{E}_t = \mathbf{M} \odot \mathbf{E} + \bar{\mathbf{M}} \odot ((1-t)\boldsymbol{\varepsilon} + t\mathbf{E}). \quad (4.2)$$

Производная состояния по t равна $\bar{\mathbf{M}} \odot (\mathbf{E} - \boldsymbol{\varepsilon})$ и обращается в нуль на наблюдаемых позициях. Векторное поле $v_\theta(\mathbf{E}_t, t, \mathbf{E}_{\text{obs}}, \mathbf{M}; \mathbf{D})$ задается нейросетью и обучается регрессией на это приращение по пропущенным позициям:

$$\mathcal{L}_{\text{imp}}(\theta) = \mathbb{E}_{t, \mathbf{E}, \mathbf{M}, \boldsymbol{\varepsilon}} \left\| \bar{\mathbf{M}} \odot (v_\theta(\mathbf{E}_t, t, \mathbf{E}_{\text{obs}}, \mathbf{M}; \mathbf{D}) - (\mathbf{E} - \boldsymbol{\varepsilon})) \right\|_F^2, \quad t \sim \mathcal{U}[0,1]. \quad (4.3)$$

Наблюдаемая часть записи входит в модель дважды: как неподвижные координаты состояния и как условие во входах сети. Сеть состоит из блоков,

чередующих свертку вдоль времени в каждом канале и внимание по каналам; в логиты внимания расстояния между электродами входят аддитивным смещением $B_{kj} = f_\phi(D_{kj})$, где f_ϕ — небольшой перцептрон, общий для всех пар электродов, что дает модели индуктивное смещение в пользу физически близких электродов.

Генерация. Восстановление записи с наблюдаемой частью $\mathbf{E}_{\text{obs}}^*$ и маской $\mathbf{M}^*$ есть численное интегрирование обыкновенного дифференциального уравнения

$$\frac{d\mathbf{E}_t}{dt} = \bar{\mathbf{M}}^* \odot v_\theta(\mathbf{E}_t, t, \mathbf{E}_{\text{obs}}^*, \mathbf{M}^*; \mathbf{D}), \quad \mathbf{E}_0 = \mathbf{E}_{\text{obs}}^* + \bar{\mathbf{M}}^* \odot \boldsymbol{\varepsilon}, \quad t: 0 \rightarrow 1, \quad (4.4)$$

методом Эйлера. Умножение поля на $\bar{\mathbf{M}}^*$ гарантирует, что наблюдаемые значения не меняются, поэтому состояния генерации лежат в том же множестве, что и обучающие состояния (4.2). Конечное состояние $\mathbf{E}_1$ есть восстановленная запись; повторение с независимыми реализациями $\boldsymbol{\varepsilon}$ дает ансамбль восстановлений, покоординатная медиана которого служит точечной оценкой, а разброс — оценкой неопределенности восстановления.

Корректность. Следующая теорема показывает, что при точном векторном поле процедура (4.4) восстанавливает именно условное распределение пропусков. Зафиксируем $(\mathbf{E}_{\text{obs}}, \mathbf{M})$ и обозначим через $\boldsymbol{\xi}_1 \in \mathbb{R}^m$ вектор пропущенных значений, где m — их число, с распределением $p(\cdot \mid \mathbf{E}_{\text{obs}}, \mathbf{M})$, а через $\boldsymbol{\xi}_0 \sim \mathcal{N}(\mathbf{0}, \mathbb{I}_m)$ — не зависящий от него вектор шума на тех же позициях. Положим $\boldsymbol{\xi}_t = (1 - t)\boldsymbol{\xi}_0 + t\boldsymbol{\xi}_1$ и

$$v^*(\boldsymbol{\xi}, t) = \mathbb{E}[\boldsymbol{\xi}_1 - \boldsymbol{\xi}_0 \mid \boldsymbol{\xi}_t = \boldsymbol{\xi}], \quad \boldsymbol{\xi} \in \mathbb{R}^m, \quad t \in [0, 1]. \quad (4.5)$$

Теорема 4.2.1. Пусть $\mathbb{E}\|\boldsymbol{\xi}_1\|_2 < \infty$, а поле (4.5) непрерывно по $(\boldsymbol{\xi}, t)$ и липшицево по $\boldsymbol{\xi}$ равномерно по t . Тогда

- (а) поле v^* есть минимизатор функции потерь (4.3) по всем измеримым функциям состояния, времени и условия $(\mathbf{E}_{\text{obs}}, \mathbf{M})$;
- (б) решение уравнения $\dot{\boldsymbol{\xi}}(t) = v^*(\boldsymbol{\xi}(t), t)$ с начальным условием $\boldsymbol{\xi}(0) = \boldsymbol{\xi}_0$ существует, единственно и $\boldsymbol{\xi}(1) \sim p(\cdot \mid \mathbf{E}_{\text{obs}}, \mathbf{M})$; это уравнение есть ограничение (4.4) на пропущенные позиции при $v_\theta = v^*$.

Доказательство. (а) При фиксированных условии и времени t слагаемые функции потерь (4.3) на наблюдаемых позициях обнулены маской $\bar{\mathbf{M}}$, а пропущенные позиции состояния (4.2) образуют вектор $\boldsymbol{\xi}_t$. Поэтому функция потерь

есть среднеквадратичная ошибка предсказания вектора $\xi_1 - \xi_0$ по наблюдению ξ_t . Среди всех измеримых функций наблюдения среднеквадратичную ошибку минимизирует условное математическое ожидание (4.5), единственное с точностью до множества нулевой вероятности; усреднение по t и по условию не меняет минимизатора, поскольку оба подаются сети на вход.

(б) Процесс ξ_t линеен по t : $\dot{\xi}_t = \xi_1 - \xi_0$, причем $\xi_0 \sim \mathcal{N}(\mathbf{0}, \mathbb{I}_m)$ и $\xi_1 \sim p(\cdot \mid \mathbf{E}_{\text{obs}}, \mathbf{M})$. Пусть q_t — распределение ξ_t . Для любой гладкой финитной функции φ

$$\frac{d}{dt} \mathbb{E} \varphi(\xi_t) = \mathbb{E} \langle \nabla \varphi(\xi_t), \xi_1 - \xi_0 \rangle = \mathbb{E} \langle \nabla \varphi(\xi_t), v^*(\xi_t, t) \rangle,$$

где второе равенство следует из определения условного ожидания (4.5), а дифференцирование под знаком ожидания законно в силу $\mathbb{E} \|\xi_1 - \xi_0\|_2 < \infty$ и ограниченности $\nabla \varphi$. Значит, семейство $(q_t)_{t \in [0,1]}$ является слабым решением уравнения непрерывности $\partial_t q_t + \nabla \cdot (q_t v^*(\cdot, t)) = 0$ с начальным условием $q_0 = \mathcal{N}(\mathbf{0}, \mathbb{I}_m)$. Поле v^* липшицево по ξ и непрерывно по t , поэтому уравнение $\dot{\xi} = v^*(\xi, t)$ имеет единственное решение $\xi(t) = \Phi_t(\xi(0))$ при любом начальном условии, и образ $(\Phi_t)_\# q_0$ начального распределения также является слабым решением того же уравнения непрерывности с тем же начальным условием. Для липшицевых полей слабое решение уравнения непрерывности единственно в классе слабо непрерывных семейств вероятностных мер [155, гл. 8], откуда $(\Phi_t)_\# q_0 = q_t$ при всех t . При $t = 1$ получаем $\xi(1) = \Phi_1(\xi_0) \sim q_1$, а q_1 — распределение ξ_1 , то есть $p(\cdot \mid \mathbf{E}_{\text{obs}}, \mathbf{M})$. Наконец, на наблюдаемых позициях правая часть (4.4) равна нулю, а на пропущенных при $v_\theta = v^*$ совпадает с v^* , что и дает последнее утверждение. $\square$

В экспериментах настоящей главы записи ЭЭГ приводятся к полному набору каналов детерминированным восстановлением (4.1); вероятностная модель описана как его обобщение, и ее применение к записям ЭЭГ составляет предмет дальнейшей работы.

4.2.2. Контрастивное обучение комбинированных представлений

Энкодер сигналов фМРТ–ЭЭГ. Архитектура энкодера состоит из трех модулей: энкодера фМРТ, энкодера ЭЭГ и модуля объединения. Для обес-




Рисунок 4.1 — Схема декодирования изображений на основе сигналов фМРТ-ЭЭГ. Процесс декодирования реализуется в два этапа. На первом этапе проводится контрастное обучение энкодера сигналов фМРТ-ЭЭГ, в ходе которого представления мозговых сигналов выравниваются с замороженными эмбедингами изображений, полученными с помощью модели CLIP. На втором этапе осуществляется двухстадийная генерация реконструкций: сначала обучается диффузионная априорная модель для уточнения эмбедингов сигналов мозга, а затем предобученная диффузионная модель, обусловленная на CLIP-эмбедингами, генерирует реконструкции изображений

печения персонализированного представления мозговой активности каждый модуль включает индивидуализирующие компоненты, позволяющие явно моделировать межсубъектные различия — критически важный аспект при работе с нейросигналами. Архитектуры энкодеров фМРТ и ЭЭГ изображены на рис. 4.2.

Энкодер ЭЭГ. Энкодер ЭЭГ через конкатенацию объединяет исходные многоканальные данные с индивидуальными обучаемыми эмбедингами пациентов, получая единое векторное представление. Архитектура энкодера включает последовательность трех сверточных слоев: одномерную свертку по временному измерению, одномерную свертку по каналам, то есть по пространству, и свертку для сжатия в вектор. Полученный эмбединг пропускается через голову в виде многослойного перцептрона (англ. Multilayer Perceptron, MLP), формируя итоговое представление. Формально, для батча данных ЭЭГ $\mathbf{E} \in \mathbb{R}^{B \times K \times T}$ энкодер

$\mathcal{E}_e$ генерирует эмбединги:

$$\mathbf{Z}_e = \mathcal{E}_e(\mathbf{E}) \in \mathbb{R}^{B \times d_e},$$

где d_e — размерность латентного пространства ЭЭГ.

Предобработка фМРТ. Из всего объема $X \times Y \times Z$ вокселей лишь относительно небольшая часть несет информацию о реакции мозга на визуальный стимул: значительную долю занимают фоновые воксели, значения которых либо близки к нулю, либо стабильны во времени и не зависят от стимула. Прямая подача всего тензора в обучаемую модель приводит к расточительной параметризации и снижает отношение сигнал/шум. Поэтому на этапе предобработки строится индивидуальная для каждого пациента бинарная маска, выделяющая только информативные воксели.

Пусть $F_{xyz}(t)$ — значение вокселя с координатами (x, y, z) в момент t временного ряда фМРТ длиной $\mathcal{T}$. Для каждого вокселя вычисляется суммарная абсолютная разность значений между соседними кадрами:

$$m_{xyz} = \sum_{t=2}^{\mathcal{T}} |F_{xyz}(t) - F_{xyz}(t-1)|.$$

Величина m_{xyz} интерпретируется как накопленная во времени вариация сигнала в данном вокселе: для фоновых вокселей m_{xyz} близка к нулю, для активно реагирующих на стимул — существенно положительна. К одномерному распределению величин $\{m_{xyz}\}$ применяется метод Оцу [156], автоматически подбирающий порог между фоновыми и информативными вокселями. Алгоритм перебирает все допустимые пороги θ , разбивая при каждом из них воксели на два класса — $C_0(\theta) = \{(x, y, z) : m_{xyz} \leq \theta\}$ и $C_1(\theta) = \{(x, y, z) : m_{xyz} > \theta\}$ — с долями $\omega_0(\theta)$, $\omega_1(\theta) = 1 - \omega_0(\theta)$ и средними $\mu_0(\theta)$, $\mu_1(\theta)$. Межклассовая дисперсия имеет вид

$$\sigma^2(\theta) = \omega_0(\theta) \omega_1(\theta) [\mu_0(\theta) - \mu_1(\theta)]^2,$$

оптимальным же считается порог, доставляющий ей максимум:

$$\theta^* = \arg \max_{\theta} \sigma^2(\theta).$$

Найденный порог задает бинарную маску

$$\mathcal{M}_{xyz} = \mathbb{1}\{m_{xyz} > \theta^*\}, \quad \mathcal{M} \in \{0, 1\}^{X \times Y \times Z}, \quad (4.6)$$

свою для каждого пациента; число информативных вокселей $\sum_{xyz} \mathcal{M}_{xyz}$ определяется анатомией и индивидуальной динамикой BOLD-сигнала. После этого для каждого фМРТ-скана $\mathbf{F}$ воксели со значением $\mathcal{M}_{xyz} = 1$ собираются в плотный вектор.

Энкодер фМРТ. Индивидуальные особенности пациентов энкодер фМРТ учитывает с помощью персонализированной линейной проекции. Вектор информативных вокселей, отобранных по бинарной маске $\mathcal{M}$, пропускается через индивидуальный для каждого пациента линейный слой, проецирующий признаки в общее латентное пространство размерности 4096. Завершающим этапом является обработка эмбедингов через MLP с остаточными соединениями. Формально, для батча данных фМРТ $\mathbf{F} \in \mathbb{R}^{B \times X \times Y \times Z}$ энкодер $\mathcal{E}_f$ преобразует исходный тензор в латентное представление:

$$\mathbf{Z}_f = \mathcal{E}_f(\mathbf{F}) \in \mathbb{R}^{B \times d_f},$$

где d_f — размерность латентного пространства фМРТ.

Модуль объединения. Полученные эмбединги $\mathbf{Z}_e$ и $\mathbf{Z}_f$ подаются на вход обучаемого модуля объединения $\mathcal{F}$, который интегрирует высокочастотную информацию из ЭЭГ и пространственно детализированные данные фМРТ, формируя совместные эмбединги:

$$\mathbf{Z}_c = \mathcal{F}(\mathbf{Z}_f, \mathbf{Z}_e) \in \mathbb{R}^{B \times d}.$$

В данной работе модуль объединения реализован как конкатенация эмбедингов с последующей обработкой через MLP для извлечения совместных представлений. В качестве альтернативной реализации $\mathcal{F}$ также рассматривалось скользящее усреднение эмбедингов модальностей вида

$$\mathbf{Z}_c = \alpha \mathbf{Z}_f + (1 - \alpha) \mathbf{Z}_e, \quad \alpha \in [0, 1],$$

где α — обучаемый скалярный параметр, балансирующий вклад фМРТ- и ЭЭГ-модальностей. Сравнительный анализ показал, что MLP более эффективно выделяет совместные признаки из пространств фМРТ–ЭЭГ, поэтому именно эта конфигурация принята в качестве основной.




Рисунок 4.2 — Архитектуры кодировщиков фМРТ и ЭЭГ. *Слева:* энкодер ЭЭГ интегрирует индивидуальные обучаемые эмбединги пациентов с исходными многоканальными данными посредством конкатенации, формируя единое векторное представление; далее применяются одномерные свертки по временному и каналному измерениям, а также MLP-голова для генерации итоговых эмбедингов. *Справа:* энкодер фМРТ включает персонализированное маскирование мозга, векторизацию вокселей и проекцию в латентное пространство через индивидуальный линейный слой; завершающая обработка осуществляется с использованием MLP с остаточными соединениями

Эмбединги изображений. Для извлечения визуальных эмбедингов используется предобученная модель CLIP ViT-H/14 [122], которая генерирует эмбединги изображений $\mathbf{Z}_I \in \mathbb{R}^{B \times d}$. Данная модель обеспечивает высококачественные, семантически насыщенные и хорошо обобщающиеся эмбединги, а также совместима с множеством генеративных моделей, предобученных на CLIP-пространстве.

Контрастивное обучение энкодера сигналов мозга. Основной целью контрастивного обучения является сопоставление нейронных представлений фМРТ–ЭЭГ с визуальными эмбедингами, извлеченными с помощью замороженного энкодера CLIP, как показано на рис. 4.1. Обучение происходит на триплетах (фМРТ, ЭЭГ, изображение) и включает оптимизацию трех ключевых компонентов: энкодера фМРТ $\mathcal{E}_f$, энкодера ЭЭГ $\mathcal{E}_e$ и модуля объединения $\mathcal{F}$. Для вычисления логитов близости используется косинусное расстояние меж-

ду нормированными эмбедингами:

$$\mathbf{z}_I^n = \frac{\mathbf{z}_I}{\|\mathbf{z}_I\|}, \quad \mathbf{z}_c^n = \frac{\mathbf{z}_c}{\|\mathbf{z}_c\|},$$

где $\mathbf{z}_I$ — эмбединги изображений, полученные с помощью замороженного CLIP, а $\mathbf{z}_c$ — объединенные эмбединги фМРТ–ЭЭГ. Матрица логитов $\mathbf{L}$ вычисляется как

$$\mathbf{L} = \mathbf{z}_I^n (\mathbf{z}_c^n)^\top \cdot e^\tau,$$

где τ — обучаемый параметр температуры. В процессе контрастивного обучения рассматриваются все возможные пары «объединенный эмбединг мозга — эмбединг изображения» для максимизации эффективности обучения. Важной особенностью подхода является наличие большого числа негативных примеров, что позволяет модели не только корректно сопоставлять положительные пары, но и четко различать негативные. Как показано на рис. 4.3, при размере батча B формируется матрица логитов размером $B \times B$, где лишь B пар, расположенных на главной диагонали, являются положительными соответствиями.

Функция потерь основывается на симметричной контрастивной оптимизации, аналогичной подходу CLIP [122], и представляет собой усредненную сумму двух кросс-энтропийных потерь:

$$\mathcal{L}_{\text{contr}} = -\frac{1}{2B} \sum_{b=0}^{B-1} \left[\log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{j=0}^{B-1} \exp(\mathbf{L}_{bj})} \right) + \log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{i=0}^{B-1} \exp(\mathbf{L}_{ib})} \right) \right],$$

где $\mathbf{L}_{ij}$ обозначает элемент матрицы логитов $\mathbf{L}$ на позиции (i, j) .

4.2.3. Процесс реконструкции стимулов

Вводится совместное распределение изображений $\mathbf{x}$ и их скрытых визуальных представлений $\mathbf{z}_I$ при условии комбинированных нейронных эмбедингов $\mathbf{z}_c$:

$$p(\mathbf{x}, \mathbf{z}_I \mid \mathbf{z}_c) \propto p(\mathbf{z}_I \mid \mathbf{z}_c) p(\mathbf{x} \mid \mathbf{z}_I).$$

Здесь $p(\mathbf{z}_I \mid \mathbf{z}_c)$ моделирует согласование комбинированного представления фМРТ–ЭЭГ с высокоуровневым визуальным пространством CLIP на стадии I, а $p(\mathbf{x} \mid \mathbf{z}_I)$ описывает генерацию изображения при условии уточненного визуального эмбединга на стадии II.

Контрастивное предварительное обучение




Рисунок 4.3 — Иллюстрация контрастивного обучения и формирования батчей. Отрицательные примеры формируются автоматически. Косинусные расстояния между эмбедингами замороженного CLIP и нейронными эмбедингами используются в качестве логитов

Стадия I: диффузионная модель в пространстве CLIP. В пространстве визуальных эмбедингов CLIP обучается легкая диффузионная модель вида

$$\epsilon_{\theta}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c),$$

где $\mathbf{z}_I^{(t)}$ — зашумленная версия истинного эмбединга $\mathbf{z}_I$ на шаге t прямого диффузионного процесса, а $\mathbf{z}_c$ — комбинированный эмбединг, полученный модулем слияния. Обучение осуществляется по методу DDPM (англ. Denoising Diffusion Probabilistic Models, вероятностные диффузионные модели расшумления) [157] с функцией потерь

$$\mathcal{L}_{\text{prior}}(\theta) = \mathbb{E}_{\mathbf{z}_I, \mathbf{z}_c, t, \epsilon} \left\| \epsilon - \epsilon_{\theta}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c) \right\|_2^2.$$

На инференсе априорная диффузионная модель генерирует оценку $\hat{\mathbf{z}}_I \approx \mathbf{z}_I$ итеративной процедурой расшумления, согласующей $\mathbf{z}_c$ с визуальным пространством CLIP. Кодировщики $\mathcal{E}_f$, $\mathcal{E}_e$ и модуль слияния $\mathcal{F}$ остаются замороженными, что упрощает схему и стабилизирует обучение.

Стадия II: генерация изображения при условии $\hat{\mathbf{z}}_I$. Для реконструкции изображения используется предобученная латентно-диффузионная модель SDXL [138]:

$$\varepsilon_{\boldsymbol{\varphi}}(\mathbf{x}^{(t)}, t, h(\hat{\mathbf{z}}_I)),$$

где $\mathbf{x}^{(t)}$ — зашумленный латент изображения, а $h(\cdot)$ — проекционный адаптер IP-Adapter [139], переводящий $\hat{\mathbf{z}}_I$ в формат условия, совместимый с SDXL. Модель $\boldsymbol{\varphi}$ не дообучается.

Итоговый процесс реконструкции.

1. Контрастивное обучение из раздела 4.2.2 выравнивает $\mathbf{z}_c$ с $\mathbf{z}_I$.
2. Априорная диффузионная модель генерирует согласованное визуальное представление $\hat{\mathbf{z}}_I$ по $\mathbf{z}_c$.
3. Предобученная SDXL, обусловленная через $h(\hat{\mathbf{z}}_I)$, синтезирует изображение $\hat{\mathbf{x}}$.

4.3. Вычислительный эксперимент

В данном разделе проводится эмпирическая оценка метода, предложенного в разделе 4.2. Раздел 4.3.1 описывает характеристики используемого датасета, параметры регистрации сигналов и процедуры предобработки, включая восстановление отсутствующих каналов ЭЭГ и построение индивидуальных масок мозга для фМРТ. В разделе 4.3.2 приведены архитектурные детали и гиперпараметры энкодеров для каждой модальности, а также модуля объединения эмбеддингов. Раздел 4.3.3 содержит результаты вычислительных экспериментов: качественный анализ реконструкций и количественную оценку через метрику CLIP-Score. Ограничения предложенного метода обсуждаются в разделе 4.3.4.

4.3.1. Данные

В работе используется открытый датасет с одновременной регистрацией фМРТ и ЭЭГ при предъявлении визуальных стимулов [146]. Данные собраны у 22 здоровых пациентов в возрасте 23–51 года в ходе двух сканирований. Эксперимент включает записи в состоянии покоя, при просмотре мерцающего шахматного поля, абстрактной анимации *Inscapes* — компьютерно сгенерированной последовательности трехмерных фигур с плавными переходами — а также коротких видеороликов, представляющих натуралистические стимулы: фрагменты мультфильмов *The Present* и *Despicable Me*, а также фрагменты фильмов с обезьянами. Все визуальные стимулы демонстрируются в естественном, натуралистическом формате, что способствует высокой межсубъектной корреляции и устойчивости нейронных откликов. Синхронизация ЭЭГ и фМРТ достигается через запись триггеров сканера в ЭЭГ-поток. Предобработка ЭЭГ включает удаление градиентных и кардиобаллистических артефактов, полосовую фильтрацию и усредненное реферирование. Для фМРТ применяется стандартная коррекция движения, сглаживание и нормализация. Параметры регистрации сведены в Таблице 12.

Исходно данные поступают в виде трех асинхронных потоков: временные ряды фМРТ, временные ряды ЭЭГ и видеозапись стимулов. Регистрация ведется синхронно, однако частоты дискретизации у модальностей различны: фМРТ обновляется с частотой 0,476 Гц, ЭЭГ записывается с частотой 5000 Гц, а видеостимул образует непрерывный поток кадров. У каждого сигнала есть и собственные артефакты, у ЭЭГ градиентные и кардиобаллистические, у фМРТ двигательные, а набор доступных электродов у разных пациентов неодинаков; в совокупности это исключает прямую подачу сырых записей на батчевое обучение нейросетевой модели. Поэтому первый шаг предобработки — разбиение записей на согласованные триплеты $(\mathbf{F}, \mathbf{E}, \mathbf{I})$. С учетом гемодинамического лага $\Delta t = 5$ с, согласующегося с физиологическим диапазоном и результатом главы 2, каждому фМРТ-тензору в момент времени t ставятся в соответствие окно ЭЭГ и кадр видеостимула, отвечающие моменту $t - \Delta t$. Видеопоток предварительно разбивается на кадры с частотой 3 кадра в секунду (англ. Frames Per Second, FPS), а ЭЭГ-сигнал сегментируется на матрицы размера (K, T) , где K — число каналов, а T — длина временного окна.

Параллельно с временной синхронизацией проводится пространственная предобработка, важная для снижения размерности и стандартизации входных тензоров. Чтобы снизить размерность фМРТ и убрать фоновые воксели, для каждого пациента строится индивидуальная маска мозга (4.6): вычисляется суммарное абсолютное изменение сигнала во времени по каждому вокселю, и к полученному тензору применяется метод Оцу [156] для автоматического выбора порога. Результат — бинарная маска мозга, отделяющая воксели мозга от фона. Пример применения маски мозга на срезы снимка фМРТ показан на рис. 4.4. Важный этап подготовки данных — приведение записей ЭЭГ к фиксированному набору каналов. Монтаж набора данных [146] включает $K = 61$ кортикальный электрод. Расположение электродов на скальпе согласно системе 10–20 показано на рис. 4.5. Однако в ряде записей часть каналов отсутствует, в результате чего количество доступных каналов $|\mathcal{C}_i| \geq 50$ варьируется. Пересечение множеств доступных каналов для всей выборки оказывается пустым ($\bigcap_i \mathcal{C}_i = \emptyset$), поскольку не существует канала, присутствующего без исключений во всех элементах выборки. Следовательно, использование общего для всех записей подмножества каналов невозможно, что обуславливает необходимость восстановления отсутствующих сигналов до полного набора из $K = 61$ канала согласно методу, описанному в разделе 4.2.1, см. (4.1). Для выбора оптимальной стратегии восстановления проведено сравнение четырех методов: нулевого заполнения, интерполяции по ближайшему соседу и двух вариантов метода k -ближайших соседей с евклидовой и сферической метриками. Качество интерполяции оценивалось по среднеквадратичной ошибке (англ. Mean Squared Error, MSE) восстановления сигнала, рассчитанной независимо для каждого канала. Результаты представлены на рис. 4.6, где по оси абсцисс отложен индекс канала, а по оси ординат — значение ошибки.

Таблица 12 — Описание оборудования и основные параметры нейросигналов

Модальность	Оборудование	Частота дискретизации	Каналы
ЭЭГ	Brain Products BrainCap MR	5000 Гц	61 кортикальный электрод
фМРТ	Siemens 3.0 T TIM Trio	0,476 Гц	12-канальная головная катушка




Рисунок 4.4 — Для снижения размерности данных фМРТ применяются маски головного мозга, исключаяющие фоновые воксели, не несущие информации о визуальном стимуле. Маски формируются на основе анализа наиболее изменчивых вокселей в ответ на стимуляцию. Воксели, включенные в маску, выделены красным цветом

4.3.2. Параметры энкодеров

В экспериментах использовались две специализированные архитектуры, адаптированные под особенности каждой модальности. Энкодер фМРТ начинается с персонализированной линейной проекции: для каждого пациента воксели, отобранные с помощью индивидуальной бинарной маски, проецируются в пространство размерности 4096 обучаемым линейным слоем. За этим следует остаточный многослойный перцептрон, состоящий из трех полносвязных преобразований: первый расширяет представление до 2048, второй сохраняет эту размерность, а третий сжимает до 1024. Между слоями применяются нелинейность GELU (англ. Gaussian Error Linear Unit) и нормализация по слою; к выходу каждого блока добавляется остаточное соединение от входа. Доля прореживания (англ. dropout) во всех слоях равна 0,1.

Для обработки ЭЭГ-сигналов применялся компактный энкодер. Входные данные имеют размер 61×525 , где 60 каналов соответствуют кортикальным электродам, а один дополнительный канал — обучаемому эмбедингу пациента. Архитектура включает три последовательные свертки: временная свертка с ядром (1, 32) и 256 фильтрами, пространственная свертка с ядром (61, 1) и 512 фильтрами, а также глобальная свертка с ядром (1, 525) и 1024 фильтрами. После свертки следует MLP-проектор, реализующий преобразование




Рисунок 4.5 — Конфигурация монтажа из $K = 61$ кортикального электрода, используемая в датасете [146]. Датчики расположены согласно системе 10–20. Данная схема используется для восстановления отсутствующих каналов методом k -ближайших соседей, описанным в разделе 4.2.1.

$1024 \rightarrow 2048 \rightarrow 1024$ с нелинейностью GELU и нормализацией по слою (англ. Layer Normalization, LayerNorm). Доля прореживания во всех сверточных и проекционных слоях равна 0,1. Выходной эмбединг имеет размерность 1024, что обеспечивает совместимость с модулем слияния и CLIP-пространством.

Модуль объединения эмбедингов фМРТ и ЭЭГ реализован как двухслойный MLP: первый слой расширяет конкатенированное представление (размерность 2048) до 4096, второй сжимает его обратно до целевой размерности 1024. Активация — GELU, доля прореживания — 0,1. Выходной эмбединг лежит в CLIP-пространстве и подается как условие при генерации изображений.




Рисунок 4.6 — Сравнение стратегий восстановления отсутствующих каналов ЭЭГ. По оси абсцисс отложен индекс канала, по оси ординат — среднеквадратичная ошибка (англ. Mean Squared Error, MSE). Метод нулевого заполнения характеризуется максимальной ошибкой, тогда как алгоритмы на основе k -ближайших соседей обеспечивают минимальные значения MSE для большинства каналов.

4.3.3. Результаты экспериментов

Для вычислительных экспериментов из всего набора стимулов датасета [146] было отобрано подмножество видеозаписей, разумно сочетающее объем данных с семантическим разнообразием визуальных стимулов. Всего датасет содержит пять типов видеостимулов: абстрактную анимацию **Inscapes**, мультфильмы **The Present** и **Despicable Me**, а также натуралистические видеоролики с обезьянами — **monkey1**, **monkey2**, **monkey5**. Два из них — **Inscapes** и **Despicable Me** — заметно сдвинуты по домену относительно реалистичных сцен. **Inscapes** — это компьютерно сгенерированная последовательность абстрактных трехмерных фигур, лишенных семантически интерпретируемых объектов, а **The Present** и **Despicable Me** принадлежат к жанру анимации с сильно стилизованной визуальной подачей. Обучение на гетерогенной смеси столь различных доменов без явной доменной адаптации приводит к противоречивым градиентам и ухудшению обобщающей способности модели. В связи с этим для основного эксперимента были выбраны три видеостимула из категории **monkey**, которые обеспечивают достаточное разнообразие сцен: различные

ракурсы, освещение, действия персонажей, при сохранении единого визуального домена — натуралистической видеосъемки. Объемы данных по каждому датасету приведены в Таблице 13.

Таблица 13 — Объемы данных по видеостимулам датасета *monkey**, использованным в основном эксперименте. Данные разделены в пропорции 80% к 20% для обучения и тестирования соответственно, с равномерным распределением записей пациентов между выборками

Видеостимул	Общий объем	Обучающая выборка	Тестовая выборка
monkey1	5 941	4 753	1 188
monkey2	4 477	3 582	895
monkey5	4 579	3 664	915

Для верификации эффективности предложенного подхода проведены два эксперимента: визуальный анализ изображений-реконструкций и количественная оценка через CLIP-Score.

В первом эксперименте выполнено сравнение реконструкций, полученных с диффузионной априорной моделью и без нее на тестовых объектах из датасета *monkey**. Примеры приведены на рис. 4.7. Для проверки гипотезы о чувствительности модели к распределению визуальных стимулов был проведен дополнительный эксперимент по кросс-доменной реконструкции. Модель, обученная исключительно на датасете *monkey**, применялась для декодирования сигналов фМРТ–ЭЭГ, зарегистрированных при просмотре абстрактной анимации *Inscapes*. Поскольку визуальные характеристики стимулов *Inscapes* принципиально отличаются от реалистичных сцен, на которых проводилось обучение, энкодер фМРТ–ЭЭГ не получает на вход паттерны нейронной активности, соответствующие выученному распределению. В результате комбинированный эмбединг $\mathbf{z}_c$ формируется в области латентного пространства, удаленной от кластеров, ассоциированных с обучающими стимулами, что приводит к генерации семантически несогласованных изображений, см. рис. 4.8. Без явной доменной адаптации или аугментации тренировочных данных обобщение на распределения с сильным визуальным сдвигом не гарантируется. Для оценки устойчивости моделей необходим датасет с выраженной доменной разнородностью, однако, как показано в разделе 1.8, открытые мультимодальные

наборы данных, обладающие подобным разнообразием визуальных стимулов, на текущий момент отсутствуют.



Рисунок 4.7 — Примеры реконструкции изображений по сигналам фМРТ–ЭЭГ. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL как предельное качество реконструкции; (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Применение априорной модели повышает семантическую согласованность реконструированных изображений с исходными стимулами

Во втором эксперименте проводится количественная оценка с использованием метрики CLIP-Score — косинусной близости между CLIP-эмбедингом реконструированного изображения $\mathbf{z}_I$ и комбинированным представлением мозговой активности $\mathbf{z}_c$:

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \cdot \|\mathbf{z}_I\|}.$$

Метрики вычислялись на тестовой выборке датасета [146], использовались данные из видеостимулов *monkey1*, *monkey2*, *monkey5*. Усреднение проводилось по пациентам и объектам. Для получения результатов в Таблице 14 были использованы следующие конфигурации моделей:

1. ЭЭГ: используется только энкодер ЭЭГ $\mathcal{E}_e$, модуль объединения отключен, эмбединг $\mathbf{Z}_e$ напрямую используется для реконструкции без априорной модели.

1. Оригинальное
изображение

2. Оригинальная
реконструкция

3. Предлагаемым
методом

4. Предлагаемым
методом с
Diffusion Prior




Рисунок 4.8 — Пример реконструкции стимула из домена *Inscapes* моделью, обученной на датасете *monkey**. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL как предельное качество реконструкции; (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Отсутствие семантической согласованности обусловлено доменным сдвигом между обучающими и тестируемыми стимулами

2. **фМРТ**: используется только энкодер фМРТ $\mathcal{E}_f$, модуль объединения отключен, эмбединг $\mathbf{Z}_f$ напрямую используется для реконструкции без априорной модели.
3. **фМРТ–ЭЭГ**: используются оба энкодера $\mathcal{E}_e$ и $\mathcal{E}_f$ с модулем объединения $\mathcal{F}$, формирующим комбинированный эмбединг $\mathbf{Z}_c$ без априорной модели.
4. **ЭЭГ & Diffusion Prior**: используется энкодер ЭЭГ с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.
5. **фМРТ & Diffusion Prior**: используется энкодер фМРТ с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.
6. **фМРТ–ЭЭГ & Diffusion Prior**: используется полная архитектура с обоими энкодерами, модулем объединения и априорной диффузионной моделью.

Полученные результаты демонстрируют, что использование одной модальности дает худшие показатели по сравнению с комбинированной моделью на основе фМРТ и ЭЭГ. Более того, интеграция диффузионной априорной модели существенно повышает CLIP-Score для всех конфигураций, а наилучшее качество достигается при совместном использовании фМРТ, ЭЭГ и диффузионной априорной модели. Это подтверждает, что мультимодальность компенсирует ограничения отдельных методов регистрации, а двухстадийная генерация необходима для семантической точности реконструкции.

Таблица 14 — Сравнение CLIP-Score для различных конфигураций модели на трех видеостимулах из набора данных. Произведено усреднение по всем 22 пациентам, нижним регистром указаны среднеквадратичные отклонения. Наилучшие результаты выделены жирным шрифтом

Модель	Название видеостимула		
	monkey1	monkey2	monkey5
ЭЭГ	0,231 $\pm$ 0,004	0,262 $\pm$ 0,004	0,224 $\pm$ 0,005
фМРТ	0,254 $\pm$ 0,004	0,270 $\pm$ 0,003	0,242 $\pm$ 0,003
фМРТ–ЭЭГ	0,310 $\pm$ 0,003	0,312 $\pm$ 0,004	0,284 $\pm$ 0,003
ЭЭГ & Diffusion Prior	0,542 $\pm$ 0,005	0,557 $\pm$ 0,003	0,538 $\pm$ 0,003
фМРТ & Diffusion Prior	0,564 $\pm$ 0,005	0,571 $\pm$ 0,004	0,551 $\pm$ 0,005
фМРТ–ЭЭГ & Diffusion Prior	0,668 $\pm$ 0,003	0,647 $\pm$ 0,005	0,644 $\pm$ 0,003

4.3.4. Ограничения метода

Отдельно стоит оговорить ограничения, которые накладывает использование CLIP-пространства как промежуточного представления. CLIP обучался сопоставлять изображения с текстовыми описаниями, поэтому его эмбединги несут преимущественно семантику высокого уровня — объекты, их взаимосвязи, общий контекст сцены — но почти не удерживают низкоуровневые визуальные характеристики: точные текстуры, локальные паттерны, пиксельные детали. Как следствие, предложенный метод реконструкции нацелен на семантическую согласованность полученных изображений с исходными стимулами, а не на

точное пиксельное воспроизведение низкоуровневых деталей. Это ограничение вытекает из выбора CLIP в качестве промежуточного представления и присуще всем подходам на основе CLIP-эмбеддингов [125—127].

Метод проверялся на одном публичном датасете [146], а качество реконструкции оценивалось преимущественно метрикой CLIP-Score. Кросс-доменные эксперименты подтвердили, что обобщающая способность модели ограничена: на стимулах из домена, которого не было в обучающей выборке — например, на абстрактной анимации **Inscapes** — качество реконструкции заметно снижается. Энкодеры подстраивают свои представления под конкретное распределение визуальных признаков обучающего домена и не обладают встроенной инвариантностью к резким семантическим сдвигам. Поэтому перенос метода на другие типы стимулов — статичные изображения, абстрактные паттерны, текстовые сцены — либо на иные условия регистрации потребует дополнительной валидации и, вероятно, явной доменной адаптации. Сказывается и индивидуальная вариабельность нейронной активности пациентов, от которой также зависит качество метода. Привлечение гетерогенных датасетов или альтернативных метрик усилило бы выводы, хотя и имеющихся результатов достаточно для подтверждения работоспособности подхода в рамках заявленного домена.

Заключение

В диссертационной работе решена задача разработки методов декодирования внешнего воздействия по мультимодальным многомерным временным рядам в условиях ограниченного объема выборки. Методы последовательно используют временную, пространственную и межмодальную структуру сигнала и проверены на данных нейровизуализации.

Основные результаты работы заключаются в следующем.

1. Построена линейная авторегрессионная модель прогнозирования фМРТ-отклика по предъявленному стимулу и на ее основе предложен метод оценки гемодинамического лага по минимуму ошибки восстановления. В локализованной области отклика ошибка имеет выраженный минимум около пяти секунд, согласующийся с физиологическими оценками, тогда как по всему объему скана минимум не выражен. Этот результат обосновывает явный учет лага и выделение информативной области в последующих методах.
2. Разработан метод классификации временных рядов фМРТ одного пациента: маски активности классов выделяются по кросс-корреляции сигнала со стимулом, а ковариация отобранных вокселей проецируется на касательное пространство в точке риманова среднего, так что объект описывается отдельно с точки зрения каждого класса. Размерность признаков не зависит от объема выборки; на данных с восемью категориями стимулов метод превосходит нейросетевые модели, а исключение любой из компонент значительно снижает качество.
3. Доказаны теоретические свойства касательных признаков ковариационных матриц: инвариантность к невырожденному преобразованию каналов, не меняющая ответ логистической регрессии; двусторонняя оценка искажения расстояний с неулучшаемой константой, выраженной через спектральный разброс касательных векторов; оценка концентрации ошибки оценки ковариации в геодезической метрике, распределение которой не зависит от истинной ковариации.
4. Предложена мультимодальная архитектура реконструкции стимула по одновременным записям фМРТ и ЭЭГ с контрастивным выравниванием совместных представлений с пространством CLIP и двухстадийной

диффузионной генерацией. Объединение модальностей повышает качество реконструкции по сравнению с каждой из них в отдельности, а априорная диффузионная модель необходима для семантической согласованности результата.

5. Разработан метод восстановления отсутствующих каналов ЭЭГ по геометрии монтажа и его вероятностное обобщение на основе маскированного согласования потоков; доказано, что при точном векторном поле обобщение восстанавливает условное распределение пропусков.

Теоретическая значимость результатов заключается в строгом обосновании широко применяемой конструкции касательных признаков: получены утверждения с явными константами, связывающими число каналов, длину ряда и ошибку признаков. Практическая значимость состоит в возможности декодирования по записям одного пациента объемом в десятки объектов, в межсубъектной нейросетевой реконструкции стимула по одновременным записям фМРТ и ЭЭГ и в применимости методов к записям с неполным набором каналов; программные реализации методов опубликованы.

Результаты работы рекомендуется использовать при декодировании по записям одного пациента, когда объем размеченной выборки измеряется десятками объектов и нейросетевые модели неприменимы, для чего предназначены методы оценки лага и классификации, и при построении межсубъектных нейросетевых моделей реконструкции по одновременным записям фМРТ и ЭЭГ, в том числе на записях с неполным набором каналов.

К перспективам дальнейшего развития темы относятся проверка полученных оценок искажения и шума на реальных записях фМРТ и ЭЭГ, обобщение постановки на большее число модальностей с неизвестными взаимными лагами, экспериментальная проверка вероятностного восстановления каналов и его включение в контур декодирования, а также перенос методов на мультимодальные временные ряды иной природы.

Автор выражает благодарность научному руководителю к.ф.-м.н. А.В. Грабовому за постановку задач, обсуждение результатов и научное руководство.

Публикации автора по теме диссертации

В рецензируемых научных журналах

- A1. Forecasting fMRI Images From Video Sequences: Linear Model Analysis / D. Dorin [et al.] // Health Information Science and Systems. — 2024. — Vol. 12, no. 1. — P. 55.
- A2. *Dorin, D.* Enhancing fMRI Data Decoding with Spatiotemporal Characteristics in Limited Dataset / D. Dorin, A. Grabovoy, V. Strijov // Doklady Rossijskoj Akademii Nauk. Matematika, Informatika, Processy Upravleniya. — 2025. — Vol. 527. — P. 11—30.
- A3. *Дорин, Д. Д.* Декодирование визуальной информации из нейронных сигналов: реконструкция изображений на основе совместного анализа функциональной магнитно-резонансной томографии и электроэнцефалографии / Д. Д. Дорин, Н. С. Киселев, А. В. Грабовой // Информатика и её применения. — 2026. — Т. 20, № 2. — С. 35—49.

В сборниках трудов конференций

- A4. *Дорин, Д. Д.* Декодирование визуальных стимулов из мультимодальных сигналов мозга / Д. Д. Дорин, Н. С. Киселев, А. В. Грабовой // Тезисы докладов 22-й всероссийской конференции с международным участием «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября, 2025 г. — М. : МАКС Пресс, 2025. — С. 124—126.
- A5. *Дорин, Д. Д.* Пространственно-временные методы анализа временных рядов / Д. Д. Дорин, Н. С. Киселев, А. В. Грабовой // Труды 66-й Всероссийской научной конференции МФТИ, 1–6 апреля 2024 г. — Долгопрудный : МФТИ, 2024. — С. 127.
- A6. *Дорин, Д. Д.* Улучшение декодирования фМРТ в условиях ограниченной выборки / Д. Д. Дорин, А. В. Грабовой // Труды 67-й Всероссийской научной конференции МФТИ. — Долгопрудный : МФТИ, 2025.

- A7. *Дорин, Д. Д.* Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик / Д. Д. Дорин, А. В. Грабовой // Труды 68-й Всероссийской научной конференции МФТИ. — Долгопрудный : МФТИ, 2026.
- A8. *Дорин, Д. Д.* Декодирование фМРТ в условиях ограниченной выборки / Д. Д. Дорин, А. В. Грабовой // AI Journey 2025, Москва, 19–21 ноября 2025 г. — 2025.
- A9. *Дорин, Д. Д.* Пространственно-временные характеристики в задаче декодирования мультимодальных многомерных временных рядов / Д. Д. Дорин, А. В. Грабовой // Интеллектуализация обработки информации: тезисы докладов 16-й Международной конференции, Витебск, 28 сентября – 1 октября 2026 г. — 2026.

Список рисунков

1.1	Три постановки задачи декодирования, упорядоченные по сложности описываемой структуры данных. Штриховые линии — учет гемодинамического лага Δt , необходимость которого показана в первой постановке, в двух последующих: при построении масок активности и при временной синхронизации модальностей . . .	11
1.2	Иллюстрация задачи реконструкции изображений по одновременным сигналам фМРТ–ЭЭГ	18
2.1	Схема модели прогнозирования снимков фМРТ по стимулу. На этапе предобработки из видеокadra предобученным энкодером извлекаются признаки, а фМРТ-сканы нормируются. На этапе прогнозирования многомерная линейная модель отображает эмбединг видеокadra в приращение между двумя последовательными сканами	25
2.2	Визуализация данных используемого набора. Для примера выбраны три момента времени. Слева показаны видеокadры, справа — срезы фМРТ-сканов за соответствующий период для трех пациентов: 7, 13 и 47. Частота видеокadров выше, поэтому каждому фМРТ-скану соответствует несколько кадров	27
2.3	Срезы фМРТ-сканов из тестовой выборки для 7-го пациента: истинный и восстановленный сканы и разность между ними. Ошибка порядка 10^{-3} свидетельствует о достаточно точном прогнозе	29
2.4	Локализация наиболее активной зоны для 47-го пациента. Красным выделены 3% наиболее изменчивых во времени вокселей затылочной доли, которая отвечает за обработку визуальной информации, в том числе при просмотре видеоряда. Это подтверждает корректность локализации	29
2.5	Зависимость MSE от величины гемодинамического лага Δt . Слева — расчет по всему фМРТ-скану, где выраженный минимум отсутствует из-за шума от областей, не связанных со зрением. Справа — расчет на локализованной затылочной доле, дающий отчетливый минимум при $\Delta t \approx 5$ с	30

- 2.6 Зависимость MSE на тестовой выборке от параметра регуляризации λ (на графике обозначен α) при различных коэффициентах сжатия. Оптимальное значение составляет $\lambda \approx 1000$; увеличение коэффициента сжатия снижает качество из-за уменьшения числа фоновых вокселей 31
- 2.7 Распределение компонент усредненного по вокселям вектора весов вспомогательной модели для 4-го пациента. Веса не концентрируются вокруг одного значения, что указывает на невырожденное распределение и свидетельствует об обученности модели, опирающейся на разнообразные признаки 32
- 2.8 Процентное изменение MSE при прогнозе со смешанной матрицей весов. Каждая строка и каждый столбец соответствуют пациенту; «смешанная» ошибка получена прогнозом по весам другого пациента. Положительные значения означают, что «смешанная» MSE больше «собственной» 34
- 2.9 Срезы последнего скана тестовой последовательности 35-го пациента: истинный скан, авторегрессионное восстановление по исходным видеокадрам и разность между ними 35
- 2.10 Срезы последнего скана тестовой последовательности при неинформативных данных. Значение MSE для неинформативной выборки больше, что указывает на наличие корреляции в истинных данных 35
- 3.1 Обзор предложенной методологии. Классифицируются временные ряды фМРТ с учетом индивидуальных структур мозга, не требуя больших объемов данных. Ключевые компоненты включают выделение областей интереса (англ. Region of Interest, ROI) и преобразование пространства признаков с использованием римановой геометрии, что составляет основу извлечения пространственно-временных характеристик. Результатом классификации является распределение вероятностей по категориям стимулов. Кроме того, используются методы аугментации данных для улучшения обучения на данных отдельных пациентов 38

- 3.2 Схема модели классификации для одного объекта $\mathbf{S}$ из $\mathcal{T}$ сканов. Строка y отвечает классу y : маска активности $\mathcal{M}^y$, построенная по кросс-корреляции сигнала со стимулом при лаге Δt , отбирает ряды активных вокселей $\mathbf{Y}_y$; их ковариационная матрица $\mathbf{R}_y$ проецируется логарифмическим отображением на касательное пространство в точке риманова среднего $\bar{\mathbf{R}}_y$, что дает вектор $\mathbf{p}_y$ соответствия объекта классу y . Векторы всех классов конкатенируются в признак $\mathbf{p} \in \mathbb{R}^d$, по которому классификатор η предсказывает класс $\hat{y}$ 39
- 3.3 Проекция на касательное пространство. Ковариационная матрица $\mathbf{R}_j$ проецируется на касательное пространство $T_{\bar{\mathbf{R}}}$ в точке риманова среднего $\bar{\mathbf{R}}$ логарифмическим отображением $\text{Log}_{\bar{\mathbf{R}}}(\mathbf{R}_j)$; проекция $\mathbf{P}_j$ возвращается на многообразии $\mathcal{R}$ экспоненциальным отображением $\text{Exp}_{\bar{\mathbf{R}}}(\mathbf{P}_j)$. Длина $\|\mathbf{P}_j\|_{\bar{\mathbf{R}}}$ касательного вектора в аффинно-инвариантной метрике равна геодезическому расстоянию $\delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_j)$ 46
- 3.4 Искривление расстояний при проекции на касательное пространство. Точки $\mathbf{R}_i, \mathbf{R}_j, \mathbf{R}_k$ лежат на окружности геодезического радиуса ρ вокруг $\bar{\mathbf{R}}$, их образы $\mathbf{p}_i, \mathbf{p}_j, \mathbf{p}_k$ — на окружности того же радиуса в $T_{\bar{\mathbf{R}}}$. Радиальное расстояние через $\bar{\mathbf{R}}$ сохраняется: $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_k) = \|\mathbf{p}_i - \mathbf{p}_k\|_2 = 2\rho$. Тангенциальное расстояние между соседними точками окружности при возвращении на многообразие растягивается: отношение $\delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j)/\|\mathbf{p}_i - \mathbf{p}_j\|_2$ меньше $c(\rho)$ и по предложению 3.3.9 стремится к $c(\rho)$ при сближении $\mathbf{R}_j$ с $\mathbf{R}_i$ 57
- 3.5 Визуализация стимулов из используемого набора данных. В наборе данных представлено 8 различных типов визуальных стимулов. Для каждого типа выбрано по 4 примера изображений. Стимулы для каждой категории значительно различаются. 59

- 3.6 Визуализация масок активности фМРТ. Выбранные области обозначены красным цветом. На верхней строке показаны предсказанные маски активности с использованием Алгоритма 1, на средней строке — статистически значимые области, полученные в результате анализа, а на нижней строке — аннотации нейрочученых в качестве эталона. Предсказанные области достаточно покрывают истинные аннотации, а статистически значимая корреляция взвешенных вокселей со стимулами подтверждает надежность алгоритма 63
- 3.7 **Анализ работы Алгоритма 1 на неинформативных данных.** Представлены срезы по трем измерениям. Использовался случайно сгенерированный бинарный временной ряд стимулов. Алгоритм предсказывает случайные области, не связанные с активностью мозга 64
- 3.8 Анализ улучшения качества декодирования в зависимости от доли обучающей выборки. Графики представляют метрики Ассигасу и Макро F1-score, усредненные по пациентам, в зависимости от доли обучающей выборки, изменяющейся от 0 до 1. Метрики вычислялись на одной и той же тестовой выборке для обеспечения согласованности. Результаты демонстрируют последовательное улучшение качества декодирования по мере увеличения размера обучающей выборки 65
- 3.9 Отношение геодезического расстояния к евклидову для пар предложения 3.3.9: касательные векторы с собственными значениями $\pm \rho / \sqrt{2}$, собственные базисы которых повернуты друг относительно друга на угол θ . Пунктиром показана граница $c(\rho)$ теоремы 3.3.8 69
- 3.10 Зависимость от радиуса облака ρ при $h = 8$; средние и стандартные отклонения по десяти задачам. (а) Точность TSM, MDM, лог-евклидовой проекции и евклидовой векторизации на тестовой выборке. (б) Отношение геодезического расстояния между объектами к евклидову расстоянию между их признаками по всем парам обучающих объектов в сравнении с границами $c(\rho)$ и $g(\omega)$ теоремы 3.3.8 71

- 3.11 Шум оценки ковариаций при $s = 0,5$. (а) Точность TSM на тестовой выборке при обучении на выборочных ковариациях в зависимости от числа отсчетов $\mathcal{T}$; пунктиром показана точность на истинных ковариациях. (б) Средняя ошибка $\delta_{\mathcal{R}}(\hat{\mathbf{R}}_i, \mathbf{R}_i)$ и граница теоремы 3.3.11 при уровне доверия 0,95 72
- 4.1 Схема декодирования изображений на основе сигналов фМРТ–ЭЭГ. Процесс декодирования реализуется в два этапа. На первом этапе проводится контрастное обучение энкодера сигналов фМРТ–ЭЭГ, в ходе которого представления мозговых сигналов выравниваются с замороженными эмбедингами изображений, полученными с помощью модели CLIP. На втором этапе осуществляется двухстадийная генерация реконструкций: сначала обучается диффузионная априорная модель для уточнения эмбедингов сигналов мозга, а затем предобученная диффузионная модель, обусловленная на CLIP-эмбединги, генерирует реконструкции изображений 80
- 4.2 Архитектуры кодировщиков фМРТ и ЭЭГ. *Слева:* энкодер ЭЭГ интегрирует индивидуальные обучаемые эмбединги пациентов с исходными многоканальными данными посредством конкатенации, формируя единое векторное представление; далее применяются одномерные свертки по временному и каналному измерениям, а также MLP-голова для генерации итоговых эмбедингов. *Справа:* энкодер фМРТ включает персонализированное маскирование мозга, векторизацию вокселей и проекцию в латентное пространство через индивидуальный линейный слой; завершающая обработка осуществляется с использованием MLP с остаточными соединениями 83
- 4.3 Иллюстрация контрастивного обучения и формирования батчей. Отрицательные примеры формируются автоматически. Косинусные расстояния между эмбедингами замороженного CLIP и нейронными эмбедингами используются в качестве логитов 85

- 4.4 Для снижения размерности данных фМРТ применяются маски головного мозга, исключаящие фоновые воксели, не несущие информации о визуальном стимуле. Маски формируются на основе анализа наиболее изменчивых вокселей в ответ на стимуляцию. Воксели, включенные в маску, выделены красным цветом 89
- 4.5 Конфигурация монтажа из $K = 61$ кортикального электрода, используемая в датасете [146]. Датчики расположены согласно системе 10–20. Данная схема используется для восстановления отсутствующих каналов методом k -ближайших соседей, описанным в разделе 4.2.1. 90
- 4.6 Сравнение стратегий восстановления отсутствующих каналов ЭЭГ. По оси абсцисс отложен индекс канала, по оси ординат — среднеквадратичная ошибка (англ. Mean Squared Error, MSE). Метод нулевого заполнения характеризуется максимальной ошибкой, тогда как алгоритмы на основе k -ближайших соседей обеспечивают минимальные значения MSE для большинства каналов. 91
- 4.7 Примеры реконструкции изображений по сигналам фМРТ–ЭЭГ. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL как предельное качество реконструкции; (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Применение априорной модели повышает семантическую согласованность реконструированных изображений с исходными стимулами 93

- 4.8 Пример реконструкции стимула из домена **Inscapes** моделью, обученной на датасете **monkey***. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL как предельное качество реконструкции; (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Отсутствие семантической согласованности обусловлено доменным сдвигом между обучающими и тестируемыми стимулами 94

Список таблиц

1	Характеристики используемого набора данных	27
2	Характеристики вычислительной системы	28
3	Зависимость времени обучения модели от коэффициента сжатия . .	31
4	Проверка гипотезы об инвариантности весов модели относительно пациентов	33
5	Качество работы метода на неинформативных данных	35
6	Основные параметры временных рядов фМРТ из выборки	60
7	Параметры выборки каждого пациента, полученной в результате аугментации временных рядов фМРТ	60
8	Усредненные значения метрик для сравнения масок активности. В таблице представлены средние значения и стандартные отклонения для каждой метрики	61
9	Средние значения метрик по пациентам для тестовой выборки, включая стандартные отклонения и 95% доверительные интервалы (англ. Confidence Interval, CI)	64
10	Анализ методом исключения компонент влияния отдельных компонентов модели на качество классификации. Метрики на тестовых выборках усреднены по пациентам. Статистическая значимость обозначена звездочками: * p -value < .05, ** p -value < .005, отражающими значимость улучшений относительно полной модели. Доверительные интервалы (англ. Confidence Interval, CI) представляют диапазон, в котором, вероятно, находятся истинные значения метрик с 95% доверительной вероятностью.	66
11	Сравнение модели с подходами на основе нейронных сетей. Метрики усреднены по пациентам для тестовой выборки, с указанием статистической значимости и доверительных интервалов. Статистическая значимость обозначена звездочками: ** p -value < .005. .	67
12	Описание оборудования и основные параметры нейросигналов	88

- 13 Объемы данных по видеостимулам датасета **monkey***,
использованным в основном эксперименте. Данные разделены в
пропорции 80% к 20% для обучения и тестирования соответственно,
с равномерным распределением записей пациентов между выборками 92
- 14 Сравнение CLIP-Score для различных конфигураций модели на
трех видеостимулах из набора данных. Произведено усреднение по
всем 22 пациентам, нижним регистром указаны
среднеквадратичные отклонения. Наилучшие результаты выделены
жирным шрифтом 95