

Вопросы по выпускной квалификационной работе и ответы

Дорин Д. Д. «Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик»

Вопрос 1. Как метод объединения двух модальностей фМРТ и ЭЭГ учитывает разную природу их данных, в частности, частоту?

Разная природа модальностей учитывается на трех уровнях. Во-первых, на этапе предобработки: записи имеют существенно различные частоты дискретизации (фМРТ обновляется с частотой 0,476 Гц, ЭЭГ регистрируется с частотой 5000 Гц), поэтому данные приводятся к согласованным триплетам (фМРТ, ЭЭГ, изображение). Каждому фМРТ-тензору в момент t ставятся в соответствие окно ЭЭГ и кадр видеостимула, отвечающие моменту $t - \Delta t$, где Δt — гемодинамическая задержка BOLD-сигнала, оцененная в работе (≈ 5 с): фМРТ-отклик запаздывает относительно стимула, тогда как ЭЭГ отражает нейронную активность практически без задержки. Во-вторых, на уровне архитектуры: для каждой модальности спроектирован отдельный энкодер, учитывающий ее структуру. Энкодер ЭЭГ обрабатывает многоканальный временной ряд последовательностью одномерных сверток по временному и каналному измерениям; энкодер фМРТ работает с пространственным тензором через индивидуальную маску мозга и персонализированную линейную проекцию. В-третьих, на уровне объединения: полученные эмбединги переводятся модулем объединения в единое латентное пространство, где высокочастотная временная информация ЭЭГ и пространственно детализированная информация фМРТ дополняют друг друга; сравнительный анализ исключением модальностей подтверждает вклад каждой из них.

Вопрос 2. Какие другие метрики качества реконструкции помимо CLIP-Score могут быть использованы для корректного анализа ошибки метода?

Оценка качества реконструкции или генерации изображений опирается на пиксельные, структурные, перцептивные и вероятностные метрики. Пиксельные метрики, такие как средняя квадратичная ошибка (MSE) и пиковое отношение сигнал-шум (PSNR), измеряют абсолютные различия между сгенерированным и эталонным изображениями. MSE вычисляется как среднее значение квадратов разностей между соответствующими пикселями:

$$MSE = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (I_{\text{ref}}(i, j) - I_{\text{gen}}(i, j))^2$$

где H и W — высота и ширина изображения, а I_{ref} и I_{gen} — значения пикселей эталонного и сгенерированного изображений. PSNR определяется через MSE и максимальное возможное значение пикселя MAX_I , что позволяет оценить качество в логарифмической шкале:

$$\text{PSNR} = 10 \cdot \log_{10} (\text{MAX}_I^2 / \text{MSE})$$

Эти метрики часто плохо коррелируют с субъективным визуальным восприятием, поскольку не учитывают структурные особенности. Для учета структурной информации применяется индекс структурного сходства (SSIM), оценивающий изменение яркости, контраста и структуры:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

где μ и σ^2 — средние значения и дисперсии, σ_{xy} — ковариация окон изображений, а C_1 и C_2 — константы для стабилизации деления. Многошкальная версия MS-SSIM применяет данную процедуру на нескольких уровнях разрешения. Перцептивные метрики используют глубокие нейронные сети для оценки сходства в пространстве признаков. Метрика LPIPS вычисляет взвешенную разницу между активациями слоев предобученной сети, что лучше согласуется с человеческим восприятием:

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h, w} \|\hat{w}_l \odot (f_l(x)_{hw} - f_l(y)_{hw})\|_2^2$$

где f_l представляет собой нормализованные активации l -го слоя сети, а w_l и $\hat{w}_l$ — параметры масштабирования. Для оценки генеративных моделей, обучающихся распределению данных, применяются метрики, сравнивающие распределения признаков реальных и сгенерированных выборок. Fréchet Inception Distance (FID) вычисляет расстояние Фреше между нормальными распределениями, аппроксимирующими признаки, извлеченные сетью InceptionV3:

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

где μ и Σ — векторы средних значений и ковариационные матрицы для реальных и сгенерированных данных. Альтернативой служит Kernel Inception Distance (KID), использующий ядерные методы для оценки максимального среднего расхождения без предположения о нормальности распределения.

Вопрос 3. Почему значения MSE в эксперименте по оценке гемодинамической задержки имеют порядок 10^{-5} ? Не свидетельствует ли это о вырожденности модели?

Это естественный масштаб данных. Значения вокселей нормированы в $[0, 1]$, а модель предсказывает не сам скан, а приращение между соседними сканами — разности маленькие. Возведение в квадрат и усреднение по десяткам тысяч вокселей и по объектам закономерно дает среднее порядка 10^{-5} . Это числовой масштаб нормированных приращений, а не признак «слишком хорошей» или вырожденной модели. Кроме того, анализ является относительным: интерес представляет не абсолютный уровень ошибки, а положение минимума кривой $\text{MSE}(\Delta t)$, которое к масштабу ошибки не чувствительно — любой постоянный множитель сдвигает всю кривую одинаково и не меняет точку минимума.