

Пространственно-временные методы декодирования мультимодальных многомерных временных рядов

Даниил Дмитриевич Дорин

Диссертация на соискание ученой степени
кандидата физико-математических наук

1.2.1 — Искусственный интеллект и машинное обучение

Научный руководитель: к.ф.-м.н. А. В. Грабовой

Москва — 2026

Пространственно-временные методы декодирования мультимодальных многомерных временных рядов

Исследуется задача декодирования: сигнал задан измерениями, реакция порождена внешним воздействием, требуется восстановить воздействие по измерениям. Выборка **ограничена**, а отклик **избыточен по пространству** и **запаздывает во времени** относительно воздействия.

Задача

Построить отображение декодирования, опирающееся на **временную**, **пространственную** и **межмодальную** структуру.

Метод решения

1. **Время**: лаг отклика оценивается по ошибке прогноза сигнала.
2. **Пространство**: отбор информативных каналов, ковариация как точка риманова многообразия.
3. **Модальности**: вторая дополняет первую и повышает качество.

Методы формулируются для любых многоканальных рядов и проверяются на функциональной магнитно-резонансной томографии (фМРТ) и электроэнцефалографии (ЭЭГ) при визуальной стимуляции.

Постановка задачи

Пусть $\mathcal{X}_{(m)}$ обозначает пространство наблюдений модальности m , где $m = 1, \dots, M$. Тогда совместное пространство данных

$$\mathcal{X} = \mathcal{X}_{(1)} \times \dots \times \mathcal{X}_{(M)}.$$

Внешний стимул или его характеристика $\mathbf{y} \in \mathcal{Y}$. Требуется построить отображение декодирования

$$\mathbf{g} : \mathcal{X} \rightarrow \mathcal{Y}.$$

Решаемые задачи

Классификация временных рядов фМРТ по категориям стимулов

$$\mathbf{g} : \mathcal{X}_f \rightarrow \{1, \dots, C\}.$$

Реконструкция изображений по совместным сигналам фМРТ–ЭЭГ

$$\mathbf{g} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}.$$

Оценка гемодинамического лага


Скан фМРТ $\mathbf{F}(t)$ соответствует кадру $\mathbf{y}(t - \Delta t)$, предъявленному на гемодинамический лаг Δt раньше. Лаг оценивается по качеству прогноза фМРТ-отклика по стимулу в обратной к декодированию задаче.

Линейная авторегрессионная модель

Приращение скана $\delta(t) = \mathbf{F}(t) - \mathbf{F}(t-1)$ линейно по эмбедингу $\mathbf{x}(t)$ кадра $\mathbf{y}(t - \Delta t)$, полученному предобученным энкодером:

$$\hat{\delta}(t) = \hat{\mathbf{W}} \mathbf{x}(t), \quad \hat{\mathbf{W}}(\Delta t) = \arg \min_{\mathbf{W}} \sum_t \|\delta(t) - \mathbf{W} \mathbf{x}(t)\|_2^2 + \lambda \|\mathbf{W}\|_F^2.$$


Лаг выбирается по минимуму MSE на тестовой выборке.



На зрительной коре минимум MSE выражен отчетливо, а найденный лаг согласуется с физиологией BOLD-отклика.

Метод классификации: признаки соответствия классам


Заданы ряды фМРТ S_i одного испытуемого с метками $y_i \in \{1, \dots, L\}$; ищется классификатор $h: \mathcal{X}_s \rightarrow \{1, \dots, L\}$. Маски классов строит алгоритм кросс-корреляции сигнала со стимулом при лаге Δt .



Ковариация R_y рядов области проецируется отображением Log в точку среднего $\bar{R}_y$ класса; вектор p_y измеряет соответствие объекта классу y , признаки всех классов конкатенируются.

Проекция на риманово касательное пространство

Ковариация $\mathbf{R}_j$ проецируется на касательное пространство $T_{\mathbf{R}}$ в точке $\mathbf{R}$ отображением $\text{Log}_{\mathbf{R}}$ и возвращается на многообразие $\mathcal{R}$ отображением $\text{Exp}_{\mathbf{R}}$; длина геодезической между $\mathbf{R}$ и $\mathbf{R}_j$ равна $\delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}_j)$.



$$\text{Log}_{\mathbf{R}}(\mathbf{R}_j) = \mathbf{R}^{\frac{1}{2}} \log(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_j \mathbf{R}^{-\frac{1}{2}}) \mathbf{R}^{\frac{1}{2}} \in T_{\mathbf{R}},$$

$$\text{Exp}_{\mathbf{R}}(\mathbf{P}_j) = \mathbf{R}^{\frac{1}{2}} \exp(\mathbf{R}^{-\frac{1}{2}} \mathbf{P}_j \mathbf{R}^{-\frac{1}{2}}) \mathbf{R}^{\frac{1}{2}} \in \mathcal{R},$$

$$\delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}_j) = \left\| \log(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_j \mathbf{R}^{-\frac{1}{2}}) \right\|_F.$$


Точкой касания служит риманово среднее ковариаций выборки $\mathbf{R} = \bar{\mathbf{R}}$.

Сохранение расстояний и устойчивость проекции

Теорема 1 (Дорин, 2026)

Пусть $\delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i) \leq \rho$ для всех i . Тогда норма признака равна геодезическому расстоянию до среднего, $\|\mathbf{p}_i\|_2 = \delta_{\mathcal{R}}(\bar{\mathbf{R}}, \mathbf{R}_i)$, а расстояния между признаками искажаются не более чем в $c(\rho) = \sinh(\rho/\sqrt{2})/(\rho/\sqrt{2})$ раз, и эта константа неумлучшаема:


$$\|\mathbf{p}_i - \mathbf{p}_j\|_2 \leq \delta_{\mathcal{R}}(\mathbf{R}_i, \mathbf{R}_j) \leq c(\rho) \|\mathbf{p}_i - \mathbf{p}_j\|_2.$$



Теорема 2 (Дорин, 2026)


Пусть $\hat{\mathbf{R}}$ выборочная ковариация по $\mathcal{T}$ гауссовским сканам с ковариацией $\mathbf{R} \in \mathbb{S}_+^h$. Тогда распределение $\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R})$ не зависит от $\mathbf{R}$, и при $\varepsilon = \sqrt{h/\mathcal{T}} + t < 1$ с вероятностью не меньше $1 - 2e^{-\mathcal{T}t^2/2}$

$$\delta_{\mathcal{R}}(\hat{\mathbf{R}}, \mathbf{R}) \leq \frac{2\sqrt{h}\varepsilon}{1-\varepsilon} = O(h/\sqrt{\mathcal{T}}).$$




Маски активности


Данные Нахby et al., первый испытуемый: частота сканирования $\mu = 2,5$ Гц, $h = 10$ областей, ядро $k_s = 4$.



(a) Алгоритм



(b) Статистически
значимые области



(c) Разметка
нейробиологов

Области, выделенные алгоритмом, покрывают разметку нейробиологов; корреляция отобранных вокселей со стимулом статистически значима.

Анализ компонент и сравнение с нейросетями

Рассматривается датасет Naхby et al., состоящий из данных 6 испытуемых, объем $N = 96$, число классов $C = 8$. Тест — 20%. Метрики усреднены по 6 выборкам. Статистическая значимость обозначена $*p < .05$, $**p < .005$.

Анализ исключением компонент

Три упрощенные модели, указаны 95%-е доверительные интервалы.

Method	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Ours, w/o TSM	$0.24 \pm 0.11^*$	$0.22 \pm 0.11^*$	$0.24 \pm 0.11^*$	[0.11, 0.37]	[0.09, 0.36]	[0.10, 0.37]
Ours, w/o Class Masks	$0.25 \pm 0.13^*$	$0.23 \pm 0.13^*$	$0.25 \pm 0.13^*$	[0.09, 0.41]	[0.07, 0.39]	[0.09, 0.41]
Ours, Original Mask	$0.10 \pm 0.05^{**}$	$0.09 \pm 0.04^{**}$	$0.10 \pm 0.05^{**}$	[0.04, 0.16]	[0.03, 0.14]	[0.04, 0.16]
Ours	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Сравнение с нейросетевыми решениями


Нейросетевые модели LSTM и Attention на масках нейробиологов.

Model	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Original Mask & LSTM	$0.12 \pm 0.02^{**}$	$0.03 \pm 0.01^{**}$	$0.12 \pm 0.02^{**}$	[0.09, 0.14]	[0.02, 0.04]	[0.09, 0.14]
Original Mask & Attention	$0.14 \pm 0.04^{**}$	$0.04 \pm 0.03^{**}$	$0.14 \pm 0.04^{**}$	[0.11, 0.18]	[0.02, 0.07]	[0.11, 0.18]
Ours, Logistic Regression φ	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Исключение любой компоненты значимо снижает качество; на малой выборке метод превосходит нейросетевые модели.

Мультимодальная реконструкция стимула

Задан датасет триплетов (фМРТ, ЭЭГ, изображение) $\mathcal{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)\}_{i=1}^N$; требуется построить отображение $\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$.



Первый этап выравнивает объединенные представления фМРТ-ЭЭГ с эмбедингами CLIP, второй порождает изображение двухстадийной диффузией, prior в пространстве CLIP и затем SDXL.

Контрастивное выравнивание представлений

Батч из B триплетов дает B эмбедингов изображений $\mathbf{Z}_I$ и B объединенных эмбедингов мозга $\mathbf{Z}_c$. После нормировки строк $\mathbf{Z}^n = \mathbf{Z} / \|\mathbf{Z}\|$ логиты равны косинусной близости с температурой τ :


$$\mathbf{L} = \mathbf{Z}_c^n (\mathbf{Z}_I^n)^\top e^\tau.$$

Диагональ $\mathbf{L}_{bb}$ отвечает верным парам, остальные $B^2 - B$ элементов служат отрицательными примерами без разметки.

Симметричная контрастивная функция потерь

$$\mathcal{L} = -\frac{1}{2B} \sum_{b=1}^B \left[\log \frac{\exp(\mathbf{L}_{bb})}{\sum_{j=1}^B \exp(\mathbf{L}_{bj})} + \log \frac{\exp(\mathbf{L}_{bb})}{\sum_{i=1}^B \exp(\mathbf{L}_{ib})} \right]$$

Потери обучают энкодеры фМРТ и ЭЭГ и модуль объединения, сближая верные пары и раздвигая остальные в обоих направлениях.



Оценка мультимодальной модели

Качество оценивается по CLIP-Score: косинусной близости объединенного эмбединга $\mathbf{z}_c$ и CLIP-эмбединга изображения $\mathbf{z}_I$,

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \|\mathbf{z}_I\|},$$

усредненной по триплетам тестовой выборки для каждого испытуемого.

Модель	Название видеостимула		
	monkey1	monkey2	monkey5
ЭЭГ	0,231 $\pm$ 0,004	0,262 $\pm$ 0,004	0,224 $\pm$ 0,005
фМРТ	0,254 $\pm$ 0,004	0,270 $\pm$ 0,003	0,242 $\pm$ 0,003
фМРТ–ЭЭГ	0,310 $\pm$ 0,003	0,312 $\pm$ 0,004	0,284 $\pm$ 0,003
ЭЭГ & Diffusion Prior	0,542 $\pm$ 0,005	0,557 $\pm$ 0,003	0,538 $\pm$ 0,003
фМРТ & Diffusion Prior	0,564 $\pm$ 0,005	0,571 $\pm$ 0,004	0,551 $\pm$ 0,005
фМРТ–ЭЭГ & Diffusion Prior	0,668 $\pm$ 0,003	0,647 $\pm$ 0,005	0,644 $\pm$ 0,003

Мультимодальная модель превосходит одномодальные аналоги.

Примеры реконструкции

Реконструкция по одновременным записям фМРТ–ЭЭГ на тесте.

1) Оригинальное изображение




2) Оригинальная реконструкция



3) Нашим методом



4) Нашим методом с Diffusion Prior



Эмбединги CLIP обучены на парах изображение и текст, поэтому хранят семантику сцены и почти не хранят текстуры и пиксельные детали. Метод восстанавливает содержание стимула, а не его точный вид.

Положения, выносимые на защиту

1. Линейная авторегрессионная модель прогнозирования фМРТ-отклика по предъявленному стимулу и метод оценки гемодинамического лага BOLD-сигнала на ее основе.
2. Метод классификации временных рядов фМРТ на основе масок активности классов и проекции ковариационных матриц на касательное пространство риманова многообразия, устойчивый в условиях ограниченного объема выборки одного пациента.
3. Теоретические свойства проекции ковариационных матриц на касательное пространство в точке риманова среднего: инвариантность признаков к невырожденному преобразованию каналов, двусторонняя оценка искажения расстояний с неухудшаемой константой и оценка ошибки оценки ковариации по длине ряда.
4. Мультимодальная архитектура реконструкции стимула по одновременным сигналам фМРТ и ЭЭГ с контрастивным выравниванием совместных представлений и двухстадийной диффузионной генерацией.

Публикации и апробация

Публикации в журналах из перечня ВАК РФ, Scopus, WoS

1. **Dorin D.**, Kiselev N., Grabovoy A., Strijov V. Forecasting fMRI Images From Video Sequences: Linear Model Analysis // Health Information Science and Systems. — 2024.
2. **Dorin D.**, Grabovoy A., Strijov V. Enhancing fMRI Data Decoding with Spatiotemporal Characteristics in Limited Dataset // Doklady Mathematics. — 2025.
3. **Dorin D.**, Kiselev N., Grabovoy A. Decoding Visual Information from Neural Signals: Image Reconstruction Based on Joint fMRI and EEG Analysis // Informatika i ee Primeneniya. — 2026.

Доклады на международных и всероссийских конференциях

1. 16-я Международная конференция «Интеллектуализация обработки информации (ИОИ-2026)», Витебск, 28 сентября — 1 октября 2026.
2. 68-я Всероссийская научная конференция МФТИ, Долгопрудный, 30 марта — 4 апреля 2026.
3. X Международная конференция AI Journey 2025, Москва, 19–21 ноября 2025.
4. 22-я Всероссийская конференция «Математические методы распознавания образов (ММРО-2025)», Муром, 22–26 сентября 2025.
5. 67-я Всероссийская научная конференция МФТИ, Долгопрудный, 31 марта — 5 апреля 2025.
6. XXVI Международная конференция «Нейроинформатика-2024», Долгопрудный, 21–25 октября 2024.
7. 66-я Всероссийская научная конференция МФТИ, Долгопрудный, 1–6 апреля 2024.